


บทที่ 3

ทฤษฎี ฟัซซี่เซตเบื้องต้น

3.1 ทฤษฎี ฟัซซี่เซต


ทฤษฎีฟัซซี่เซต ถูกนำเสนอในรูปแบบของค่าขอบเขตที่คลุมเครือ แนวความคิดหลักคือการกำหนดฟังก์ชันความเป็นสมาชิกให้แก่สมาชิกภายในเซต ฟังก์ชันนี้จะมีค่าอยู่ระหว่าง 0 ถึง 1 $[0,1]$ โดยที่ค่า 0 หมายถึง ไม่มีความเป็นสมาชิกเลย ค่า 1 หมายถึงความเป็นสมาชิกโดยสมบูรณ์ และค่าที่อยู่ระหว่าง 0 ถึง 1 หมายถึง ความเป็นสมาชิกแค่บางส่วน ดังนั้นความความเป็นสมาชิกของ ฟัซซี่เซตจะมีความต่อเนื่อง



รูปที่ 3-1 แสดงความแตกต่างระหว่าง Crisp set และ Fuzzy set

จากรูปที่ 3.1 จะเห็นว่า Crisp set จะประกอบไปด้วยส่วนที่เป็นสีขาวและสีดำเท่านั้น หมายถึง ค่าความเป็นสมาชิกจะมีค่าเป็น 0 หรือ 1 เท่านั้น $\{0,1\}$ ส่วน Fuzzy set จะประกอบไปด้วย 3 ด้วยด้วยกันคือส่วนสีขาว สีดำ และ สีเทา ซึ่งหมายถึง ค่าความเป็นสมาชิกใน Fuzzy set นี้ จะประกอบไปด้วย ค่าความเป็นสมาชิก ที่อยู่ระหว่าง 0 ถึง 1 $[0,1]$ ซึ่งสามารถอธิบายได้ดังนี้

นิยาม ฟัซซี่สับเซต A ของเอกภพ U ถูกกำหนดโดยฟังก์ชันความเป็นสมาชิก $\mu_A : U \rightarrow [0,1]$ ซึ่งกำหนดสมาชิกแต่ละตัว u ของเอกภพ ให้มีค่า $\mu_A(u)$ มีค่าอยู่ในช่วง $[0,1]$ ซึ่งสามารถแสดงได้ในรูป 3-2 ซึ่งจะยกตัวอย่างในการอธิบายได้ เช่นกำหนดให้ระยะทาง 20 ก.ม. ให้ถือว่าเป็นระยะทางที่ถึงว่าไกล ดังนั้นระยะทางที่มากกว่า 20 ก.ม.จะมีค่าความเป็นสมาชิกกับคำว่าไกลเป็น 1 และ ค่าที่น้อยกว่า 13 ก.ม. ให้ถือว่าเป็นระยะทางที่ใกล้ อยู่ ดังนั้นค่าที่อยู่ระหว่าง 13.001 ก.ม. ถึง 14.9999 จะมีค่าความเป็นสมาชิกกับคำว่าไกลเป็นเท่าไร ทฤษฎี ฟัซซี่ จะมาใช้ในการอธิบายข้อมูลประเภทนี้



รูปที่ 3-2 กราฟแสดงความความเป็นสมาชิก

เช่นเดียวกับ เซต ทั่ว ๆ ไปที่จำเป็นต้องมีตัวดำเนินการในการทำงานซึ่งประกอบไปด้วย คอมพรีเมนต์ , ยูเนียน และ อินเตอร์เซ็ก ฟัชชี เซต ก็เช่นเดียวกันที่จำเป็นต้องมีตัวดำเนินการในการประมวลข้อมูลแต่ มีข้อแตกต่างกันในบางส่วนซึ่งสามารถอธิบายได้ดังนี้

ตัวดำเนินการหลัก ๆ 3 ประเภทของ ฟัชชีเซต

1. คอมพรีเมนต์ของฟัชชีเซต
2. ยูเนียนของฟัชชีเซต
3. อินเตอร์เซ็กฟัชชีเซต

นิยาม ให้ U คือเอกภพ A และ B เป็นฟัชชีสับเซต ของ เอกภพ U

$$\mu_{\bar{A}}(u) = 1 - \mu_A(u)$$

$$\mu_{A \cup B}(u) = \max(\mu_A(u), \mu_B(u))$$

$$\mu_{A \cap B}(u) = \min(\mu_A(u), \mu_B(u))$$

ซึ่งนิยามนี้สามารถเปลี่ยนแปลงได้ ซึ่งเกิดจากขั้นตอนการวัดประสิทธิภาพในการประมวลผล โดยนัก ฟัชชีแต่ละคนอาจให้นิยามของ ตัวดำเนินการที่แตกต่างกันไป ขึ้นอยู่กับว่านำเอาหลักการของ ฟัชชีไปใช้อธิบายเรื่องใด โดยนิยามที่ยกเป็นตัวอย่างนี้เป็น นิยามของการทำ ยูเนียนของฟัชชีเซต และ อินเตอร์เซ็กของฟัชชีที่อยู่ในรูปแบบที่ง่ายที่สุด โดยนิยามนี้อาจใช้ได้ไม่ดีกับงานบางอย่าง ยกตัวอย่างเช่น นำเอาไปใช้งานในการทำ ระบบค้นคืนข้อมูล ซึ่งมีวิธีแก้ไขนิยามนี้ซึ่งจะอธิบายในหัวข้อ 5.1 ทฤษฎีฟัชชีที่นำมาใช้ในการค้นคืน

3.2 ทฤษฎีฟัชชีที่นำมาใช้ในการค้นคืน

การนำเอาทฤษฎีฟัชชีมาใช้ในการค้นคืนข้อมูล เราจะนำเอาทฤษฎีฟัชชีมาจับความสัมพันธ์ของ อินเด็กซ์เทอม และความสัมพันธ์ของเอกสารที่มีอินเด็กซ์เทอมร่วมกันมาอยู่ในรูปของ เมตริก โดยที่ความสัมพันธ์นี้จะเขียนในรูปแบบแถวและคอลัมน์ในลักษณะของบัญชีค่า โดยความสัมพันธ์ดังกล่าวคิดได้จากสูตรดังนี้

$$c_{i,j} = \frac{n_{i,j}}{n_i + n_j - n_{i,j}}$$

โดยจากสูตรสามารถอธิบายได้ดังนี้

- $c_{i,j}$ คือ ความสัมพันธ์คู่อินเด็กซ์เทอม กับ j
- $n_{i,j}$ คือ จำนวนเอกสารที่มีทั้ง อินเด็กซ์เทอม i และ j เป็นอินเด็กซ์เทอม
- n_i คือ จำนวนเอกสารที่มี อินเด็กซ์เทอม i เป็นอินเด็กซ์เทอม
- n_j คือ จำนวนเอกสารที่มี อินเด็กซ์เทอม j เป็นอินเด็กซ์เทอม

โดยเราสามารถยกตัวอย่างความสัมพันธ์ของอินเด็กซ์เทอมในรูปเมตริกได้ดังนี้

	Index term1	Index term2	Index term3	Index term4
Index term1	1	0.47	0.34	0
Index term2	0.47	1	0.03	0
Index term3	0.34	0.03	1	0
Index term4	0	0	0	1

ตาราง 3-1 ตารางความสัมพันธ์ของ index term

จากตาราง 3-1 จะอธิบายได้ดังนี้

- $c_{i,i}$ จะมีค่าเท่ากับ 1 เสมอเพราะ $n_{i,i} = n_i$
- $c_{1,2}$ มีค่า 0.47 แสดงให้เห็นถึงความสัมพันธ์ของ index term1 ที่มีต่อ index term2 ซึ่งความสัมพันธ์นี้แสดงให้เห็นว่า มีเอกสารหลายเอกสารที่มีทั้ง index term1 และ index term2 เป็น index term ในเอกสารฉบับนั้นเมื่อเทียบกับ เอกสารที่มี index term1 หรือ index term2 เป็น index term และ ค่า $c_{1,2}$ จะเท่ากับค่า $c_{2,1}$
- $c_{1,4}$ มีค่า 0 หมายถึงไม่มีเอกสารใดเลยที่มีทั้ง index term1 และ index term4 เป็น index term ที่อยู่ในเอกสารเดียวกัน ดังนั้นเราจะกล่าวได้ว่าความสัมพันธ์ของ index term1 และ index term4 ไม่มีความสัมพันธ์กันเลย

ตามหลักการความสัมพันธ์นี้ ถ้า query ที่ผู้ใช้ป้อนเข้ามาตรงกับ index term ที่มีเอกสารเป็นสมาชิก

$k_i \in \{d_1, d_6, d_{20}, \dots, d_n\}$ ค่าความเป็นสมาชิกของเอกสารแต่ละฉบับ ที่มี k_i เป็น index term จะมีค่า

เท่ากับ 1 และถ้าเรานำความสัมพันธ์ของ index term เช่นจากตาราง จะเป็นว่า index term1 มีความสัมพันธ์กับ index term 2 เท่ากับ 0.47 ดังนั้นเอกสารที่เป็นสมาชิกของ $k_2 \in \{d_6, d_8, d_{20}, \dots, d_n\}$ แต่ค่าความเป็นสมาชิกของเอกสารชุดนี้เมื่อใช้ index term1 เป็นหลักค่าของความเป็นสมาชิกจะไม่เท่ากับ 1 แต่จะเท่ากับ 0.47 ตามสูตรต่อไปนี้


$$\mu_{i,j} = 1 - \prod_{k_l \in d_j} (1 - c_{i,l})$$

จากสูตรนี้เราจะได้ว่า

ค่าความเป็นสมาชิกของเอกสาร d_j ที่มีต่อ index term k_i เมื่อค่า index term k_l มีความสัมพันธ์กับ index term k_i มาก ค่า $c_{i,j} \sim 1$ จะทำให้ค่า $\mu_{i,j}$ เข้าใกล้ค่า 1 ด้วย หมายถึงค่า index term k_i เป็นค่าฟัซซี่ index ที่ดีต่อเอกสาร d_j แต่ในทางตรงกันข้ามถ้า เมื่อค่า index term k_l มีความสัมพันธ์กับ index term k_i น้อย ค่า $c_{i,j} \sim 0$ จะทำให้ค่า $\mu_{i,j}$ เข้าใกล้ค่า 0 ด้วย หมายถึงค่า index term k_i เป็นค่าฟัซซี่ index ที่ไม่ดีต่อเอกสาร d_j

การทำ อินเตอร์เซ็ก

แต่ในการใช้งานจริงแล้วนั้น query ที่ผู้ใช้เข้ามาส่วนมากจะเป็นกลุ่มของคำดังนั้นจึงมีเทอมในการค้นหาหลายเทอมเช่นผู้ใช้ได้ query เข้ามาอย่างเช่น ‘who is the first president of U.S.A?’ ซึ่งกลุ่มก่อนของ query ชุดนี้เมื่อจัดให้อยู่ในเทอมจะได้ออกมา 3 เทอมคือคำว่า ‘first’ , ‘president’ , ‘u.s.a’



รูปที่ 3-3 รูปความสัมพันธ์ของ index term กับการค้นหาของผู้ใช้แบบ อินเตอร์เซ็ก

ดังที่แสดงในรูป 3-3 จะเห็นว่าในการค้นหาโดยใช้ทั้ง 3 เทอมนั้นเราต้องนำค่าความเป็นในแต่ละเทอมมา and กันดังนั้นเราจะได้ว่า

$$\mu_{first \cap president \cap u.s.a}(x) = \min(\mu_{first}(x), \mu_{president}(x), \mu_{u.s.a}(x)) \quad \forall x \in U$$


ซึ่งสูตรนี้ได้จากนิยามของ fuzzy แต่มีข้อเสียคือจะไม่มีคำตอบเนื่อง เพราะความเป็นสมาชิกจะขึ้นอยู่กับเทอมที่มีค่าความเป็นสมาชิกน้อยที่สุดเพียงเทอมเดียวเท่านั้น ดังนั้นจึงต้องคิดใหม่ให้แต่ละเทอมมีผลต่อความเป็นสมาชิกจึงได้สูตรใหม่นี้

$$\mu_{first \cap president \cap u.s.a}(x) = \mu_{first}(x) \cdot \mu_{president}(x) \cdot \mu_{u.s.a}(x) \quad \forall x \in U$$

ซึ่งสูตรนี้จะทำให้ผลลัพธ์มีความต่อเนื่องเพิ่มขึ้น

การทำ ยูเนียน

เช่นเดียวกันกับ ถ้าหากผู้ใช้ต้องการค้นหาเอกสารที่ประกอบด้วย “first” or “president” or “u.s.a” จะได้เทอมออกมา 3 เทอมดังนี้



รูปที่ 3-4 รูปความสัมพันธ์ของ index term กับการค้นหาของผู้ใช้แบบ หรือ

ดังที่แสดงในรูป 3-4 จะเห็นว่าในการค้นหาโดยใช้ทั้ง 3 เทอมนั้นเราต้องนำค่าความเป็นในแต่ละเทอมมา or กันดังนั้นเราจะได้ว่า


$$\mu_{first \cup president \cup u.s.a}(x) = \max(\mu_{first}(x), \mu_{president}(x), \mu_{u.s.a}(x)) \quad \forall x \in U$$

ซึ่งสูตรนี้ได้จากนิยามของ fuzzy แต่มีข้อเสียคือจะไม่มีค่าต่อเนื่อง เพราะความเป็นสมาชิกจะขึ้นอยู่กับเทอมที่มีค่าความเป็นสมาชิกมากที่สุดเพียงเทอมเดียวเท่านั้น ดังนั้นจึงต้องคิดใหม่ให้แต่ละเทอมมีผลต่อความเป็นสมาชิกจึงได้สูตรใหม่ดังนี้

$$\mu_{first \cup president \cup u.s.a}(x) = (1 - (1 - \mu_{first}(x)) \cdot (1 - \mu_{president}(x)) \cdot (1 - \mu_{u.s.a}(x))) \quad \forall x \in U$$

รูปแบบการทำคอมพรีเมนต์

หากผู้ใช้มีความต้องการค้นหาเอกสารที่ไม่มีคำว่า “first” เป็น index term จะได้ดังรูป 3-5



รูปที่ 3-5 รูปความสัมพันธ์ของ index term กับการค้นหาผู้ใช้แบบ not

สูตรในการคำนวณแบบ คอมพรีเมนต์คือ

$$\mu_{first}^{\neg}(x) = (1 - \mu_{first}(x)) \quad \forall x \in U$$

โดยจะนำสูตรต่าง ๆ ที่ได้อธิบายไว้ในบทนี้ไปใช้ในการสร้างระบบค้นคืนสารสนเทศแบบฟัซซี่ซึ่งได้อธิบายไว้ในบทที่ 7 ซึ่งจะอธิบายรายละเอียดของระบบ ในส่วนของการสร้างการค้นคืน