

บทที่ 8

ผลการทดลองและการวัดประสิทธิภาพ

8.1 ผลการทดลอง

ผลการทดลองของระบบการค้นคืนสารสนเทศแบบฟัซซี่ลอจิก นี้สามารถอธิบายได้โดยการยกตัวอย่างในการประกอบ เพื่อระบุสิ่งที่ผู้ใช้ระบบต้องการค้นหา โดยตัวอย่าง ซึ่งมีสิ่งแวดล้อมต่าง ๆ ดังนี้

1. คำที่ใช้ต้องการค้นหา คือ คำว่า {dog,cat}
2. เอกสารที่มี {dog,cat} เป็น index term และ มีความเป็นสมาชิกเท่ากับ 1 ได้แก่

$$d1 = \{dog,cat,bird,zebra,zoo\}$$

$$d2 = \{cat,kitty,fish\}$$

$$d3 = \{dog,puppy,house,robber\}$$

$$d4 = \{ant,sugar\}$$
3. ความสัมพันธ์ของ index term แต่ละตัวที่มีต่อ index เทอม “cat” , “dog”

$$cat = \{dog/0.33,bird/0.5,zebra/0.5,zoo/0.5,kitty/0.5,fish/0.5\}$$

$$dog = \{cat/0.33,bird/0.5,zebra/0.5,zoo/0.5,puppy/0.5,house/0.5,robber/0.5\}$$

เมื่อนำสิ่งแวดล้อมข้างบนมาคำนวณ โดยระบบค้นคืนสารสนเทศแบบฟัซซี่เป็นผู้คำนวณจะได้ค่าดังนี้

$$cat = \{d1/1,d2/1,d3/0.33,d4/0\}$$

$$dog = \{d1/1,d2/0.33,d3/1,d4/0\}$$

และเมื่อนำ index term 2 ตัวมาทำการอินเตอร์เซกกันจะได้ค่าดังนี้

$$\mu_{cat \cap dog} = \{d1/1,d2/0.33,d3/0.33,d4/0\}$$

และเมื่อนำ index term 2 ตัวมายูเนียนกันจะได้ค่าดังนี้

$$\mu_{cat \cup dog} = \{d1/1,d2/1,d3/1,d4/0\}$$

และเมื่อนำค่ามาทำคอมพรีเมนต์แล้วทำอินเตอร์เซกกันจะได้ค่าดังนี้

$$\mu_{\bar{cat} \cap \bar{dog}} = \{d1/0,d2/0,d3/0,d4/1\}$$

ขั้นตอนก็นำข้อมูลมาเรียงจากมากไปหาน้อย เช่น ในการทำแบบ อินเตอร์เซก จะได้ผลดังนี้

$$d1,d2,d3,d4$$

ให้นำหมายเลขเอกสารไปค้นหาเอกสารในฐานข้อมูลมาแสดงให้แก่ผู้ใช้จะได้ดังนี้

d1 เรื่อง “life in zoo”

d2 เรื่อง “cat ‘s food”

d3 เรื่อง “The advantage of dog”


ส่วนเอกสาร d4 จะไม่ถูกแสดงออกมาเพราะไม่มีความเป็นสมาชิกเลย หรือ มีค่าเป็น 0

8.2 การวัดประสิทธิภาพ

การวัดประสิทธิภาพสามารถวัดได้หลายรูปแบบด้วยกันแต่ ระบบค้นคืนที่ดีนั้นต้องมี ประสิทธิภาพ 2 สิ่งนี้ที่สำคัญคือ

1. ประสิทธิภาพทางด้วยความถูกต้องและตรงตามความต้องการของผู้ค้นหา
2. ประสิทธิภาพทางด้านความเร็วในการค้นหา

8.2.1 ประสิทธิภาพทางด้วยความถูกต้องและตรงตามความต้องการของผู้ค้นหา




รูป 8.1 แสดงคำจำกัดความ ของ precision และ recall

จะมีนิยามที่พูดถึงการวัดประสิทธิภาพด้านนี้ด้วยกัน 2 ค่าคือ

- ค่า Precision = $\frac{| \text{expect} \cap \text{result} |}{| \text{result} |}$
- ค่า Recall = $\frac{| \text{expect} \cap \text{result} |}{| \text{expect} |}$

และค่าในอุกมคติคือ Precision = Recall ซึ่งหมายถึง เอกสารทุก ๆ เอกสารที่เกิดจากการค้นคืนของระบบ เป็นสิ่งที่ผู้ใช้ต้องการ แต่ไม่มี เอกสารใดเลยที่ผู้ใช้ไม่ต้องการ ซึ่งในความเป็นจริงแล้วทำได้ยากมาก ๆ เพราะ ระบบนั้นต้องสามารถเรียนรู้ความต้องการของผู้ใช้ที่มีความแตกต่างกันออกไปได้และระบบจะต้องทำการเก็บข้อมูลการค้นของผู้ใช้แล้วนำค่าที่ได้ไปทำการเรียนรู้

ดังนั้นระบบที่ดีทั่ว ๆ ไปจะทำให้อยู่ในรูปแบบดังรูปนี้



รูป 8.2 รูปประสิทธิภาพของการวัดความถูกต้องและตรงกับความต้องการ

จากรูปจะหมายถึง ระบบจะต้องพยายามทำให้ผลที่ได้รับ(result) ที่ออกมาให้ตรงกับสิ่งที่คาดหวัง(expect) ได้ทั้งหมดหรือ เกือบทั้งหมด เพื่อเพิ่มค่าความแม่นยำของระบบ

8.2.2 ประสิทธิภาพทางด้านความเร็วในการค้นหา

ประสิทธิภาพอีกเรื่องหนึ่งของระบบค้นคืนสารสนเทศคือเรื่องความเร็ว โดยเราต้องคำนึงถึงว่าในระบบค้นคืนสารสนเทศจริง ๆ แล้วนั้นเราไม่ได้มี เอกสารเพียง 3-4 เอกสารแต่จำนวนเอกสารจะมีจำนวนมากอย่างน้อย ต้อง 10000 เอกสารขึ้นไปเรื่องความเร็วจะมีผลอย่างยิ่งต่อระบบสารสนเทศนั้นว่าดีหรือไม่ ซึ่งในการแก้ปัญหาด้านความเร็วมีวิธีแก้ไขได้ 3 แบบด้วยกัน

1. แก๊ทที่ Hard ware ต้องที่เพียงพอต่อการเข้าถึงข้อมูลของผู้ใช้และช่วยให้การประมวลผลทำได้อย่างรวดเร็ว เช่นในระบบการค้นคืนที่ใหญ่ ๆ ยกตัวอย่างเช่น Google และ Altavista ซึ่งเป็นระบบค้นคืนสารสนเทศที่มีประสิทธิภาพมากและเป็นที่รู้จักกันดี ในการทำงานของ Google นั้น จะใช้โครงสร้างการค้นหาเป็นแบบ เว็คเตอร์ และ ระบบในการแบ่งหน้าที่ช่วยในการประมวลผล จะใช้แบบ clustering ส่วน Altavista นั้นจะมีระบบการประมวลผลคือการมี หลาย ๆ หน่วยประมวลผล(CPU) แบ่งแยกงานในการช่วยการประมวลผล แต่ในระบบสารสนเทศแบบพีซีซึ่งนี้ไม่อาจเพิ่มความเร็วโดยการ ใช้ Hard wareช่วยได้มากนัก เพราะปัจจัยหลายๆ เรื่องดังนั้นเรื่องการปรับประสิทธิภาพต้องใช้การปรับค่าอื่น
2. การปรับประสิทธิภาพโดยการปรับโครงสร้างของโปรแกรม เป็นการปรับค่าประสิทธิภาพที่เราสามารถกระทำได้โดยการใช้ อัลกอริทึม ที่เหมาะสมและรวดเร็ว และจากการได้ปฏิบัติ การเขียนโปรแกรมจริงแล้วนั้นปัญหาที่ทำให้ระบบช้ามีได้หลายกรณี แต่กรณีให้เห็นเด่นชัดคือการเขียน โปรแกรมติดต่อฐานข้อมูล ดังนั้นควรเขียนโปรแกรมให้มีการติดต่อกับฐานข้อมูลให้น้อยที่สุดเท่าที่ทำได้ หรือ การทำค่าในฐานข้อมูลมาเก็บในตัวแปรแทนการต้องติดต่อฐานข้อมูลทุกครั้ง ก็จะช่วยให้ระบบทำงานเร็วขึ้นได้
3. การปรับประสิทธิภาพโดยใช้ DBMS ที่มีประสิทธิภาพ ในการใช้งานจริง ๆ แล้วเราอาจแบ่งฐานข้อมูลออกเป็น 2 ชุดคือ ชุดที่ไว้สำหรับการอ่านอย่างเดียว และ ชุดที่ต้องมีการแก้ไขบ่อย

ๆ ในการกระทำเช่นนี้ ชุดที่ไว้สำหรับการอ่านอย่างเดียวจะเป็นฐานข้อมูลที่ถูก query บ่อยครั้ง แต่รูปแบบการ query ส่วนใหญ่ จะเป็นรูปแบบการอ่าน ดังนั้นเราอาจ ทำการ denormalize เพื่อลดการ join กันของฐานข้อมูล เพื่อประสิทธิภาพด้านความเร็วในการค้นคืนมากขึ้น ส่วน ฐานข้อมูลที่มีการเปลี่ยนแปลงบ่อยๆ บรรณารักษ์หรือผู้ดูแลระบบจะเป็นผู้ใช้งาน ดังนั้นเมื่อมีการเปลี่ยนแปลงข้อมูลจะกระทำต่อฐานข้อมูลชุดนี้เท่านั้นไม่ไปยุ่งกับ ฐานข้อมูลที่ใช้โดย ผู้ใช้ เพราะการเปลี่ยนแปลงค่า จะต้องทำการ lock record row ที่ทำการเปลี่ยนแปลง และ ผลกระทบที่ ชัดชัด อย่างเช่น DB2 หรือ ORACLE สามารถตั้งเวลาของคำสั่งได้ ดังนั้นการนำเอาข้อมูลจาก ฐานข้อมูลที่ บรรณารักษ์ใช้ไป update ฐานข้อมูลของผู้ใช้ สามารถทำได้โดยง่าย ซึ่งในระบบค้นคืนสารสนเทศแบบพีซีซีนี้ ใช้ DB2 สามารถตั้งเวลาของคำสั่งได้ โดยจะให้ทำงานตามคำสั่งในเวลาที่เราคิดว่ามีผู้ใช้งานข้อมูลน้อย เช่นในเวลาหลังเที่ยงคืนก็เป็นได้