

แหล่งรวมสื่อและข้อมูลดิจิทัลบนเว็บ
DIGITAL COLLECTIONS ON THE WEB

นาย สุรพันธ์ อัสรัตน์
นาย อาทิตย์ สิริอารีย์

ปฏิญานี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต
ภาควิชาวิศวกรรมคอมพิวเตอร์
คณะวิศวกรรมศาสตร์
สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง
ปีการศึกษา 2545

แหล่งรวมสื่อและข้อมูลดิจิทัลบนเว็บ
DIGITAL COLLECTIONS ON THE WEB

โดย
นาย สุรพันธ์ อัสสรรัตน์
นาย อาทิตย์ สิริอารีย์

อาจารย์ที่ปรึกษา
ดร. วิศิษฐ์ หิรัญกิตติ

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต
ภาควิชาวิศวกรรมคอมพิวเตอร์
คณะวิศวกรรมศาสตร์
สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง
ปีการศึกษา 2545

ปริญญานิพนธ์ปีการศึกษา 2545

ภาควิชา วิศวกรรมคอมพิวเตอร์

คณะวิศวกรรมศาสตร์ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

เรื่อง แหล่งรวมสื่อและข้อมูลดิจิทัลบนเว็บ

DIGITAL COLLECTIONS ON THE WEB

ผู้จัดทำ

1. นาย สุรพันธ์ อัสสรรัตน์ รหัสประจำตัว 42010401
2. นาย อาทิตย์ สิริอารีย์ รหัสประจำตัว 42010441

อาจารย์ที่ปรึกษา

(ดร. วิศิษฐ์ หิรัญกิตติ)

แหล่งรวมสื่อและข้อมูลดิจิทัลบนเว็บ

นาย สุรพันธ์ อัสสรรัตน์ 42010401

นาย อาทิตย์ สิริอารีย์ 42010441

ดร. วิศิษฐ์ ทรัพย์กิตติ อาจารย์ที่ปรึกษา
ปีการศึกษา 2545

บทคัดย่อ

ในปัจจุบันอินเทอร์เน็ตเป็นที่นิยมและแพร่หลายอย่างมาก ผู้ใช้บริการอินเทอร์เน็ตสามารถค้นหาและได้รับข่าวสารข้อมูลต่าง ๆ มากมายจากอินเทอร์เน็ต อินเทอร์เน็ตจึงเป็นแหล่งรวบรวมข้อมูลและสื่อดิจิทัลขนาดใหญ่ที่สุดของโลก อย่างไรก็ตามข้อมูลและสื่อดิจิทัลต่างๆ ในอินเทอร์เน็ตที่มีอยู่มากมายยังคงอยู่กันอย่างกระจัดกระจาย

เพื่อแก้ไขปัญหาดังกล่าวโครงการนี้จึงได้พัฒนาเว็บไซต์เพื่อเป็นแหล่งรวบรวมข้อมูลและสื่อดิจิทัลทุกรูปแบบที่เป็นที่ต้องการของผู้ใช้บริการไว้ในแหล่งเดียวกัน เพื่อให้ผู้ใช้สามารถจัดเก็บ ค้นหา และคัดลอกสื่อและข้อมูลได้อย่างหลากหลายมากมายที่อยู่บนอินเทอร์เน็ต โดยเชื่อมผ่านทางเว็บเบราว์เซอร์

ระบบทั้งหมดเป็นเว็บแอปพลิเคชันที่พัฒนาโดยใช้จาวา เซิร์ฟเล็ท ที่ทำหน้าที่จัดการบริหารจัดการเก็บสื่อข้อมูลและสื่อดิจิทัลในรูปแบบของไฟล์ โดยที่ข้อมูลและสื่อดิจิทัลเหล่านี้จะได้รับการอธิบายความหมาย ซึ่งจัดเก็บไว้ในรูปแบบของเอกสารอิเล็กทรอนิกส์ ระบบมีการบริหารฐานข้อมูลด้วยดีบีทู โดยมี เอ็กซ์เอ็มแอล เอกซ์เทนเดอร์ช่วยในการจัดเก็บกลุ่มของเอกสารอิเล็กทรอนิกส์

Digital Collections on the web

Surapun Assaratt

Arthit Siriaree

Dr. Visit Hirankitti Adviser

ABSTRACT

. At present the Internet is very popular and widely used. People can find enormous information from the Internet. Undoubtedly the Internet is the largest source of information and digital contents in the world. However, the information is scattered and stored in different places on the Internet, this brings some difficulty for the user to find his/her intended information easily. It would be better if there is one place where useful information are organized and stored together.

The attempt in this thesis is to develop a web site which gathers all forms of digital information and contents, e.g. images, sound, videos, etc. in one place. The user can access to the site in order to store, copy, and search this information by themselves using a web browser.

The web site is developed as a web application using Java Servlet. The application allows the user to store and manage information and digital content in the form of files. Each content is described by an XML(Extensible Mark-up Language) document, in order to provide meta information about the content, e.g. information about the author, type and size of the content. These XML documents are stored and managed by DB2 using XML Extender so that we can search, store, copy, a digital contents form our web application.

กิตติกรรมประกาศ

ปริญญานิพนธ์ฉบับนี้สำเร็จได้ด้วยดี สืบเนื่องมาจากการได้รับความช่วยเหลือและความร่วมมือจากบุคคลต่างๆหลายฝ่าย บุคคลแรกที่มีส่วนอย่างมากในการทำให้ปริญญานิพนธ์ฉบับนี้สำเร็จได้ก็คือ ดร. วิศิษฐ์ หิรัญกิตติ ซึ่งเป็นอาจารย์ที่ปรึกษาปริญญานิพนธ์ของผู้เขียน อาจารย์ให้ความเอาใจใส่ คำแนะนำ และความช่วยเหลือเสมอมาตั้งแต่เริ่มต้นจนกระทั่งปริญญานิพนธ์สำเร็จได้ด้วยดี จึงต้องขอขอบพระคุณเป็นอย่างยิ่ง

บุคคลที่สองที่ต้องขอบคุณเป็นอย่างมากก็คือ พี่อู๋ที่ได้ให้คำแนะนำมาโดยตลอด และเพื่อนๆ ทุกคนที่คอยช่วยเหลือ ให้คำแนะนำ และให้กำลังใจ ช่วยแก้ไขปัญหาร่วมกันตลอดมา รวมทั้งต้องขอบคุณห้อง Intelligence Communication Lab (ICL) ที่เอื้อเฟื้อสถานที่ในการทำปริญญานิพนธ์นี้

สุดท้ายขอขอบพระคุณบุคคลสำคัญที่สุดที่ทำให้ข้าพเจ้ามีวันนี้ก็คือ บิดา มารดา อันเป็นที่เคารพรักยิ่ง ซึ่งได้เลี้ยงดูผู้เขียนมาเป็นอย่างดี พร้อมทั้งให้โอกาสในการศึกษาอย่างเต็มที่และยังให้กำลังใจเอาใจใส่เสมอมาในทุกด้านอันหาที่เปรียบมิได้ ข้าพเจ้าขอระลึกในพระคุณอันสุดประมาณและขอกราบขอบพระคุณมา ณ ที่นี้

สุรพันธ์ อัสสระรัตน์

อาทิตย์ สิริอารีย์

สารบัญ

บทคัดย่อภาษาไทย	I
บทคัดย่อภาษาอังกฤษ	II
กิตติกรรมประกาศ	III
สารบัญ	IV
สารบัญตาราง	VII
สารบัญรูปภาพ	VIII
บทที่ 1 บทนำ	1
1.1 ความสำคัญ และที่มา	1
1.2 วัตถุประสงค์ของงานวิจัย	2
1.3 ขอบเขตของงานวิจัย	2
1.4 วิธีการดำเนินงาน	2
บทที่ 2 เซิร์ฟเล็ต (Servlet)	3
2.1 จาวาเซิร์ฟเล็ต	3
2.2 ข้อแตกต่างของเซิร์ฟเล็ตเมื่อเทียบกับซีจีไอ (CGI)	3
2.3 การอ่านข้อมูลจากเว็บ	4
2.4 สร้างเซิร์ฟเล็ตอ่านข้อมูลจากฟอร์ม	6
2.5 การใช้งานคุกกีด้วยเซิร์ฟเล็ต	7
2.6 เจดีบีซี (JDBC) ช่องทางติดต่อฐานข้อมูลด้วยจาวา	9
บทที่ 3 เอ็กซ์เอ็มแอล และฐานข้อมูลที่สามารถทำงานกับเอ็กซ์เอ็มแอลได้	14
3.1 ภาษาเอ็กซ์เอ็มแอล	14
3.2 ลักษณะโครงสร้างของเอกสารเอ็กซ์เอ็มแอล	14
3.3 ดีทีดีข้อกำหนดโครงสร้างเอ็กซ์เอ็มแอล	17
3.3.1 ดีทีดี คืออะไร	17
3.3.2 ประโยชน์ของเอกสารดีทีดี	18
3.4 เอกสารเอ็กซ์เอ็มแอลที่ถูกต้อง	18
3.5 เอกสารเอ็กซ์เอ็มแอลดีและถูกต้อง	20
3.6 ประโยชน์ของเอ็กซ์เอ็มแอล	21
3.7 ฐานข้อมูลที่ทำงานร่วมกับเอ็กซ์เอ็มแอล	21
3.7.1 เหตุผลที่ใช้เอ็กซ์เอ็มแอลและ ดีบีทู	21
3.7.2 การทำงานร่วมกันของเอ็กซ์เอ็มแอลและ ดีบีทู	22
3.7.3 เอ็กซ์เอ็มแอลคอลัมน์	23

สารบัญ

3.7.4	ไซค์เทเบิล	24
3.7.5	ไฟล์ดีเอคิ	24
3.7.6	ขั้นตอนการทำให้ฐานข้อมูลสามารถทำงานกับเอ็กซ์เอ็มแอล	24
3.7.7	สร้างตารางเอ็กซ์เอ็มแอล	26
3.7.8	จัดเก็บไฟล์ดีทีดีลงฐานข้อมูล	26
3.7.9	ขั้นตอนการทำให้คอลัมน์สามารถทำงานกับเอ็กซ์เอ็มแอล	27
บทที่ 4	การสร้าง และการออกแบบ	29
4.1	บทนำ	29
4.2	เอกสารเอ็กซ์เอ็มแอล	30
4.2.1	วิเคราะห์และออกแบบโครงสร้างเอกสารเอ็กซ์เอ็มแอล	30
4.2.2	โครงสร้างดีทีดี	33
4.3	การจัดหมวดหมู่ในการจัดเก็บไฟล์ข้อมูล	34
4.4	การสร้างฐานข้อมูลด้วยดีบีทู	50
4.4.1	การสร้างตารางและจัดการกับเอกสารเอ็กซ์เอ็มแอลด้วยดีบีทู	50
4.4.2	ไฟล์ดีเอคิ	50
4.4.3	ตารางต่างๆบนฐานข้อมูล	53
4.4.4	การจัดเก็บเอกสารเอ็กซ์เอ็มแอลบนฐานข้อมูล	53
4.5	การทำงานของระบบ	54
4.5.1	การสมัครสมาชิก	54
4.5.2	การเข้าสู่ระบบ	54
4.5.3	การจัดเก็บสื่อและข้อมูลดิจิทัล	54
4.5.4	การเรียกดูสื่อและข้อมูลดิจิทัล	55
4.5.5	การแสดงผลสื่อและข้อมูลดิจิทัล	55
4.5.6	การดาวน์โหลดสื่อและข้อมูลดิจิทัล	56
4.5.7	การค้นหาสื่อและข้อมูลดิจิทัล	56
4.5.8	การลบข้อมูลสื่อและข้อมูลดิจิทัล	56
4.5.9	การลบหมวดหมู่ของสื่อและข้อมูลดิจิทัล	57
4.5.10	การสร้างหมวดหมู่ของสื่อและข้อมูลดิจิทัล	57
4.5.11	การออกจากระบบ	57
4.6	ระบบค้นหา	57
4.6.1	การแปลความหมายของคีย์เวิร์ด	58
4.6.2	การจัดอันดับของเอกสาร	59

สารบัญ

4.6.3 การคำนวณในการจัดลำดับในเอกสาร	61
บทที่ 5 ผลการทำงานของระบบ	64
5.1 หน้าจอหลักของเว็บไซต์	64
5.2 การสมัครสมาชิกใหม่	65
5.3 การจัดเก็บข้อมูลสื่อ และข้อมูลดิจิทัล	66
5.4 การเรียกดูไฟล์ข้อมูลบนเซิร์ฟเวอร์	71
5.5 การแสดงผลข้อมูล	72
บทที่ 6 บทสรุป และวิจารณ์	73
6.1 สรุปและวิจารณ์	73
6.2 ปัญหาที่เกิดขึ้น	73
6.3 แนวทางการพัฒนา	74
ภาคผนวก ก ไฟล์ข้อมูลที่สามารถแสดงผลทางหน้าเว็บ	75
ก.1 ไฟล์ที่เล่นได้บนควิกไทม์ 6	75
ก.2 ไฟล์ที่เล่นได้บนวินโดวส์มีเดียเพลย์เยอร์	77
ภาคผนวก ข เวกเตอร์โมเดลสำหรับหาความคล้ายคลึงกันของเอกสาร	78
ข.1 บทนำ	78
ข.2 สัญลักษณ์	78
ข.3 ทฤษฎีและการคำนวณ	78
บรรณานุกรม	81

สารบัญรูปภาพ

รูปที่ 3-1 เอกสารอิเล็กทรอนิกส์ที่มีการสร้างตารางไฮค์เทเบิล	24
รูปที่ 4-1 แสดงโครงสร้างทั้งหมดของโครงการ	29
รูปที่ 4-2 แสดงหมวดหมู่ Upload	34
รูปที่ 4-3 แสดงหมวดหมู่ Animation	35
รูปที่ 4.4 แสดงหมวดหมู่ Document	36
รูปที่ 4.5 แสดงหมวดหมู่ Game	37
รูปที่ 4-6 แสดงหมวดหมู่ Image	39
รูปที่ 4-7 แสดงหมวดหมู่ Music	41
รูปที่ 4-8 แสดงหมวดหมู่ News	43
รูปที่ 4-9 แสดงหมวดหมู่ Program	46
รูปที่ 4-10 แสดงหมวดหมู่ Sound	47
รูปที่ 4-11 แสดงหมวดหมู่ Video	48
รูปที่ 5-1 หน้าจากหลักของเว็บไซต์	64
รูปที่ 5-2 แสดงหน้าเว็บการสมัครสมาชิกใหม่	65
รูปที่ 5-3 แสดงหน้าเว็บการเลือกหมวดหมู่ในอันดับแรก	66
รูปที่ 5-4 แสดงหน้าเว็บการเลือกหมวดหมู่ในขั้นที่สอง	67
รูปที่ 5-5 แสดงหน้าเว็บการเลือกหมวดหมู่ในขั้นที่สอง(ต่อ)	68
รูปที่ 5-6 แสดงหน้าเว็บการเลือกหมวดหมู่ในขั้นที่สอง(ต่อ)	69
รูปที่ 5-7 แสดงฐานข้อมูลที่ทำกรจัดเก็บเอกสารอิเล็กทรอนิกส์ โดยเครื่องมือของดีบีทู(1)	69
รูปที่ 5-8 แสดงฐานข้อมูลที่ทำกรจัดเก็บเอกสารอิเล็กทรอนิกส์ โดยเครื่องมือของดีบีทู(2)	70
รูปที่ 5-9 แสดงการเรียกดูไฟล์ข้อมูลที่อยู่บนเซิร์ฟเวอร์โดยผู้ให้บริการทั่วไป	70
รูปที่ 5-10 แสดงการเรียกดูไฟล์ที่อยู่บนเซิร์ฟเวอร์โดยผู้ดูแลระบบ	71
รูปที่ 5-11 แสดงหน้าแสดงผลในการเล่นไฟล์ข้อมูลด้วยวินโดว์มีเดียเพลย์เซอร์	72

สารบัญตาราง

ตารางที่ 2-1 แสดงรายละเอียดที่เกี่ยวข้องกับการใช้งานคุกกี้	9
ตารางที่ 3-1 แสดงชนิดของข้อมูลในคอลัมน์ต่างในดีทีดีเรฟเฟอร์รี่	27
ตารางที่ 4-1 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่ Upload	35
ตารางที่ 4-2 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่ Animation	37
ตารางที่ 4-3 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่ Document	38
ตารางที่ 4-4 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่ Game	39
ตารางที่ 4-5 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่ Image	40
ตารางที่ 4-6 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่ Art	40
ตารางที่ 4-7 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่ People	40
ตารางที่ 4-8 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่ Places	41
ตารางที่ 4-9 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ Music	42
ตารางที่ 4-10 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ News	44
ตารางที่ 4-11 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ Entertainment	44
ตารางที่ 4-12 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ SCI-TECH	44
ตารางที่ 4-13 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ Sports	45
ตารางที่ 4-14 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ World	45
ตารางที่ 4-15 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ Program	46
ตารางที่ 4-16 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ Driver	47
ตารางที่ 4-17 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ Mobile	47
ตารางที่ 4-18 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ Sound	48
ตารางที่ 4-19 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ Video	49
ตารางที่ 4-20 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ Movie	49
ตารางที่ 4-21 แสดงการคำนวณค่าความคล้ายคลึงด้วยค่าน้ำหนัก	62
ตารางที่ 4-22 แสดงการคำนวณค่าความคล้ายคลึงด้วยค่า idf_i	63
ตาราง ก-1 ชนิดของไฟล์ที่ วินโดวส์ มีเดียเพลย์เยอร์เล่นได้	77

ภาคผนวก

ภาคผนวก ก

ไฟล์ข้อมูลที่สามารถแสดงผลทางหน้าเว็บ

ก.1 ไฟล์ที่เล่นได้บนควิกไทม์ 6

รูปแบบของไฟล์นำเข้า (Import file formats)

- 3DMF
- AIFF
- AU
- Audio CD Data(MACINTOSH)
- AVI
- BMP
- Cubic VR
- DLS
- DV
- FlashPix
- FLC
- GIF
- JPEG/JFIF
- Karaoke
- MacPaint
- Macromedia Flash5
- MIDI
- MPEG-1
- MP3
- M3U
- MPEG-2
- MPEG-4(MP4)
- Photoshop
- PICS
- PICT
- PLS
- PNG
- QuickTime 6 Image File

- QuickTime 6 Movie
- SF2
- SGI
- Sound
- TARGA
- Text
- TIFF
- TIFF Fax
- Virtual Reality(VR)
- Wave

รูปแบบส่งออก (Export formats)

- AIFF
- AU
- AVI
- BMP
- DV Stream
- FLC
- Image Sequence movie exporters
- JPEG/JFIF
- JPEG 2000
- MacPaint
- MIDI
- MPEG-4
- Photoshop
- PICT
- PNG
- QuickTime 6 Image
- QuickTime 6 Movie
- SGI
- System 7 Sound
- Targa
- Text

- TIFF
- WAV

ก.2 ไฟล์ที่สามารถเล่นบนวินโดวส์มีเดียเพลเยอร์

File type (format)	File name extension
CD audio	.cda
Intel Indeo video technology	.ivf
Audio Interchange File Format (AIFF)	.aif, .aifc, and .aiff
Windows Media audio and video files	.asf, .asx, .wax, .wm, .wma, .wmd, .wmv, .wvx, .wmp, and .wmx
Windows audio and video files	.avi and .wav
Windows Media Player skins	.wmz and .wms
Moving Picture Experts Group (MPEG)	.mpeg, .mpg, .m1v, .mp2, .mpa, .mpe, .mp2v*, and .mpv2
Musical Instrument Digital Interface (MIDI)	.mid, .midi, and .rmi
AU (UNIX)	.au and .snd
MP3	.mp3 and .m3u
DVD video	.vob

ตาราง ก-1 ชนิดของไฟล์ที่ วินโดวส์ มีเดีย เพลย์เยอร์ เล่นได้

ภาคผนวก ข

เวกเตอร์โมเดลสำหรับหาความคล้ายคลึงกันของเอกสาร

ข.1. บทนำ

เวกเตอร์โมเดลเป็นหนึ่งในโมเดลวิชาการอินฟอร์เมชัน รีทรีฟอล (Information Retrieval) ซึ่งเป็นโมเดลที่ช่วยในการกำหนดค่าน้ำหนัก (weight) ให้แก่อินเด็กซ์เทอม(index term)ต่างๆในเวกเตอร์หนึ่ง เพื่อที่จะนำค่าน้ำหนักนี้ไปคำนวณและเปรียบเทียบกับอีกเวกเตอร์หนึ่ง เพื่อพิจารณาว่ามีความคล้ายกันหรือตรงประเด็นมากแค่ไหน ซึ่งจะมีประโยชน์ในการพัฒนาการค้นหาข้อมูลในฐานข้อมูล และนำมาแสดงผล

ข.2. สัญลักษณ์

เพื่อให้ง่ายต่อการเข้าใจและเข้าใจตรงกัน กำหนด

D เป็นเซตของเอกสารในฐานข้อมูล

Q เป็นเซตของเทอมที่ผู้ใช้ query

$\vec{q}$ $\vec{q} = (w_{1,q}, w_{2,q}, \dots, w_{t,q})$ เป็นเวกเตอร์บอกค่าน้ำหนักของแต่ละเทอมของ query โดย t คือจำนวนทั้งหมดของเทอมใน query

$\vec{d}$ $\vec{d} = (w_{1,j}, w_{2,j}, \dots, w_{t,j})$

k_i เป็นอินเด็กซ์เทอมลำดับที่ i

d_j เป็นเอกสาร (Document) ลำดับที่ j

$w_{i,j}$ เป็นค่าน้ำหนักแสดงความสัมพันธ์ของคู่อินเด็กซ์เทอม k_i ในเอกสาร d_j

$q_{i,j}$ เป็นค่าน้ำหนักแสดงความสัมพันธ์ของคู่อินเด็กซ์เทอม k_i ใน q

ข.3. ทฤษฎีและการคำนวณ

จากค่าน้ำหนักของเทอมของ query q และค่าน้ำหนักของในแต่ละอินเด็กซ์เทอมและในแต่ละเอกสาร d_j มีจำนวน t เทอม สามารถที่จะแสดงความสัมพันธ์หาความคล้ายคลึงกัน(Similarity)มากที่สุด ระหว่าง $\vec{q}$ กับ $\vec{d}$ ได้ในรูปแบบของฟังก์ชันโคซายน์ ดังนี้

$$\begin{aligned} \text{sim}(d_j, q) &= \frac{\vec{d}_j \cdot \vec{q}}{|\vec{d}_j| \times |\vec{q}|} \\ &= \frac{\sum_{i=1}^t w_{i,j} \times w_{i,q}}{\sqrt{\sum_{i=1}^t w_{i,j}^2} \times \sqrt{\sum_{i=1}^t w_{i,q}^2}} \end{aligned}$$

โดยที่ $|\vec{d}_j|, |\vec{q}|$ เป็นขนาดของเวกเตอร์ของเอกสารและเซตของ query ของผู้ใช้ตามลำดับ โดยค่า $w_{i,j}$ และ $w_{i,q}$ มีค่ามากกว่า 0 และ $0 \leq \text{sim}(d_j, q) \leq 1$ เราสามารถจัดอันดับของเอกสารโดยใช้ค่าของความ

คล้ายคลึงของเอกสารได้ โดยค่าที่ใกล้เคียงกับ 1 มากที่สุด จะหมายความว่า ในเอกสารนั้นมีเทอมที่ตรงกับเทอมที่ผู้ใช้ query มากที่สุด ในทางตรงกันข้ามถ้าเอกสารใดให้ค่าความคล้ายคลึงกับเทอม query เท่ากับศูนย์ หรือเข้าใกล้ศูนย์ แสดงว่าเอกสารนั้นไม่มีความคล้ายคลึงเลย หรือมีน้อยตามลำดับ

จากความสัมพันธ์การหาค่าความคล้ายคลึงกัน ปัจจัยที่เกี่ยวข้องโดยตรงในความสัมพันธ์นั้นคือค่าน้ำหนักของในแต่ละเทอมในแต่ละเอกสาร ดังนั้นปัญหาต่อไปคือทำอย่างไรจึงจะสามารถกำหนดค่าน้ำหนักของแต่ละเทอมได้อย่างเหมาะสมและมีประสิทธิภาพ ในเวกเตอร์โมเดลเราสามารถหาค่าความถี่ของจำนวนครั้งที่เทอมนั้นๆปรากฏ เป็นแฟคเตอร์หลักในการกำหนดค่าน้ำหนักของเทอม อีกแฟคเตอร์หนึ่งเป็นค่า ไอดีเอฟ หรือ อินเวอร์ส ดีออคคัมเมนส์ ฟรีควเ็นซี (idf หรือ Inverse Document Frequency) ที่เป็ค่าที่บ่งบอกความสำคัญของเทอมนั้นเมื่อเปรียบเทียบกับค่าอื่นๆ โดยคำนวณจากจำนวนเอกสารที่มีเทอมปรากฏอยู่ ถ้าเทอมปรากฏอยู่ในเอกสารมากมายเทียบกับเอกสารทั้งหมดในฟังก์ชันลอการิทึมแล้ว ค่าไอดีเอฟจะให้ค่าออกมาน้อย และถ้าเทอมปรากฏอยู่ในเอกสารน้อยแล้ว ค่าไอดีเอฟจะให้ค่าออกมามาก ซึ่งแสดงว่าเทอมที่ปรากฏอยู่ในเอกสารจำนวนน้อยๆ จะให้ความสำคัญมากกว่าเทอมที่ปรากฏอยู่ในเอกสารจำนวนมาก ดังสูตร

$$idf_i = \log \frac{N}{n_i}$$

ที่ซึ่ง idf_i เท่ากับค่าไอดีเอฟของอินเด็กซ์เทอมที่ i ในทุกๆเอกสาร

และกำหนด $freq_{i,j}$ เป็นความถี่คือจำนวนครั้งที่ปรากฏของเทอมที่ i ในเอกสารที่ j และ

$\max_l freq_{l,j}$ คือค่าความถี่ของเทอมในเอกสารที่ j ที่มากที่สุด แล้วจะได้ค่าความถี่ $f_{i,j}$ (normalized frequency) ดังนี้

$$f_{i,j} = \frac{freq_{i,j}}{\max_l freq_{l,j}}$$

แล้วจะได้ค่าของน้ำหนักของเทอม ดังสูตร

$$w_{i,j} = f_{i,j} \times idf_i$$

นอกจากนี้จากทฤษฎีของซอลตันและบัคเคย์ (Salton and Buckley) ได้เสนอแนะ ความสัมพันธ์หาค่าน้ำหนักของเทอมความต้องการของผู้ใช้ $w_{i,q}$ ไว้ว่า

$$w_{i,q} = \left(0.5 + \frac{0.5 \text{freq}_{i,q}}{\max_l \text{freq}_{l,q}} \right) \times \log \frac{N}{n_i}$$

โดย $w_{i,q}$ คือค่าน้ำหนักของเทอมที่ i ในเซตของเทอมความต้องการของผู้ใช้ และ $\text{freq}_{i,q}$ คือค่าความถี่ที่วัดจากจำนวนครั้งที่เทอมปรากฏอยู่ในเซตของ query ของผู้ใช้ และ $\max_l \text{freq}_{l,q}$ คือค่าความถี่ของเทอมที่ปรากฏมากที่สุดภายในเซตของ query ของผู้ใช้

จากเวกเตอร์โมเดล ได้ข้อดีของโมเดลนี้คือ

- การหาค่าความสัมพันธ์จากค่าน้ำหนักของในแต่ละเทอม ซึ่งสามารถนำมาใช้และทำให้การเรียกหาข้อมูลมีประสิทธิภาพมากขึ้น
- การที่ตอบสนองต่อความต้องการของผู้ใช้ สามารถสร้างเงื่อนไขได้ เช่น การสร้างเงื่อนไขในการให้ค่าน้ำหนักของในแต่ละเทอมของเซตความต้องการของผู้ใช้ไม่เท่ากัน
- ค่าของความคล้ายคลึงกันสามารถนำไปใช้ในการจัดลำดับความสำคัญหรือความตรงประเด็นกับความต้องการของผู้ใช้ได้

บรรณานุกรม

- [1] Deitel & Deitel: *"JAVA HOW TO PROGRAM THIRD EDITION"*, PRENTICE HALL, 2002
- [2] Marty Hall: *"Core Servlets and Java Server Pages"*, Prentice Hall PTR, 2000
- [3] Ricardo Baeza-Yates & Berthier Ribeiro-Neto: *"Modern Information Retrieval"*, Addison-Wesley, 1999, pp 27-30
- [4] Steven Holzner: *"INSIDE XML"*, New Riders, 2001
- [5] *"XML Extender Administration and Programming version"*,
<http://www.ibm.com/xsoftware/data/db2/library>
- [6] ดร.วีระศักดิ์ ชิงฉาว: *"Fundamental of Java Programming Volume 1"*, บริษัท ซีเอ็ดดูเคชั่น จำกัด(มหาชน), 2543
- [7] ดร.วีระศักดิ์ ชิงฉาว: *"Fundamental of Java Programming Volume 2"*, บริษัท ซีเอ็ดดูเคชั่น จำกัด(มหาชน), 2543
- [8] ศุภชัย สมพานิช: *"เข้าใจและใช้งาน XML ฉบับโปรแกรมเมอร์"*, นนทบุรี, อินโฟเพรส, 2544