


บทที่ 4

โครงสร้างและการออกแบบ

4.1 บทนำ

การออกแบบและสร้างเว็บแอปพลิเคชันนี้มีแนวคิดเริ่มมาจากการที่อินเทอร์เน็ตมีข้อมูลและสื่อดิจิทัลปริมาณมากมายมหาศาลอยู่ตามแหล่งต่างๆ และมีผู้ใช้บริการอินเทอร์เน็ตจำนวนมากที่ต้องการไฟล์ข้อมูลเหล่านี้ แต่อย่างไรก็ตามข้อมูลเหล่านั้นก็กระจัดกระจายไปทั่วโลก ดังนั้นจุดประสงค์ของโครงการคือ ต้องการสร้างแหล่งรวบรวมข้อมูลและสื่อดิจิทัลต่างๆ ไว้ในที่เดียวกัน เพื่อให้ผู้ใช้สามารถจัดเก็บ ค้นหา และดาวน์โหลดข้อมูลได้อย่างหลากหลาย โดยผู้ใช้สามารถใช้บริการแหล่งรวมข้อมูลและสื่อดิจิทัลผ่านทางหน้าเว็บไซต์ จุดเด่นของเว็บเซิร์ฟเวอร์นี้คือ การที่มีผู้เข้าใช้บริการต่างๆ เข้ามาจัดเก็บไฟล์ผู้เข้าใช้บริการจึงเหมือนเป็นผู้ที่ช่วยกันรวบรวมไฟล์หลากหลายประเภทไว้บนเซิร์ฟเวอร์เองด้วย โดยเว็บแอปพลิเคชันถูกพัฒนาด้วยเทคโนโลยีจาวาเซิร์ฟเล็ตเป็นตัวกลางสื่อสารกับผู้ใช้ทางหน้าเว็บไซต์ในการจัดการกับไฟล์ เว็บเซิร์ฟเวอร์มีหน้าที่ให้บริการต่างๆ กับผู้ใช้ นอกจากนี้ได้นำเทคโนโลยีภาษาเอ็กซ์เอ็มแอลเข้ามาช่วยในการสร้างเอกสารที่ใช้ช่วยสื่อถึงความหมายของข้อมูลเพื่อให้ไฟล์ข้อมูลเหล่านั้นมีความหมายในตัวเอง เพิ่มความสะดวกในการทำระบบค้นหาอีกด้วย เซิร์ฟเวอร์จัดการบริหารฐานข้อมูลด้วยดีบีทูและดีบีทูเอ็กซ์เอ็มแอลเอ็กซ์เทนเดอร์ที่ช่วยจัดการกับเอกสารเอ็กซ์เอ็มแอลบนฐานข้อมูล



รูปที่ 4-1 แสดงโครงสร้างทั้งหมดของโครงการ

4.2 เอกสารเอ็กซ์เอ็มแอล

ในโครงการนี้เราใช้เอกสารเอ็กซ์เอ็มแอลมาช่วยในการเก็บค่าคอนเทนต์ต่างๆที่รับมาจากผู้ที่ทำการจัดเก็บไฟล์ข้อมูลบนเซิร์ฟเวอร์ผ่านทางเว็บไซต์ โดยเก็บค่าคอนเทนต์ที่สื่อถึงความหมายของไฟล์นั้นๆ โดยค่าคอนเทนต์ต่างๆผู้ที่ทำการจัดเก็บจะต้องสร้างและป้อนให้กับเซิร์ฟเวอร์เอง ค่าคอนเทนต์เหล่านี้จะถูกจัดเก็บไว้ในเอกสารเอ็กซ์เอ็มแอลบนฐานข้อมูล

4.2.1 วิเคราะห์และออกแบบโครงสร้างเอกสารเอ็กซ์เอ็มแอล

ในโครงการนำเอกสารเอ็กซ์เอ็มแอลมาใช้สำหรับเก็บค่าคอนเทนต์ต่างๆจากผู้ใช้ได้ทำการจัดเก็บไฟล์นั้นๆไว้เพื่อทำให้ตัวไฟล์เอกสารที่ทำการจัดเก็บในฐานข้อมูลให้มีความหมาย เมื่อไฟล์มีคำอธิบายที่มีความหมายแล้ว เราสามารถนำค่าต่างๆในคอนเทนต์ไปแสดงต่อผู้ใช้งานว่าไฟล์เอกสารนั้นๆคือไฟล์ประเภทไหน มีชื่อว่าจะอะไร อยู่ในหมวดหมู่อะไรได้

จุดประสงค์หลักอีกอันหนึ่งของการกำกับความหมายให้กับไฟล์ข้อมูลในรูปแบบของเอกสารเอ็กซ์เอ็มแอล ก็เพื่อให้สามารถค้นหาไฟล์ข้อมูลจากความหมายได้ ดังนั้นการกำกับความหมายจึงต้องคำนึงถึงจุดนี้ เมื่อต้องการจะค้นหาไฟล์ข้อมูลอะไรบางอย่างผู้ต้องการค้นหาจะนึกถึงคีย์เวิร์ดอะไรบ้างที่จะช่วยในการค้นหาเพื่อจะได้ไฟล์ข้อมูลตรงตามต้องการ เช่น ถ้าเป็นไฟล์เพลง สิ่งแรกที่นึกถึงคือชื่อเพลง อันดับต่อไปก็อาจเป็นชื่อนักร้องหรือผู้ประพันธ์เพลง จากความคิดนี้เราได้คีย์เวิร์ดสามตัว คือ ชื่อของเพลง ชื่อนักร้องหรือนักประพันธ์และสุดท้ายชนิดของไฟล์คือเป็นไฟล์ประเภทเสียง ดังนั้นหากจะสร้างเอกสารที่กำกับความหมายให้กับไฟล์ข้อมูลหนึ่งๆอย่างน้อยจะต้องมีทั้งสามคอนเทนต์นี้อยู่ คือ หัวเรื่องหรือชื่อที่เป็นที่รู้จักกันทั่วไป คำอธิบายอื่นๆนอกจากนั้นและประเภทของไฟล์ จากแนวความคิดนี้เราสามารถนำไปสร้างเอกสารเอ็กซ์เอ็มแอลที่มีแท็กอธิบายถึงคอนเทนต์ดังกล่าวได้

เอกสารเอ็กซ์เอ็มแอลในโครงการนี้ มีโครงสร้าง ดังนี้

<Multimedia>

<Title>...</Title>

<FileName>...</FileName>

<FileType>...</FileType>

<Category>...</Category>

<Size>...</Size>

<Date>...</Time>

<Description>...</Description>

<Author>...</Author>

<Email>...</Email>

</Multimedia>

จากโครงสร้างเอกสารเอ็กซ์เอ็มแอลด้านบน ค่าของคอนเท้นท์ในแต่ละแท็กมีความหมายและความสำคัญดังต่อไปนี้

<Multimedia>	เป็นรูปอิลลิเมนต์ของเอกสารที่จัดเก็บแท็กที่มีค่าคอนเท้นท์ต่างๆอยู่
<Title></Title>	ใช้เก็บค่าคอนเท้นท์ที่แสดงหัวข้อหรือชื่อที่เป็นที่รู้จักกันของเอกสาร เช่น ชื่อเพลง ชื่อ หนังสือ ชื่อภาพยนตร์ เป็นต้น เป็นคอนเท้นท์ที่สำคัญมากที่ใช้ในการค้นหา เพราะเป็นคอนเท้นท์ที่ระบุได้ตรงประเด็นมากที่สุด
<FileName></FileName>	ใช้เก็บค่าคอนเท้นท์ที่แสดงชื่อไฟล์ของเอกสาร ใช้ในการอ้างอิงถึงไฟล์ เช่น “Java Programming.pdf” “More than word.mp3” เป็นต้น
<FileType></FileType>	ใช้เก็บค่าคอนเท้นท์ที่แสดงชนิดของไฟล์ของเอกสารมีประโยชน์ในขั้นตอนใช้ ตรวจสอบว่าเป็นไฟล์ประเภทไหน เพื่อเลือกโปรแกรมที่จะใช้ในการแสดงผลได้อย่างถูกต้อง
<Category></Category>	ใช้เก็บค่าคอนเท้นท์ที่แสดงหมวดหมู่หรือประเภทของไฟล์ของเอกสาร นำไปใช้ในการจัดเก็บเอกสารให้เป็นหมวดหมู่ที่เหมาะสมเพื่อให้สะดวกในการค้นหายิ่งขึ้น
<Size></Size>	ใช้เก็บค่าคอนเท้นท์ที่แสดงขนาดของเอกสาร มีหน่วยเป็นไบต์ ใช้แสดงแก่ผู้ค้นหา เพื่อเป็นทางเลือกในการเลือกไฟล์ เช่น ในกรณีไฟล์ฟิดีโอพ มีหัวข้อเรื่องเหมือนกัน แต่ขนาดไฟล์ไม่เท่ากัน ผู้ค้นหาอาจต้องการไฟล์ที่มีรายละเอียดมากกว่าก็จะเลือกไฟล์ที่มีขนาดมากกว่า
<Date></Date>	ใช้เก็บค่าคอนเท้นท์ที่แสดงวันที่ทำการเก็บไฟล์เอกสารไว้บนฐานข้อมูลของเซิร์ฟเวอร์ ใช้ในการช่วยพิจารณาเช่นเดียวกับ Size
<Time></Time>	ใช้เก็บค่าคอนเท้นท์ที่แสดงเวลาที่ทำการเก็บไฟล์เอกสารไว้บนฐานข้อมูลของเซิร์ฟเวอร์ ใช้ในการช่วยพิจารณาเช่นเดียวกับ Size
<Description></Description>	ใช้เก็บค่าคอนเท้นท์ที่แสดงคำอธิบายอื่นๆที่รับมาจากผู้ทำการจัดเก็บไฟล์ของเอกสาร เป็นอีกคอนเท้นท์ที่มีความสำคัญมาก เพราะจะเก็บรายละเอียดต่างๆที่นอกเหนือไปจาก หัวเรื่อง
<Author></Author>	ใช้เก็บค่าคอนเท้นท์ที่แสดงยูสเซอร์เนมของผู้ทำการอัปโหลดไฟล์เอกสาร ช่วยเพิ่มความสะดวกในการค้นหา เช่น ต้องการไฟล์ที่ถูกจัดเก็บโดยยูสเซอร์คนนั้นๆ
<Email></Email>	ใช้เก็บค่าคอนเท้นท์ที่แสดงอีเมลแอดเดรสของผู้ทำการอัปโหลดไฟล์เอกสาร เช่นเดียวกับ Author

ตัวอย่างของไฟล์เอกสารเอ็กซ์เอ็มแอลที่ใช้ในโครงการนี้

```
<?xml version="1.0" encoding="UTF-8" ?>
<!DOCTYPE Multimedia SYSTEM "E:\Project\save\multimedia.dtd">
<Multimedia>
  <Title>More than word</Title>
  <FileName>More than word.mp3</FileName>
  <FileType>audio/mpeg</FileType>
  <Category>Music/Pop</Category>
  <Size>2846</Size>
  <Date>December 13, 2002</Date>
  <Time>2:14:05 AM GMT+07:00</Time>
  <Description>Extreme</Description>
  <Author>Por</Author>
  <Email>arthieg7@hotmail.com</Email>
</Multimedia>
```

จากตัวอย่างเอกสารเอ็กซ์เอ็มแอลนี้ เราสร้างเอกสารเอ็กซ์เอ็มแอลเพื่ออธิบายความหมายของไฟล์เพลงเอ็มพีสามไฟล์ ต่างๆ ดังตัวอย่าง เมื่อเราอ่านไฟล์เอกสารเอ็กซ์เอ็มแอลนี้จะได้ความหมายของไฟล์ที่ถูกจัดเก็บ ดังนี้

จากแท็ก **Title** จะจัดเก็บชื่อเรื่องของไฟล์เอกสารคือในกรณีนี้เป็นชื่อเพลงว่า “more than word”

จากแท็ก **FileName** มีชื่อไฟล์ว่า “more than word.mp3”

จากแท็ก **FileType** บ่งบอกไฟล์นี้เป็นไฟล์ประเภท “audio/mpeg”

จากแท็ก **Category** บ่งบอกหมวดหมู่ที่ไฟล์ถูกจัดเก็บไว้ “Music/Pop”

จากแท็ก **Size** บ่งบอกว่าขนาดของไฟล์ มีขนาด “2486” ไบต์

จากแท็ก **Date** บ่งบอกว่าไฟล์นี้ถูกจัดเก็บไว้บนเซิร์ฟเวอร์ ณ วันที่ 13 ธันวาคม ปี 2002

จากแท็ก **Time** บ่งบอกว่าไฟล์นี้ถูกจัดเก็บไว้บนเซิร์ฟเวอร์ ณ เวลา 2:14:05 am เทียบกับเวลา GMT+ 7:00

จากแท็ก **Description** บ่งบอกคำอธิบายอื่นที่เกี่ยวข้องกับไฟล์นี้ ซึ่ง “Extreme” เป็นชื่อของกลุ่มศิลปินที่ร้องและเป็นเจ้าของเพลงนี้

จากแท็ก **Author** บ่งบอกว่าผู้ที่ทำการจัดเก็บไฟล์นี้ มีชื่อยูสเซอร์เนมว่า “Por”

จากแท็ก **Email** บ่งบอกว่า “arthieg7@hotmail” เป็นอีเมลล์แอดเดรสของยูสเซอร์เนม “Por”

การจัดเก็บค่าคอนเทนต่างๆ มีที่มา ดังนี้

จากแท็ก **Title** ได้ค่าคอนเทนที่มาจากอ่านค่าพารามิเตอร์ที่ป้อนเข้ามาของผู้ใช้บริการ

จากแท็ก **FileName** ได้ค่าคอนเทนที่มาจากอ่านค่าพารามิเตอร์ที่ป้อนเข้ามาของผู้ใช้บริการ

จากแท็ก **FileType** ได้ค่าคอนเทนที่มาจากแปลงค่าพารามิเตอร์ที่ป้อนเข้ามาของผู้ใช้บริการ

จากแท็ก **Category** ได้ค่าคอนเทนที่มาจากอ่านค่าพารามิเตอร์ที่ผู้ใช้บริการเลือกไว้

จากแท็ก **Size** ได้ค่าคอนเทนที่มาจากอ่านขนาดจากไฟล์ที่ทำการจัดเก็บ

จากแท็ก **Date** ได้ค่าคอนเทนที่มาจากวันที่ทำการจัดเก็บไฟล์

จากแท็ก **Time** ได้ค่าคอนเทนที่มาจาก เวลาที่ทำการจัดเก็บไฟล์

จากแท็ก **UserName** ได้ค่าคอนเทนที่มาจากชื่อของยูสเซอร์เนมที่ใช้ในการล็อกอินอยู่และทำการจัดเก็บไฟล์

จากแท็ก **Email** ได้ค่าคอนเทนที่มาจากอ่านค่าพารามิเตอร์ที่ป้อนเข้ามาของผู้ใช้บริการ โดยถ้าไม่มีการเปลี่ยนแปลงใช้ค่าอีเมลแอดเดรสของผู้ที่ทำการล็อกอินอยู่ และทำการจัดเก็บไฟล์

4.2.2 โครงสร้างดีทีดี

ดีทีดี คือ ไฟล์เอกสารที่ใช้กำหนดโครงสร้างของเอกสารเอ็กซ์เอ็มแอลให้อยู่ในรูปแบบที่ถูกต้อง และตรงกันทุกๆเอกสารเอ็กซ์เอ็มแอลในฐานะข้อมูล

ไฟล์ดีทีดีที่ใช้ในโครงงานมีรูปแบบดังนี้

```
<?xml version="1.0" encoding="UTF-8" ?>
<!ELEMENT Multimedia ( Title, FileName, FileType, Category, Size, Date, Time, Description, Author,
Email ) >
<!ELEMENT Author ( #PCDATA ) >
<!ELEMENT Category ( #PCDATA ) >
<!ELEMENT Date ( #PCDATA ) >
<!ELEMENT Description ( #PCDATA ) >
<!ELEMENT Email ( #PCDATA ) >
<!ELEMENT FileName ( #PCDATA ) >
<!ELEMENT FileType ( #PCDATA ) >
<!ELEMENT Size ( #PCDATA ) >
<!ELEMENT Title ( #PCDATA ) >
<!ELEMENT Time ( #PCDATA ) >
```

จากไฟล์ที่ดี จะแสดงโครงสร้างของเอกสารเอกซ์เอ็มแอลไว้ดังนี้

เวอร์ชันและการเข้ารหัสที่ใช้ในเอกสารเอกซ์เอ็มแอล จะต้องตรงกับ เวอร์ชัน 1.0 กับ “UTF-8” ตามลำดับ อิลิเมนต์รากมีเพียงตัวเดียว คือ Multimedia โดยมี อิลิเมนต์ลูกต่างๆ คือ


Title,FileName,FileType,Category,Size,Date,Time,Description,Author และ Email ตามลำดับ

โดยค่าคอนเท้นท์ในแต่ละอิลิเมนต์ลูกทั้งหมดจะต้องเป็นแบบ PCDATA(Parse Character Data) ซึ่งเป็นข้อความที่จะถูกแปลภาษาก่อนแล้วค่อยแสดงข้อความออกมาได้

4.3 การจัดหมวดหมู่ในการจัดเก็บไฟล์ข้อมูล

เนื่องจากเว็บไซต์เวอร์เป็นแหล่งรวบรวมไฟล์ข้อมูลจำนวนมาก จำเป็นจะต้องจัดเก็บไฟล์เป็นหมวดหมู่เพื่ออำนวยความสะดวกต่างๆเกี่ยวกับไฟล์ โดยเฉพาะในเรื่องการค้นหา ถ้าไม่จัดที่อยู่ของไฟล์ไว้ให้เป็นระเบียบจะใช้เวลามากกว่าในการหาไฟล์หนึ่งๆ

หมวดหมู่ที่ใช้ในการจัดเก็บไฟล์ต่างๆมีดังนี้




รูปที่ 4-2 แสดงหมวดหมู่ใน Upload

Upload เป็นหมวดมารากของทุกหมวดหมู่ ดังนั้นไฟล์ข้อมูลและสื่อดิจิทัลที่อยู่ในระบบทั้งหมดจะอยู่ในหมวดหมู่ Upload เป็น โดยในหมวดหมู่นี้ถูกแบ่งเป็นหมวดหมู่ย่อยออกไป ในแต่ละหมวดหมู่ย่อยบางหมวดหมู่มียังมีหมวดหมู่แบ่งแยกลงไปอีก บางหมวดหมู่ย่อยก็ไม่มี

รายละเอียดหมวดหมู่ย่อยใน Upload

หมวดหมู่	คุณลักษณะ
Animation	ภาพเคลื่อนไหว
Document	เอกสารต่างๆ เช่น เอกสารเวิร์ด เอกสารพีดีเอฟ
Game	เกมต่างๆ
Image	รูปภาพ
Music	เพลงต่างๆ เช่น ไฟล์เอ็มพีสาม
News	ข่าว
Program	โปรแกรม
Sound	เสียงต่างๆ เช่น เสียงเตือน เสียงนกกร้อง
Video	วิดีโอต่างๆ เช่น ภาพยนตร์

ตารางที่ 4-1 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่ Upload




รูปที่ 4-3 แสดงหมวดหมู่ Animation

รายละเอียดหมวดหมู่ย่อยใน Animation

หมวดหมู่	คุณลักษณะ
Alphabet	ตัวอักษร ตัวเลขต่างๆ
Animals	จำพวกสัตว์
Clothing	เสื้อผ้า เครื่องนุ่งห่ม
Computer_TECH	เทคโนโลยีทางคอมพิวเตอร์
Creature_Cartoons	คน สัตว์ สิ่งมีชีวิต และการ์ตูน
Entertainment	สื่อบันเทิง
Food_Drink	อาหาร เครื่องดื่ม
Geography_History	ภูมิศาสตร์ ประวัติศาสตร์
Job_People	งาน คน
Nature	ธรรมชาติ
Science_Body	วิทยาศาสตร์เกี่ยวกับร่างกายสิ่งมีชีวิต
Sports	กีฬา

Transportation	การขนส่งต่างๆ
WebDesign_Element	ที่ใช้ตกแต่งหน้าเว็บเพจ

ตารางที่ 4-2 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่ Animation




รูปที่ 4-4 แสดงหมวดหมู่ Document

รายละเอียดหมวดหมู่ย่อยใน Document

หมวดหมู่	คุณลักษณะ
AddressBook	สมุดบันทึกที่อยู่
Article	บทความทั่วไป
E-Book	หนังสือไฟฟ้า
E-Mail	จดหมายไฟฟ้า
Magazine	นิตยสาร
Message	ข้อความ
NewsLetter	จดหมาย
Note	ข้อความสั้นๆ
Paper	บทความทางวิชาการ
Report	รายงาน

ตารางที่ 4-3 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่ Document




รูปที่ 4-5 แสดงหมวดหมู่ Game

รายละเอียดหมวดหมู่ย่อยใน Game

หมวดหมู่	คุณลักษณะ
Action	เกมแนวต่อสู้
AdventureRPG	เกมผจญภัย โดยสวมบทบาทเป็นตัวละคร
Arcade	เกมตะลุยไปตามฉาก
Card	เกมไพ่
Puzzle	เกมตัวต่อ
Scenarios	เกมที่ดำเนินเป็นเรื่องราว
Simulation	เกมจำลองกับเหตุการณ์จริง
Sports	กีฬา
Strategy	เกมวางแผน

ตารางที่ 4-4 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่ Game



รูปที่ 4-6 แสดงหมวดหมู่ Image

รายละเอียดหมวดหมู่ย่อยใน Image

หมวดหมู่	คุณลักษณะ
Animal	รูปสัตว์ต่างๆ
Art	รูปศิลปะ
Clothing	เสื้อผ้า
Flash	ไฟล์ประเภทแฟลช
Food	อาหาร
Furniture	เครื่องตกแต่งเรือน
HandyCraft	ผลิตภัณฑ์ทางหัตถกรรม

Map	แผนที่
Nature	ธรรมชาติ
People	รูปคนทั่วไป
Places	สถานที่ต่างๆ
Stamp	แสตมป์
Technology	เทคโนโลยี
Vehicle	ยานพาหนะ

ตารางที่ 4-5 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่Image

รายละเอียดหมวดหมู่ย่อยใน Art

หมวดหมู่	คุณลักษณะ
Drawing	ภาพวาด
Modeled	รูปปั้น
Painting	ภาพวาดพู่กัน

ตารางที่ 4-6 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่Art

รายละเอียดหมวดหมู่ย่อยใน People


หมวดหมู่	คุณลักษณะ
Family	ครอบครัว
Friends	เพื่อนๆ
Group	หมู่คณะ
Single	ภาพเดี่ยว
SportsMan	นักกีฬา
SuperStar	ดารา

ตารางที่ 4-7 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่People

แสดงหมวดหมู่ Places

หมวดหมู่	คุณลักษณะ
History	สถานที่ทางประวัติศาสตร์
Hotel	โรงแรม
Mountain	ภูเขา
Resort	บ้านพักตากอากาศ
River	แม่น้ำ
Sea	ทะเล
Waterfall	น้ำตก

ตารางที่ 4-8 แสดงคุณลักษณะของหมวดหมู่ย่อยในหมวดหมู่ Places




รูปที่ 4-7 แสดงหมวดหมู่ Music

รายละเอียดหมวดหมู่ย่อยใน Music

หมวดหมู่	คุณลักษณะ
Alternative	แนวอัลเทอร์เนทีฟ
Blues	แนวบลู
Classical	เพลงคลาสสิก
Dance	เพลงเต้น
Electronica	แนวอิเล็กทรอนิกส์
HipHop	ฮิปฮอป
Jazz	แจ๊ซ
Melody	ทำนองเพลง
Metal	แนวเมทัล
Opera	โอเปร่า
Pop	ป๊อป
R&B	อาร์แอนด์บี
Reggae	เรกเก้
Rock	ร็อก
Soul	แนวโซล
Techno	เทคโน
Vocal	เพลงประสานเสียง

ตารางที่ 4-9 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ Music



รูปที่ 4-8 แสดงหมวดหมู่ News

รายละเอียดหมวดหมู่ย่อยใน News

หมวดหมู่	คุณลักษณะ
Agriculture	ข่าวเกษตรกรรม
Business	ข่าวธุรกิจ
Culture	ข่าววัฒนธรรม
Economy	ข่าวเศรษฐศาสตร์
Education	ข่าวการศึกษา
Entertainment	ข่าวบันเทิง
Food	ข่าวเกี่ยวกับการโภชนา

Health	ข่าวสุขภาพ
Law	ข่าวเกี่ยวกับกฎหมาย
Politics	ข่าวการเมือง
SCI_TECH	ข่าวเทคโนโลยีทางวิทยาศาสตร์
SocialEvent	ข่าวสังคม
Sport	ข่าวกีฬา
Travel	ข่าวการท่องเที่ยว
Weather	ข่าวพยากรณ์อากาศ
World	ข่าวรอบโลก

ตารางที่ 4-10 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่News

รายละเอียดหมวดหมู่ย่อยใน **Entertainment**

หมวดหมู่	คุณลักษณะ
Movie	ข่าวเกี่ยวกับภาพยนตร์
Music	ข่าวทางดนตรี
TV	ข่าวโทรทัศน์

ตารางที่ 4-11 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่Entertainment

รายละเอียดหมวดหมู่ย่อยใน **SCI-TECH**

หมวดหมู่	คุณลักษณะ
SPACE	ข่าวเกี่ยวกับอวกาศ

ตารางที่ 4-12 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่SCI-TECH

รายละเอียดหมวดหมู่ย่อยใน Sports


หมวดหมู่	คุณลักษณะ
Basketball	ข่าวบาสเก็ตบอล
Cars	ข่าวการแข่งขันรถ
Football	ข่าวฟุตบอล
Tennis	ข่าวเทนนิส

ตารางที่ 4-13 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ Sports

รายละเอียดหมวดหมู่ย่อยใน World

หมวดหมู่	คุณลักษณะ
Africa	ข่าวในทวีปแอฟริกา
America	ข่าวในทวีปอเมริกา
Asia	ข่าวในทวีปเอเชีย
Australia	ข่าวในทวีปออสเตรเลีย
Europe	ข่าวในทวีปยุโรป
MiddleEast	ข่าวในแถบตะวันออกกลาง
USA	ข่าวในทวีปอเมริกา

ตารางที่ 4-14 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ World



รูปที่ 4-9 แสดงหมวดหมู่Program

รายละเอียดหมวดหมู่ย่อยใน Program

หมวดหมู่	คุณลักษณะ
Driver	โปรแกรมไดรฟ์เวอร์
Internet	เกี่ยวกับอินเทอร์เน็ต
Mobile	เกี่ยวกับมือถือ
Multimedia	เกี่ยวกับมัลติมีเดีย
Patch	แพทช์ที่ใช้กับโปรแกรมต่างๆ
Palm	โปรแกรมบนปาล์ม
PocketPc	โปรแกรมบนคอมพิวเตอร์พกพา
ScreenSaver	สกรีนเซฟเวอร์
Script	สคริปต์ต่างๆ
Utility	ยูทิลิตี้ต่างๆ

ตารางที่ 4-15 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่Program

รายละเอียดหมวดหมู่ย่อยใน Driver


หมวดหมู่	คุณลักษณะ
BIOS	ใช้งานกับไบออส
CD_ROM	สำหรับซีดีรอมไดรฟ์
Display	สำหรับการ์ดแสดงผล
DVD	สำหรับดีวีดีไดรฟ์
Network	สำหรับอุปกรณ์ทางเน็ตเวิร์ก
Printer	สำหรับเครื่องพิมพ์
Scanner	สำหรับเครื่องสแกนเนอร์
Sound	สำหรับการ์ดเสียง

ตารางที่ 4-16 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่Driver

รายละเอียดหมวดหมู่ย่อยใน Mobile

หมวดหมู่	คุณลักษณะ
Application	แอปพลิเคชันต่างๆที่ทำงานบนโมบายได้
Game	เกมบนมือถือ
Utility	ยูทิลิตี้บนมือถือ

ตารางที่ 4-17 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่Mobile




รูปที่ 4-10 แสดงหมวดหมู่Sound

รายละเอียดหมวดหมู่ย่อยใน Sound

หมวดหมู่	คุณลักษณะ
Animals	เสียงสัตว์
Effect	เสียงประกอบต่างๆ
Instrument	เสียงเครื่องมือต่างๆ
Machine	เสียงเครื่องจักร
Nature	เสียงธรรมชาติ
People	เสียงคน

ตารางที่ 4-18 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่ Sound



รูปที่ 4-11 แสดงหมวดหมู่ Video

รายละเอียดหมวดหมู่ย่อยใน Video

หมวดหมู่	คุณลักษณะ
Advertisement	ภาพยนตร์โฆษณา
Clip	ภาพเคลื่อนไหวสั้นๆ
FasionShow	การแสดงแฟชั่น
Feature	สารคดี
Movie	ภาพยนตร์
MusicVideo	ภาพยนตร์ประกอบเพลง

ตารางที่ 4-19 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่Video

รายละเอียดหมวดหมู่ย่อยใน Movie

หมวดหมู่	คุณลักษณะ
Action	แนวมูวี่ ดิ้นเต้น
Adventure	แนวผจญภัย
Animation	ภาพยนตร์การ์ตูน
Comedy	แนวตลก
Crime	แนวฆาตกรรม
Drama	แนวชีวิต
Family	แนวชีวิตครอบครัว สนุกสนาน
Fantasy	แนวนิยาย มหัศจรรย์
AnimalLife	ชีวิตสัตว์
Education	เพื่อการศึกษา
History	ประวัติศาสตร์
Horror	น่ากลัว สยองขวัญ
Mystery	ลึกลับ ปริศนา
Romance	หนังรัก
SCI-FI	นิยายวิทยาศาสตร์
Thriller	ดิ้นเต้น
War	สงคราม

ตารางที่ 4-20 แสดงคุณลักษณะหมวดหมู่ย่อยในหมวดหมู่Movie

4.4 การสร้างฐานข้อมูลด้วยดีบีทู

ทำการติดตั้งดีบีทู ยูทีบี เวอร์ชัน 8.1

4.4.1 การสร้างตารางและจัดการกับเอกสารอิเล็กทรอนิกส์ด้วยดีบีทู

เริ่มจากเรียกหน้าต่างคำสั่งขึ้นมาใช้งาน ทำการสร้างฐานข้อมูลชื่อ DC โดยใช้คำสั่งเอสคิวแอล

db2 "create database DC"

ติดต่อกับฐานข้อมูลด้วยคำสั่ง

db2 "connect to DC"

ใส่คำสั่งทำให้ฐานข้อมูลสามารถจัดเก็บเอกสารอิเล็กทรอนิกส์แอลได้ ด้วยคำสั่ง

db2 "bind C:\Progra~1\IBM\SQLLIB\bnd\@dxxbind.lst"

dxxadm enable_db DC

ต่อไปทำการใส่ เอกสารดีทีดีเพื่อใช้เป็นแม่แบบให้กับเอกสารอิเล็กทรอนิกส์แอลลงในตาราง DTD_REF

ซึ่งดีบีทูจะสร้างให้อัตโนมัติเมื่อมีคำสั่งให้ฐานข้อมูลสามารถจัดการเอกสารอิเล็กทรอนิกส์แอล

db2 "insert into db2xml.dtd_ref values('getstart.dtd',

db2xml.XMLClobFromFile('C:\Progra~1\IBM\SQLLIB\samples\db2xml\dtd\multimedia
.dtd'), 0, 'admin', 'admin', 'admin')"

ทำการสร้างตารางเพื่อจัดเก็บเอกสารอิเล็กทรอนิกส์แอลด้วยคำสั่ง

db2 "create table MM_TAB(XML DB2XMLFILE)"

ก่อนที่จะใส่คำสั่งให้คอลัมน์ของเอกสารอิเล็กทรอนิกส์แอลสามารถทำงานได้ ต้องสร้างเอกสารดีเอทีให้เรียบร้อยก่อน โดยถูกจัดเก็บไว้ที่

C:\Progra~1\IBM\SQLLIB\samples\db2xml\dad\getstart_xcolumn.dad

แล้วใช้คำสั่ง

dxxadm enable_column sales_db sales_tab order

C:\Progra~1\IBM\SQLLIB\samples\db2xml\dad\getstart_xcolumn.dad -v MM_view

เมื่อเสร็จสิ้นขั้นตอนนี้ เราจะได้ตารางสำคัญ 2 ตารางที่นำไปใช้งาน คือ ตารางหลักชื่อ

MM_TAB และ **TXML** เป็นไซค์เทเบิลที่ถูกสร้างขึ้นตามที่ประกาศโครงสร้างไว้ในไฟล์ดีเอที

4.4.2 เอกสารดีเอที

เป็นไฟล์เอกสารที่ระบุว่าเอกสารที่จะจัดเก็บในคอลัมน์ที่สามารถทำงานร่วมกับ อิเล็กทรอนิกส์แอล นั้นจะทำอินเตอร์แอคชันอย่างไร เอกสารดีเอทีนั้นระบุไฟล์ ดีทีดี ไว้สำหรับตรวจสอบเอกสารที่จะนำมาเก็บในคอลัมน์ไว้ในแท็ก <didid> ถ้าต้องการให้ตรวจสอบเอกสารก่อนที่จะทำการจัดเก็บลงตารางให้ใส่ค่า “YES” ภายในแท็ก <validation> หากไม่ต้องการให้ใส่ “NO” ด้านล่างนี้เป็นไฟล์ดีเอทีที่ใช้ในโครงการนี้

```

<?xml version = "1.0" encoding="UTF-8"?>
<!DOCTYPE DAD SYSTEM "E:\Project\db2\sample.dtd">
<!DOCTYPE DAD SYSTEM "E:\Project\db2\sample.dtd">
<DAD>
    <dtdid>sample.dtd</dtdid>
    <validation>NO</validation>
    <Xcolumn>
        <table name = "TXML">
            <columnname = "Title"
                type = "varchar(50)"
                path = "/Multimedia/Title"
                multi_occurrence = "NO"
            />
            <columnname = "FileName"
                type = "varchar(50)"
                path = "/Multimedia/FileName"
                multi_occurrence = "NO"
            />
            <columnname = "FileType"
                type = "varchar(50)"
                path = "/Multimedia/FileType"
                multi_occurrence = "NO"
            />
            <columnname = "Category"
                type = "varchar(50)"
                path = "/Multimedia/Category"
                multi_occurrence = "NO"
            />
            <columnname = "Size"
                type = "integer"
                path = "/Multimedia/Size"
                multi_occurrence = "NO"
            />
            <columnname = "Date"

```

```
        type = "varchar(50)"
        path = "/Multimedia/Date"
        multi_occurrence = "NO"
    />
    <columnname = "Time"
        type = "varchar(50)"
        path = "/Multimedia/Time"
        multi_occurrence = "NO"
    />
    <columnname = "Description"
        type = "varchar(500)"
        path = "/Multimedia/Description"
        multi_occurrence = "NO"
    />
    <columnname = "Author"
        type = "varchar(50)"
        path = "/Multimedia/Author"
        multi_occurrence = "NO"
    />
    <columnname = "Email"
        type = "varchar(50)"
        path = "/Multimedia/Email"
        multi_occurrence = "NO"
    />
</table>
</Xcolumn>
</DAD>
```


4.4.3 ตารางต่างๆบนฐานข้อมูล

MM_TAB

DXXROOT_ID	XML
------------	-----

โดย XML เป็นคอลัมน์ที่จัดเก็บเอกสารเอ็กซ์เอ็มแอล

TXML

DXXROOT_ID		TITLE	FILENAME	FILETYPE
CATEGORY	SIZE	DATE	TIME	DESCRIPTION
AUTHOR	EMAIL			

TXML เป็นไชด์เทเบิลที่ถูกสร้างขึ้นมาจากโครงสร้างในเอกสารดีเอดี

CAT_TAB

SUB1	SUB2	SUB3
------	------	------

CAT_TAB เป็นตารางเก็บข้อมูลหมวดหมู่ของประเภทไฟล์

USER_TAB

U_NAM	PASSWORD	EMAIL	GRANT
-------	----------	-------	-------

USER_TAB เป็นตารางเก็บข้อมูลของผู้ใช้

4.4.4 การจัดเก็บเอกสารเอ็กซ์เอ็มแอลบนฐานข้อมูล

เมื่อมีการรับไฟล์ข้อมูลเข้ามาเพื่อจัดเก็บ เอกสารเอ็กซ์เอ็มแอลจะถูกสร้างขึ้น และถูกจัดเก็บไว้บนตาราง MM_TAB ในตารางนี้จะมีสองคอลัมน์ คือ หนึ่งใช้จัดเก็บตำแหน่งของเอกสารเอ็กซ์เอ็มแอลในคอลัมน์ XML บนตาราง MM_TAB และสองคือ DXXROOT_ID ที่ดีบีทูลสร้างและกำหนดให้กับแต่ละเอกสารเอ็กซ์เอ็มแอล เมื่อตำแหน่งของเอกสารเอ็กซ์เอ็มแอลถูกจัดเก็บไว้บนตาราง MM_TAB แล้วดีบีทูลจะจัดการเก็บค่าคอนเท้นท์ต่างๆในแต่ละแท็ก ของเอกสารเอ็กซ์เอ็มแอลไปจัดเก็บใส่ไว้ในแต่ละคอลัมน์ของไชด์เทเบิล TXML โดยจะความสัมพันธ์จะตรงกันกับที่ประกาศไว้ในเอกสารดีเอดี โดยอัตโนมัติ

4.5 การทำงานของระบบ

4.5.1 การสมัครสมาชิก

ผู้ใช้ที่มีความประสงค์ในการใช้ระบบจะต้องทำการลงทะเบียนสมัครสมาชิกกับระบบก่อน ในการสมัครสมาชิกผู้ใช้อาจกรอกรายละเอียดข้อมูลดังนี้

- ชื่อสมาชิก
- ชื่อจดหมายอิเล็กทรอนิกส์ (Email)
- รหัสผ่านที่ต้องการ
- รหัสผ่านที่ต้องการอีกครั้ง

เมื่อผู้ใช้ได้ทำการกรอกรายละเอียดข้อมูลข้างต้นแล้ว ระบบจะนำข้อมูลเหล่านี้มาทำการตรวจสอบข้อมูลที่ผู้ใช้ว่าได้ทำการกรอกมาหรือไม่ ขั้นต่อไปก็จะทำการตรวจสอบชื่อจดหมายอิเล็กทรอนิกส์ที่กรอกมานั้นจะต้องมีเครื่องหมาย “@” อยู่ตามด้วย “.” ซึ่งตัวอักษร “@” และ “.” นั้นต้องไม่ติดกันอีกด้วย จากนั้นก็จะทำการตรวจสอบรหัสผ่านของผู้ใช้ว่าทำการกรอกมาเหมือนกันหรือไม่ ขั้นต่อไปจะนำข้อมูลชื่อสมาชิกไปทำการตรวจสอบกับชื่อสมาชิกในฐานข้อมูลที่มีอยู่ ชื่อของสมาชิกนั้นจะต้องไม่ซ้ำกัน หากผ่านขั้นตอนเหล่านี้แล้วระบบก็จะทำการเก็บชื่อสมาชิก ชื่อจดหมายอิเล็กทรอนิกส์ และรหัสผ่านไว้ในฐานข้อมูล

4.5.2 การเข้าสู่ระบบ

ผู้ใช้ที่มีความประสงค์ที่จะใช้ระบบจะต้องทำการสมัครสมาชิกก่อนที่จะเข้าสู่ระบบ เมื่อสมัครสมาชิกเรียบร้อยแล้ว ผู้ใช้ก็จะมาเริ่มเข้าสู่ระบบได้โดยการกรอกชื่อสมาชิกและรหัสผ่าน ระบบจะนำชื่อสมาชิกและรหัสผ่านที่ผู้ใช้ทำการกรอกมาไปตรวจสอบกับฐานข้อมูลที่มีอยู่หากชื่อสมาชิกและรหัสผ่านถูกต้อง ระบบจะสร้างคุกกี้ (Cookie) แล้วส่งไปฝังตัวที่ทางฝั่งผู้ใช้ ระบบจะใช้คุกกี้นี้เพื่อที่จะทำการตรวจสอบการเข้าสู่ระบบของผู้ใช้ต่อไป ในการสร้างคุกกี้ก็จะฝังข้อมูลสองอย่างดังนี้ ชื่อผู้ใช้ และ สิทธิของผู้ใช้ ซึ่งสิทธิของผู้ใช้นั้นขึ้นอยู่กับข้อมูลสิทธิที่อยู่ในฐานข้อมูล สิทธิของผู้ใช้แบ่งออกเป็นสองระดับคือ ผู้ใช้ระดับธรรมดา กับ ผู้ใช้ที่เป็นผู้ดูแลระบบ

4.5.3 การจัดเก็บสื่อและข้อมูลดิจิทัล

การจัดเก็บสื่อและข้อมูลดิจิทัลผู้ใช้อาจจะต้องทำการเข้าสู่ระบบก่อนที่จะทำการจัดเก็บได้ เมื่อผู้ใช้เลือกที่จะทำการจัดเก็บระบบจะทำการตรวจสอบคุกกี้ที่ได้สร้างไว้ตอนที่ทำการเข้าสู่ระบบ หากทางฝั่งผู้ใช้มีคุกกี้ที่ระบบสร้างไว้ให้ก็จะสามารถทำการจัดเก็บสื่อและข้อมูลดิจิทัลได้โดย ผู้ใช้จะต้องทำการเลือกหมวดหมู่หลักที่จะทำการจัดเก็บ เมื่อทำการเลือกแล้วขั้นตอนต่อไปผู้ใช้อาจจะต้องทำการเลือกหมวดหมู่ย่อยให้ตรงกับเนื้อหาของข้อมูลที่ผู้ใช้ต้องการที่จะจัดเก็บ ผู้ใช้จะต้องทำการกรอกข้อมูลต่างๆดังนี้

- หัวเรื่อง (Title)
- ชื่อผู้ทำการจัดเก็บข้อมูล (Author)

- ชื่อจดหมายอิเล็กทรอนิกส์ (Email)
- รายละเอียดอื่นของสื่อและข้อมูล (Description)
- สื่อและข้อมูลที่ประสงค์จะจัดเก็บ (FileName)

ผู้ใช้งานเป็นต้องที่ทำการกรอกข้อมูลให้ครบและให้ตรงกับเนื้อหาของข้อมูลทำการจัดเก็บให้มากที่สุดเพื่อนำไปใช้ในการค้นหาข้อมูล เมื่อทำการกรอกข้อมูลต่างๆครบแล้ว ระบบจะทำการเก็บข้อมูลโดยการนำข้อมูลไปจัดเก็บภายในเซิร์ฟเวอร์ให้ตรงกับหมวดหมู่ของข้อมูลตามที่ใช้ได้ทำการเลือกมา และจะสร้างเอกสารเอ็กซ์เอ็มแอล (XML) การสร้างเอกสารเอ็กซ์เอ็มแอลนี้ข้อมูลที่ยกรอกภายในเอกสารนี้ส่วนหนึ่งได้มาจากผู้ใช้และอีกส่วนหนึ่งได้มาจากข้อมูลทางฝั่งเซิร์ฟเวอร์ และข้อมูลของสื่อที่ผู้ใช้ประสงค์ที่จะจัดเก็บ เอกสารเอ็กซ์เอ็มแอลที่สร้างขึ้นนี้จะถูกจัดเก็บลงภายในฐานข้อมูลบีบีทู (DB2) ซึ่งขั้นตอนการจัดเก็บข้อมูลนั้นได้กล่าวไว้ข้างต้นแล้ว

4.5.4 การเรียกดูสื่อและข้อมูลดิจิทัล

การเรียกดูสื่อและข้อมูลดิจิทัลผู้ใช้จะต้องทำการเข้าสู่ระบบก่อนเช่นเดียวกันกับการจัดเก็บสื่อและข้อมูลดิจิทัล เมื่อผู้ใช้เลือกที่จะทำการเรียกดูข้อมูล ผู้ใช้ต้องทำการเลือกหาข้อมูลตามหมวดหมู่ที่ผู้ใช้ต้องการโดยขั้นตอนการเรียกดูจะคล้ายคลึงกับการจัดเก็บข้อมูลกล่าวคือ ต้องทำการเลือกหมวดหมู่หลักตามด้วยหมวดหมู่ย่อยหากหมวดหมู่นั้นมีข้อมูลตามที่ใช้เรียกดูก็จะแสดงออกมา การแสดงผลการเรียกดูจะแสดงข้อมูล ชื่อของข้อมูลนั้นๆ วันที่ทำการจัดเก็บ ชื่อผู้ที่ทำการจัดเก็บ หมวดหมู่ และ รายละเอียดเพิ่มเติมของข้อมูล หลังจากขั้นตอนการเรียกดูนี้ผู้ใช้สามารถที่จะค้นหาข้อมูลภายในหมวดหมู่ที่ผู้ใช้ประสงค์ที่จะเรียกดูต่อไป และยังสามารถที่จะเล่นข้อมูลประเภทภาพหรือเสียงได้ รวมทั้งสามารถดาวน์โหลดข้อมูลเหล่านั้นได้อีกด้วย

4.5.5 การแสดงผลสื่อและข้อมูลดิจิทัล

การแสดงผลสื่อและข้อมูลดิจิทัลผู้ใช้จะต้องทำการเข้าสู่ระบบก่อนเช่นเดียวกันกับการจัดเก็บสื่อและข้อมูลดิจิทัล ต่อจากเมื่อทำการเรียกดูสื่อและข้อมูลดิจิทัลแล้วนั้น หากผู้ใช้ประสงค์ที่จะให้แสดงผลสื่อและข้อมูลดิจิทัลสำหรับสื่อที่เป็นภาพหรือเสียงได้นั้น ระบบจะทำการตรวจสอบคุกกี้ของผู้ใช้เพื่อให้แน่ใจว่าได้ทำการเข้าสู่ระบบมาก่อนแล้ว โดยการแสดงผลสื่อและข้อมูลดิจิทัลนั้นจะแสดงผ่านแท็ก ตัวอย่างนี้

```
<object width="378" height="292">
```

```
<embed src="../../MediaTest/trippygaia1.mid" width="378" height="292"></embed>
```

```
</object>
```

ภายในแท็กอ็อบเจกต์ <object> จะทำการกำหนดความกว้างและสูงของส่วนแสดงผล

แท็กเอ็มเบด <embed> เอสอาซี src เป็นการอ้างถึงข้อมูลสื่อที่ต้องการแสดงผล

4.5.6 การดาวน์โหลดสื่อและข้อมูลดิจิทัล

การดาวน์โหลดสื่อและข้อมูลดิจิทัลผู้ใช้จะต้องทำการเข้าสู่ระบบก่อนเช่นเดียวกันกับการแสดงผลสื่อและข้อมูลดิจิทัล ต่อจากเมื่อทำการเรียกดูสื่อและข้อมูลดิจิทัลแล้วนั้น หากผู้ใช้ประสงค์ที่การดาวน์โหลดสื่อและข้อมูลดิจิทัล ก็สามารถทำได้โดยเลือกไปที่การดาวน์โหลดตรงส่วนนี้เป็นการสร้างแท็กที่อ้างถึงไฟล์ธรรมดา

4.5.7 การค้นหาสื่อและข้อมูลดิจิทัล

การค้นหาสื่อและข้อมูลดิจิทัล เมื่อผู้ใช้เข้าสู่ระบบแล้ว ผู้ใช้สามารถค้นหาไฟล์ข้อมูลโดยการป้อนคีย์เวิร์ด ให้กับระบบนำมาใช้ในการค้นหา โดยในขั้นตอนแรก ระบบจะทำการแปลความหมายของคีย์เวิร์ด แล้วไปค้นหาคีย์เวิร์ดจากเอกสารอิเล็กทรอนิกส์แอมแอลบนฐานข้อมูล เมื่อพบจะนำผลลัพธ์เหล่านั้นมาทำการจัดอันดับในการแสดงผลให้ตรงกับความหมายที่แปลมาจากคีย์เวิร์ด แล้วจึงนำไปแสดงผลต่อผู้ค้นหาต่อไป โดยในการแสดงผลจะเหมือนกับการผลในหัวข้อ 4.5.5 ซึ่งผู้ใช้สามารถเลือกที่จะดาวน์โหลดหรือแสดงผลต่อไปได้ ส่วนการแปลความหมายของคีย์เวิร์ด และกระบวนการคำนวณจัดลำดับการแสดงผลจะกล่าวถึงในหัวข้อ 4.6

4.5.8 การลบข้อมูลสื่อและข้อมูลดิจิทัล

การลบข้อมูลสื่อและข้อมูลดิจิทัลผู้ใช้จะต้องทำการเข้าสู่ระบบก่อนเช่นเดียวกันแต่ผู้ที่ทำการลบข้อมูลสื่อได้นั้นจะต้องเป็นผู้ที่มีสิทธิในการลบข้อมูลสื่อกล่าวคือ ระบบจะทำการตรวจสอบสิทธิของผู้ใช้จากทุกที่ที่ระบบได้สร้างไว้ในขั้นตอนการเข้าสู่ระบบหากเป็นผู้ใช้ระดับผู้ดูแลระบบจะมีทุกที่ที่มีข้อมูลสิทธิที่เป็นระดับผู้ดูแลระบบก็จะสามารถทำการลบข้อมูลสื่อได้ ส่วนติดต่อผู้ใช้ในขั้นตอนการลบนั่นก็คล้ายกับในขั้นตอนการเรียกดูสื่อและข้อมูลดิจิทัลแต่จะมีฟังก์ชันในการลบข้อมูลสื่อเพิ่มขึ้นมา การลบนั่นสามารถทำได้โดยการเลือกหมวดหมู่หลักที่ต้องการตามด้วยหมวดหมู่ย่อย หากมีข้อมูลสื่ออยู่ภายในหมวดหมู่นั้นก็จะสามารถที่จะเลือกได้โดยทำการเลือกเช็คบ็อก (Checkbox) แล้วเลือกทำการลบระบบก็จะทำการลบข้อมูลสื่อนั้นออกจากฐานข้อมูล และข้อมูลสื่อบนเซิร์ฟเวอร์

4.5.9 การลบหมวดหมู่ของสื่อและข้อมูลดิจิทัล

การลบหมวดหมู่ของสื่อและข้อมูลดิจิทัลเป็นส่วนที่สำคัญของผู้ดูแลระบบ ผู้ดูแลระบบต้องทำการตรวจสอบให้แน่ใจเสียก่อนการลบว่าหมวดหมู่นั้นไม่สำคัญอีกต่อไปแล้ว การลบหมวดหมู่นั้นผู้ดูแลระบบต้องทำการเข้าสู่ระบบเช่นเดียวกับผู้ใช้ทั่วไป ในการลบหมวดหมู่นั้นผู้ดูแลต้องเลือกฟังก์ชันการเรียกดูข้อมูลสื่อ การลบหมวดหมู่สามารถลบหมวดหมู่หลัก หมวดหมู่ย่อยที่1 และหมวดหมู่ย่อยที่2 การลบหมวดหมู่หลักจะทำได้ เมื่อเลือกฟังก์ชันการเรียกดูข้อมูลแล้ว จะมีส่วนแสดงแท็กช็อบ (Textbox) ให้กรอกชื่อหมวดหมู่ที่จะทำการลบตามที่แสดงไว้ที่หน้าเว็บเพจ หากต้องการที่จะลบหมวดหมู่ย่อยที่1 ต้องทำการเลือกหมวดหมู่หลักเสียก่อน หลังจากที่ได้เลือกหมวดหมู่หลักแล้วหน้าเว็บจะแสดงหมวดหมู่ย่อยที่1 ผู้ดูแลทำการกรอกชื่อหมวดหมู่ย่อยที่1 ที่ต้องการลบออกจากระบบ หากต้องการลบหมวดหมู่ย่อยที่2 ก็

สามารถทำได้เช่นเดียวกับการลบหมวดหมู่ย่อยที่1 โดยทำการเลือกหมวดหมู่หลักก่อนตามด้วยหมวดหมู่ย่อยที่1 หน้าเว็บจะแสดงผลหมวดหมู่ย่อยที่2 ออกมา ผู้ดูแลทำการกรอกชื่อหมวดหมู่ย่อยที่2 ที่ต้องการลบออกจากระบบ

หลังจากที่ทำการเลือกหมวดหมู่ที่ต้องการลบออกจากระบบแล้วระบบจะทำการลบชื่อหมวดหมู่ดังที่เลือกไว้จากฐานข้อมูล และทำการลบไดเรกทอรี (Directory) และข้อมูลสื่อต่างๆที่อยู่ภายใต้ไดเรกทอรีนั้นออกไปจากเซิร์ฟเวอร์

4.5.10 การสร้างหมวดหมู่ของสื่อและข้อมูลดิจิทัล

การสร้างหมวดหมู่ของสื่อและข้อมูลดิจิทัลเป็นส่วนที่สำคัญอีกเช่นเดียวกันกับการลบหมวดหมู่ เพราะผู้ดูแลต้องทำการตรวจสอบเนื้อหาข้อมูลสื่อของผู้ใช้ที่ทำการจัดเก็บมาเพื่อที่จะคัดเลือกว่าหมวดหมู่ใดที่ต้องทำการสร้างขึ้นมาเพื่อให้สอดคล้องกับความต้องการการจัดเก็บข้อมูลของผู้ใช้ ในการสร้างหมวดหมู่ของสื่อและข้อมูลดิจิทัลนั้นคล้ายกับการลบมาก ในการสร้างหมวดหมู่นั้นผู้ดูแลต้องเลือกฟังก์ชันการเรียกดูข้อมูลสื่อ การสร้างหมวดหมู่สามารถสร้างหมวดหมู่หลัก หมวดหมู่ย่อยที่1 และหมวดหมู่ย่อยที่2ได้ การสร้างหมวดหมู่หลักจะกระทำได้เมื่อเลือกฟังก์ชันการเรียกดูข้อมูลแล้ว จะมีส่วนเท็กซ์บ็อกซ์ (Textbox) ให้กรอกชื่อหมวดหมู่ที่จะทำการสร้างตามที่แสดงไว้ที่หน้าเว็บเพจ หากต้องการที่จะสร้างหมวดหมู่ย่อยที่1 ต้องทำการเลือกหมวดหมู่หลักเสียก่อน หลังจากที่ได้เลือกหมวดหมู่หลักแล้ว หน้าเว็บจะแสดงผลหมวดหมู่ย่อยที่1 ผู้ดูแลทำการกรอกชื่อหมวดหมู่ย่อยที่1 ที่ต้องการสร้างเข้าสู่จากระบบ หากต้องการสร้างหมวดหมู่ย่อยที่2 ก็สามารถทำได้เช่นเดียวกับการสร้างหมวดหมู่ย่อยที่1 โดยทำการเลือกหมวดหมู่หลักก่อนตามด้วยหมวดหมู่ย่อยที่1 หน้าเว็บจะแสดงผลหมวดหมู่ย่อยที่2 ออกมา ผู้ดูแลทำการกรอกชื่อหมวดหมู่ย่อยที่2 ที่ต้องการสร้างเข้าสู่ระบบ

หลังจากที่ทำการเลือกหมวดหมู่ที่ต้องการสร้างเข้าสู่จากระบบแล้วระบบจะทำการสร้างชื่อหมวดหมู่ดังที่เลือกไว้เข้าสู่ฐานข้อมูล และทำการสร้างไดเรกทอรี (Directory) นั้นบนเซิร์ฟเวอร์

4.5.11 การออกจากระบบ

การออกจากระบบสามารถทำได้โดยเลือกฟังก์ชันออกจากระบบ ระบบจะทำการทำลายคุกกี้ที่ได้สร้างไว้ตอนการเข้าสู่ระบบโดยทำการตั้งค่าอายุของคุกกี้ให้เป็นศูนย์คุกกี้ นั้นก็จะถูกทำลาย

4.6 ระบบค้นหา (Search engine)

ระบบค้นหาเป็นระบบที่ช่วยในการค้นหาไฟล์เอกสารในฐานข้อมูล โดยการรับคีย์เวิร์ดจากผู้ใช้ แล้วนำมาพิจารณาแปลความหมายของคีย์เวิร์ด แล้วจึงนำไปค้นหาจากคอนเท้นต์ต่างๆของเอกสารอิเล็กทรอนิกส์ เอมแอลบนฐานข้อมูล เมื่อได้ผลลัพธ์จะนำเอกสารที่ตรงกับคีย์เวิร์ดมาทำการจัดลำดับว่าเอกสารใดมีความหมายตรงกับคีย์เวิร์ดมากที่สุด(ranking) แล้วจึงนำผลลัพธ์นั้นมาแสดงผลต่อผู้ใช้

4.6.1 การแปลความหมายของคีย์เวิร์ด

จะพิจารณาเป็นลำดับขั้นดังนี้

- อันดับแรกรับคีย์เวิร์ดที่ต้องการนำไปใช้ค้นหาจากผู้ใช้
- พิจารณาจากสัญลักษณ์พิเศษที่ผู้ใช้ใส่เข้ามานอกเหนือจากข้อความที่ผู้ใช้ต้องการแล้วนำไปค้นหา โดยสัญลักษณ์พิเศษมีทั้งหมด 3 ตัว คือ
 - สัญลักษณ์ฟั่นหนู “...” โดยใส่ครอบประโยคหรือวลีเพื่อให้ค้นหาจากทั้งกลุ่มคำนั้น
 - สัญลักษณ์บวก “+” โดยใส่ไว้หน้าคำหรือวลีเพื่อให้แสดงผลเฉพาะเอกสารที่มีคำหรือวลีนั้นๆอยู่
 - สัญลักษณ์ลบ “-” โดยใส่ไว้หน้าคำหรือวลีเพื่อให้แสดงผลเฉพาะเอกสารที่ไม่มีคำหรือวลีนั้นๆอยู่

จะพิจารณาความหมายคีย์เวิร์ดและสัญลักษณ์ในกรณีต่างๆดังนี้

1. คำหรือกลุ่มคำที่ไม่มีสัญลักษณ์พิเศษ เช่น

key : computer

ระบบจะค้นหาและแสดงผลเอกสารที่มีคำว่า “computer”

key : computer system

ระบบจะค้นหาแสดงผลเอกสารที่มีคำว่า “computer system”, “computer” และ “system”

ตามลำดับ

key : computer system security

ระบบจะค้นหาแสดงผลเอกสารที่มีคำว่า “computer system security”, “computer”, “system”

และ “security” ตามลำดับ

2. เมื่อใส่สัญลักษณ์ฟั่นหนู ครอบกลุ่มของคำ จะมองว่า กลุ่มคำนั้นเป็นประโยคหรือวลีชุด

เดียวกัน เช่น

key : “computer system” security

ระบบจะค้นหาและแสดงผลเอกสารที่มีคำว่า “computer system” และ “security” ตามลำดับ

โดยไม่แสดงผลเอกสารที่มีแต่คำว่า “computer”, “system” หรือ “system computer”

key : computer “system security”

ระบบจะค้นหาและแสดงผล “computer” และ “system security” ตามลำดับ โดยไม่แสดงผลเอกสารที่มีแต่คำว่า “system”, “security” หรือ “security system”

key : “computer system security”

ระบบจะค้นหาและแสดงผล “computer system security” เท่านั้น โดยไม่แสดงผลเอกสารที่มีแต่คำว่า “computer”, “system” หรือ “security” คำใดคำหนึ่งเท่านั้น

3. เมื่อใส่สัญลักษณ์บวกลบนำหน้าคำ ระบบจะค้นหาและแสดงผลเอกสารที่มีค่านั้นเท่านั้น เช่น

key : +computer system

ระบบจะค้นหาคำว่า “computer” และ “system” แต่จะแสดงผลเอกสารเฉพาะที่มีคำว่า “computer” เท่านั้น ส่วนคำว่า “system” จะมีปรากฏหรือไม่ก็ได้

4. เมื่อใส่สัญลักษณ์ลบนำหน้าคำ ระบบจะค้นหาและแสดงผลเอกสารที่ไม่มีค่านั้นเท่านั้น เช่น

key : computer –system

ระบบจะค้นหาคำว่า “computer” และ “system” แต่จะแสดงผลเอกสารเฉพาะที่มีคำว่า “computer” และไม่มีคำว่า “system” ปรากฏอยู่ในเอกสารนั้น

5. เมื่อใส่สัญลักษณ์บวกลบนำหน้าข้อความที่ถูกครอบงำด้วยเครื่องหมายฟันทวน เช่น

key : +”computer system” security

ระบบจะค้นหาคำว่า “computer system” และ “security” แต่จะแสดงผลเฉพาะเอกสารที่มีคำว่า “computer system” ส่วน “security” จะมีปรากฏอยู่ด้วยหรือไม่ก็ได้

key : computer –“system security”

ระบบจะค้นหาคำว่า “computer” และ “system security” แต่จะแสดงผลเฉพาะเอกสารที่มีคำว่า “computer” และไม่มีคำว่า “system security” อยู่ด้วย

- หลังจากแสดงผลแล้วจะมีทางเลือกสำหรับผู้ใช้อีกว่าต้องการค้นหาเอกสารจาก แท็กอะไรเป็นพิเศษหรือไม่ เช่น ต้องการค้นหาจากเฉพาะแท็กชื่อเอกสาร หรือแท็ก <Title> นั่นเอง

4.6.2 หลักการคำนวณในการจัดอันดับของเอกสาร เพื่อแสดงผล

การจัดอันดับของเอกสาร คือ การจัดเรียงเอกสารในการแสดงผลการค้นหา มีหลักการคิด

คำนวณหา

ค่าความคล้ายคลึงกันของคีย์เวิร์ดและเทอมในเอกสาร โดยใช้สูตรการหาค่าความคล้ายคลึงกันจากเวกเตอร์โมเดล ซึ่งเป็นโมเดลหนึ่งในวิชาอินฟอร์เมชัน รีทรีฟอล(Information Retrieval) โดยมีหลักการคำนวณอยู่ คือ นำค่าน้ำหนักของเทอมของคีย์เวิร์ด และค่าน้ำหนักของอินเด็กซ์เทอมในเอกสารซึ่งใช้เทอมเดียวกันกับเทอมของคีย์เวิร์ดเท่านั้น มาสร้างเป็นเวกเตอร์ กำหนด

$\vec{q}$ $\vec{q} = (w_{1,q}, w_{2,q}, \dots, w_{t,q})$ เป็นเวกเตอร์บอกค่าน้ำหนักของแต่ละเทอมของคีย์เวิร์ด โดย t คือจำนวนทั้งหมดของคีย์เวิร์ด

$\vec{d}$ $\vec{d} = (w_{1,j}, w_{2,j}, \dots, w_{t,j})$ เป็นเวกเตอร์บอกค่าน้ำหนักของแต่ละเทอมของอินเด็กซ์เทอมในเอกสาร

k_i เป็นอินเด็กซ์เทอมลำดับที่ i

d_j เป็นเอกสาร ลำดับที่ j

$w_{i,j}$ เป็นค่าน้ำหนักแสดงความสัมพันธ์ของคู่เทอม k_i ในเอกสาร d_j

$q_{i,j}$ เป็นค่าน้ำหนักแสดงความสัมพันธ์ของคู่เทอม k_i ใน q

เราสามารถกำหนดค่าให้แก่แต่ละ $w_{i,j}$ ได้ดังสูตร

$$w_{i,j} = f_{i,j} \times idf_i$$

โดย $f_{i,j}$ หาได้จากสูตร

$$f_{i,j} = \frac{freq_{i,j}}{\max_l freq_{l,j}}$$

ซึ่งค่า $freq_{i,j}$ คือ ค่าของความถี่ของการปรากฏของเทอมที่ i ในเอกสารที่ j และ $\max_l freq_{l,j}$ คือ ค่าความถี่ของการปรากฏที่มากที่สุดของเทอม l ในเอกสารที่ j และหาค่า idf_i ได้จากสูตร

$$idf_i = \log \frac{N}{n_i}$$

โดย N คือ ค่าจำนวนเอกสารทั้งหมดบนฐานข้อมูล และ n_i คือ ค่าจำนวนเอกสารที่มีเทอมของคีย์เวิร์ดอยู่ ส่วนการคำนวณหาค่าน้ำหนักของเทอมของคีย์เวิร์ดนั้น ทฤษฎีของซอลตันและบัคเลย์ (Salton and Buckley) ได้เสนอแนะการกำหนดค่าน้ำหนักของเทอมของคีย์เวิร์ดในควายี่ q ที่ค่านั้นหาได้จากสูตร

$$w_{i,q} = \left(0.5 + \frac{0.5 freq_{i,q}}{\max_l freq_{l,q}} \right) \times \log \frac{N}{n_i}$$

ซึ่ง $freq_{i,q}$ คือ ค่าความถี่ที่ปรากฏของเทอมของคีย์เวิร์ดในควายี่ q และ $\max_l freq_{l,q}$ คือ ค่าความถี่ที่ปรากฏของเทอมของคีย์เวิร์ดที่มากที่สุด

เมื่อได้ค่าน้ำหนักของทุกเทอมทั้งในเวกเตอร์ $\vec{d}$ และ $\vec{q}$ จะสามารถหาค่าความใกล้เคียงกันของทั้งสองเวกเตอร์ได้จากสูตร

$$\begin{aligned} sim(d_j, q) &= \frac{\vec{d}_j \bullet \vec{q}}{|\vec{d}_j| \times |\vec{q}|} \\ &= \frac{\sum_{i=1}^t w_{i,j} \times w_{i,q}}{\sqrt{\sum_{i=1}^t w_{i,j}^2} \times \sqrt{\sum_{i=1}^t w_{i,q}^2}} \end{aligned}$$

เรานำค่า $sim(d_j, q)$ มาใช้ในการบ่งบอกค่าความคล้ายกันของทั้งสองเวกเตอร์ โดยเมื่อค่า $sim(d_j, q)$ เข้าใกล้ 1 หมายความว่าเอกสารมีความคล้ายคลึงกันมาก แต่ถ้าค่า $sim(d_j, q)$ เข้าใกล้ 0 หมายความว่าเอกสารมีความคล้ายคลึงกันน้อย

นอกจากคำนวณหาความคล้ายคลึงกันของเอกสาร จากค่าน้ำหนักที่กำหนดไว้ในแต่ละเทอมแล้ว ในการจัดลำดับเอกสารเพื่อแสดงผลการค้นหานั้น จะมีการคูณค่าคงที่เข้าไปเพื่อเป็นการทวีคูณ ความสำคัญของเทอมนั้นๆ ที่ได้มาจากการแปลความหมายของคีย์เวิร์ด เช่น รับคีย์เวิร์ดมาจากผู้ใช้งานที่ต้องการค้นหา

key : computer security

จากคีย์เวิร์ดนี้ระบบจะทำการค้นหาคีย์เวิร์ดทั้งหมด 3 เทอม คือ “computer security” “computer” และ “security” โดยระบบจะให้ความสำคัญกับคำว่า “computer security” เป็นอันดับแรก จะคูณค่าคงที่ให้กับเทอมนี้มากกว่าอีกสองเทอมที่เหลือ ดังค่าในเวกเตอร์ของควายี่ q

$$\vec{q} = (2 \times w_{1,q}, 1 \times w_{2,q}, 1 \times w_{3,q})$$

จากเวกเตอร์ ค่าน้ำหนักของ $w_{1,q}$ ถูกคูณด้วย 2 ซึ่งอีก 2 เทอมถูกคูณด้วย 1 ทำให้ค่าน้ำหนักของเทอม $w_{1,q}$ มีค่าทวีคูณขึ้นในอัตราส่วนที่มากกว่าอีก 2 เทอม เพื่อบ่งบอกว่าให้ความสำคัญกับเทอมแรกมากที่สุด ในอัตราส่วน 2:1:1

4.6.3 การคำนวณในการจัดลำดับในเอกสาร

ขั้นตอนที่ 1 รับค่าคีย์เวิร์ดจากผู้ให้บริการระบบที่ต้องการใช้ในการค้นหา แล้วทำการแปลความหมายของคีย์เวิร์ดตามรูปแบบที่กล่าวไว้ในหัวข้อ 4.6.1 ในขั้นตอนนี้จะแบ่งคีย์เวิร์ดตามความสำคัญคือ วลีหรือประโยคมีความสำคัญเป็น 2 เท่าของคำเดี่ยวๆ นอกจากนี้จะทำกำกับคีย์เวิร์ดแต่ละตัวว่ามีสัญลักษณ์พิเศษใดบ้าง “+” หรือ “-”

ขั้นตอนที่ 2 นำคีย์เวิร์ดทุกค่าไปค้นหาจากฐานข้อมูล โดยใช้คำสั่ง SQL เลือกเอกสารที่มีคีย์เวิร์ดต่างๆ ในขั้นตอนนี้จะเลือกสร้างคำสั่ง SQL ในการเลือกเอกสารตามเงื่อนไขของคีย์เวิร์ดแต่ละตัวด้วย โดยคีย์เวิร์ดที่มีสัญลักษณ์ “+” กำกับอยู่จะต้องปรากฏอยู่ในทุกเอกสารที่ถูกเลือก คีย์เวิร์ดที่มีสัญลักษณ์ “-” กำกับอยู่จะต้องไม่ปรากฏอยู่ในเอกสารใดๆ ที่ถูกเลือกอยู่ตามเงื่อนไขที่กำหนด ในคำสั่ง SQL ทั้งคีย์เวิร์ดที่มีทั้งสองสัญลักษณ์กำกับอยู่จะถูกเชื่อมกับคีย์เวิร์ดอื่นๆ ด้วยคำเชื่อม AND โดยมีเงื่อนไข เท่ากับ และ ไม่เท่ากับตามลำดับ

ขั้นตอนที่ 3 เมื่อได้เซตของเอกสารที่มีคีย์เวิร์ดต่างๆตามเงื่อนไขแล้ว จะนำแต่ละเอกสารมาจัดลำดับในการแสดงผล โดยใช้หลักการคำนวณตามสูตรในหัวข้อ 4.6.2 ในการทำงานนั้นระบบจะคำนวณทุกค่าที่ปรากฏในสูตรการคำนวณ แต่ในการอธิบายตัวอย่างการคำนวณจะแบ่งเป็นสองส่วน จากสูตรการคำนวณหาค่าความคล้ายคลึง คือ ผลรวมของเวกเตอร์ของค่าน้ำหนักของแต่ละคีย์เวิร์ดในแต่ละเอกสารคูณกับเวกเตอร์ของค่าน้ำหนักของแต่ละคีย์เวิร์ดใน query แล้วนำหารด้วยผลคูณของขนาดของสองเวกเตอร์ พิจารณาจากสูตรแล้วค่าที่มีผลกับค่าความคลึงเปลี่ยนแปลงไปมากที่สุดคือค่าของน้ำหนักของแต่ละคีย์เวิร์ดในแต่ละเอกสาร กับ ค่าของน้ำหนักของแต่ละคีย์เวิร์ดใน query และพิจารณาต่อไปค่าน้ำหนักของแต่ละคีย์เวิร์ดในแต่ละเอกสารเกิดจากความถี่ที่ปรากฏในเอกสารคูณกับค่า idf_i ดังนั้นจะอธิบายหลักการคำนวณเป็นสองส่วน คือ ส่วนที่ค่าความคล้ายคลึงมีผลมาจากความถี่ที่ปรากฏในเอกสาร กับ ส่วนที่ค่าความคล้ายคลึงมีผลมาจากค่า idf_i

ตัวอย่างการคำนวณส่วนที่มีผลมาจากความถี่

คีย์เวิร์ด : computer security

จากการแปลความหมายคีย์เวิร์ดจะได้คีย์เวิร์ดทั้งหมด 3 ตัว คือ “computer security” “computer” และ “security” สมมติมีเอกสารที่มีคีย์เวิร์ดต่างๆปรากฏอยู่อย่างน้อย 1 คีย์เวิร์ด ทั้งหมด 3 เอกสาร

เอกสาร/คีย์เวิร์ด	“computer security”	“computer”	“security”	ความคล้ายคลึง
เอกสารที่ 1	0	6	1	7
เอกสารที่ 2	2	4	2	10
เอกสารที่ 3	2	2	3	9
Query	2	1	1	

ตารางที่ 4-21 แสดงการคำนวณค่าความคล้ายคลึงด้วยค่าน้ำหนัก

จากตารางการคำนวณ ใน query มีคีย์เวิร์ดตัวที่ 1 คือ “computer security” ให้ความสำคัญมากกว่าคีย์เวิร์ดตัวที่ 2 และ 3 (“computer” และ “security”) สองเท่า ในเอกสารที่ 1 มีคีย์เวิร์ดที่ 1,2 และ 3 ปรากฏอยู่ 0 ครั้ง, 6 ครั้ง และ 7 ครั้งตามลำดับ ดังนั้น ค่าความคล้ายคลึงจะคำนวณอย่างง่าย ๆ ได้ $(0 \times 2) + (6 \times 1) + (1 \times 1)$ จะได้เท่ากับ 7 และด้วยวิธีการคำนวณแบบเดียวกันจะได้ค่าความคล้ายคลึงของในเอกสารที่ 2 และ 3 คือ 10 และ 9 ตามลำดับ

ผลการจัดลำดับจะได้ว่าเอกสารที่ 2 มีความคล้ายคลึงกับ คีย์เวิร์ดมากที่สุด รองลงไปที่เอกสารที่ 3 และ 1 ตามลำดับ

พิจารณาจากตัวอย่าง ค่าความถี่ของคีย์เวิร์ดตัวที่ 1 ซึ่งเป็นวลี “computer security” มีผลต่อการค่าความคล้ายคลึงมากที่สุด จากเอกสารที่ 2 และ 3 มีคีย์เวิร์ดที่ 1 ปรากฏอยู่เพียง 2 ครั้ง แต่มีค่าความคล้ายคลึงมากกว่าเอกสารที่ 1 เพราะเอกสารที่ 1 ไม่มีปรากฏคีย์เวิร์ดตัวที่ 1 เลย ถึงแม้ในเอกสารที่ 1 จะมีคีย์เวิร์ดตัวที่ 2 ปรากฏอยู่ถึง 6 ครั้ง

ตัวอย่างการคำนวณส่วนที่มีผลมาจากค่า idf_i จากตัวอย่างเดียวกัน พิจารณาสูตร

$$idf_i = \log \frac{N}{n_i}$$

ค่า idf_i มีผลมาจากค่า n_i และ N โดยสมมติค่า N มีค่าเท่ากับ 100

เอกสาร\ศัพท์	“computer security”	“computer”	“security”	ความคล้ายคลึง
เอกสารใดๆ	1.6989	1.5228	1.5228	4.7445
Query	1	1	1	

ตารางที่ 4-22 แสดงการคำนวณค่าความคล้ายคลึงด้วยค่า idf_i

ค่าที่ปรากฏในตารางของแต่ละศัพท์ในเอกสารใดๆ คือค่า idf_i ของแต่ละศัพท์ โดยในศัพท์เวิร์ดตัวที่ 1 มีเอกสารที่ปรากฏศัพท์เวิร์ดตัวที่ 1 อยู่ 2 เอกสาร ดังนั้น idf_i หาได้จาก $\log(100/2)$ ซึ่งมีค่าเท่ากับ 1.6989 และศัพท์เวิร์ดตัวที่ 2 และ 3 มีเอกสารที่มีศัพท์เวิร์ดปรากฏอยู่ศัพท์เวิร์ดละ 3 เอกสาร ดังนั้นค่า idf_i หาได้จาก $\log(100/3)$ ซึ่งเท่ากับ 1.5228 ค่าความคล้ายคลึงเราจะไม่สนใจตัวอย่างนี้ ค่าที่น่าสนใจคือค่า idf_i ซึ่งจะนำไปใช้คูณกับค่าน้ำหนักในการหาค่าความคล้ายคลึงกันในตัวอย่างแรก

พิจารณาฟังก์ชัน $\log$ เมื่อค่า n_i ยิ่งมากขึ้นจะทำให้ค่า $\log$ หรือ idf_i มีค่าลดลงเรื่อยๆ ดังนั้นศัพท์เวิร์ดที่ปรากฏอยู่ในเอกสารจำนวนมากๆ จะทำให้มีค่า idf_i น้อยกว่าศัพท์เวิร์ดที่ปรากฏอยู่ในเอกสารจำนวนน้อยๆ ทำให้ศัพท์เวิร์ดที่ปรากฏในเอกสารจำนวนมากๆเราจะให้ค่าความสำคัญน้อยกว่า เพราะถือว่าศัพท์เวิร์ดที่ปรากฏน้อยกว่าน่าจะมีความสำคัญมากกว่า เนื่องจากค่า idf_i นี้จะต้องนำไปคูณกับค่าความถี่ ก่อนนำไปคำนวณและส่งผลถึงค่าความคล้ายคลึงด้วย กล่าวให้เข้าใจง่ายๆคือ สมมติมีเอกสารที่ได้จากการค้นหา 100 เอกสาร โดยใช้ศัพท์เวิร์ด “computer” กับ “security” ปรากฏว่าใน 100 เอกสาร มีคำว่า “computer” อยู่ 95 เอกสาร และมีเอกสารที่มีคำว่า “security” อยู่ 10 เอกสาร จะเห็นได้ว่า “computer” เป็นคำที่ปรากฏอยู่เกือบทุกเอกสาร (95 จาก 100) เราจึงควรจะให้ค่าความสำคัญหรือค่าน้ำหนักกับ “security” มากกว่า

***หมายเหตุ ในขั้นตอนการจัดเรียงเอกสารนี้ ศัพท์เวิร์ดที่ถูกกำกับโดยสัญลักษณ์ “+” และ “-” ไม่มีผลใดๆต่อค่าความคล้ายคลึง