

บทที่ 4

ปัญญาประดิษฐ์

เป็นเวลากว่าหลายศตวรรษมาแล้วที่นักวิทยาศาสตร์ ต้องการเรียนรู้และเข้าใจจิตใจของมนุษย์ แต่ ปัญหาที่เกิดขึ้นก็ยังคงไร้ซึ่งคำตอบ ถึงกระนั้นก็ตามก็ยังมีนักวิทยาศาสตร์บางกลุ่มทำการสร้างและพัฒนา โปรแกรมเพื่อให้มีความสามารถเทียบเท่ามนุษย์ คือสามารถรู้สึกนึกคิดได้ โดยสิ่งที่พวกเขาได้สร้างขึ้นมา นั้นเราเรียกว่า ปัญญาประดิษฐ์


ปัญญาประดิษฐ์ สามารถจำกัดความได้ 2 ความหมาย คือ

- 1) สิ่งที่สามารถเข้าใจ และเรียนรู้เองได้
- 2) สิ่งที่สามารถคิด และเข้าใจในสิ่งที่ได้กระทำลงไปโดยสามัญสำนึก หรือทำโดยอัตโนมัติ

ความคิดที่สามารถแยกแยะสิ่งต่างๆ ที่มีความคลุมเครือได้ และการเรียนรู้ด้วยตัวเอง หนึ่งในวิธี จัดการกับปัญหาที่เกิดขึ้นคือ การนำฟัซซี่ลอจิก (Fuzzy Logic) และนิวรอนเน็ตเวิร์ค (Neural Network) มา ใช้งาน

4.1 ฟัซซี่ลอจิก (Fuzzy Logic)

ฟัซซี่ลอจิก เป็นการแก้ปัญหาที่ไม่สามารถระบบช่วงของข้อมูลได้ชัดเจน เช่น การแยกความสูง ของมนุษย์ ซึ่งไม่สามารถระบบขอบเขตที่ชัดเจนในการแบ่งได้ว่าใครสูงใครต่ำ ดังนั้นจึงมีการนำฟัซซี่ ลอจิกมาใช้งานเพื่อแยกแยะระดับต่างๆ โดยแต่ละระดับจะมีค่าอยู่ระหว่าง 0-1 โดยใช้เป็นตัวกำหนดค่า ความเป็นสมาชิก (Membership) คือ หากมีค่าเป็น 0 แสดงว่าไม่มีความเป็นสมาชิกเลย 1 คือมีความเป็นสมาชิ ก(Membership)มากที่สุด และค่าที่อยู่ระหว่าง 0-1 ก็คือระดับการเป็นสมาชิก เช่น ความสูง อาจมีการระบุ ว่าบุคคลผู้นี้มีความสูงมาหรือน้อยเป็นเช่นไร สามารถแบ่งระดับดังนี้ เตี้ยมาก เตี้ย ปานกลาง สูง สูงมาก เป็นต้น




รูปที่ 4-1 แสดงการแบ่งระดับระหว่างบูลีน(Boolean) และ ฟัซซี่ลอจิก(fuzzy)

ชื่อ	ความสูง	ระดับความสูง	
		บุลิน	พีชชี
สมชาย	208	1	1.00
สมยศ	205	1	1.00
สมรักษ์	198	1	0.98
สมสมัย	181	0	0.82
สมศรี	179	0	0.74
สมพร	172	0	0.24
สมพิศ	167	0	0.15
สมหมาย	158	0	0.06
สมจิต	155	0	0.01
สมใจ	152	0	0.00

ตารางที่ 4-1 แสดงตัวอย่างการแบ่งระดับความสูงโดยใช้บุลินและพีชชี

4.1.1 การนำพีชชีมาใช้งานในคอมพิวเตอร์

พีชชีลอจิกเป็นระบบการทำงานหนึ่งที่น่าสนใจในเรื่องของการเรียนรู้ เช่น ระบบต้องการทราบความคิดเห็นเป็นเช่นไร จากตัวอย่างในเรื่องของความสูง เราจะมีการแบ่งค่าต่างๆ ออกเป็นระดับ 3 ระดับ คือ ต่ำ ปานกลาง และ สูง แต่หากเป็นพีชชีลอจิกบุคคลที่มีความสูง 184 ซม. จะมีค่าความเป็นสมาชิกในระดับปานกลางอยู่ 0.1 และมีค่าสมาชิกในระดับสูงอยู่ 0.4 หมายความว่าความสูง 184 อยู่ในเซตหลายๆ เซต



รูปที่ 4-2 แสดงการทำฟัซซี่เซต (fuzzy set)

ฟัซซี่เซต (fuzzy set) คือ ค่าที่ใช้ในการแบ่งขอบเขตของฟัซซี่ เช่น

$$f_A(x) = \begin{cases} 1, & \text{if } x \in A \\ 0, & \text{if } x \notin A \end{cases}$$

ลึงกิตติก วาริเอเบิล (linguistic variable) คือ ค่าที่ใช้อธิบายค่าของฟัซซี่ลอจิก ว่ามีค่าเป็นเช่นใด บาง เป็นค่าที่แสดงอยู่ในฟัซซี่เซต เช่น ต่ำ ปานกลาง สูง

กฎของฟัซซี่ สามารถอธิบายเงื่อนไขของแต่ละอันในฟอร์ม เช่น

กฎข้อที่ 1

ถ้า ระดับความเร่งมีความเร็วสูง แล้ว ระยะการหยุดยาว

กฎข้อที่ 2

ถ้า ระดับความเร่งมีความเร็วต่ำ แล้ว ระยะการหยุดสั้น

4.1.2 วิธีการทำงานของฟัซซี่ลอจิก

ในการทำงานของฟัซซี่มีเทคนิคที่นำมาใช้งานอยู่ 2 รูปแบบคือ

- 1) **แมนดานิ สไตล์ (Mandani-style)** โดยมีขั้นตอนการทำงานแบ่งออกเป็น 4 ขั้นตอน คือ นำค่าอินพุตมาทำฟัซซี่ (fuzzification) คำนวณค่าจากกฎ (Rule evaluation) สรุปผลกฎต่างๆ ออกเป็นเอ้าท์พุต (aggregation of the rule outputs) ประมวลผลออกเป็นค่า (defuzzification)

ตัวอย่างของ Mandani-style

กำหนดให้ ปัญหาประกอบด้วย 2 อินพุต 1 เอาท์พุต และมี 3 กฎ

กฎข้อที่ 1

ถ้า $x = A3$ หรือ $y = B1$ แล้ว $z = C1$

ถ้า $x = A2$ หรือ $y = B2$ แล้ว $z = C2$

ถ้า $x = A1$ แล้ว $C3$

กฎข้อที่ 1

ถ้า น้ำหนักมาก หรือ คนสูงมาก แล้ว ตัวใหญ่

ถ้า น้ำหนักปานกลาง และ คนสูงปานกลาง แล้ว ตัวปานกลาง

ถ้า คนน้ำหนักน้อย แล้ว ตัวเล็ก

ขั้นตอนที่ 1 การทำฟัซซี่ (Fuzzification)

นำค่าอินพุตที่มีมากำหนดเป็นฟัซซี่

ขั้นตอนที่ 2 คำนวณหาค่าจากกฎ (Rule evolution)

$$\mu_{(x=A1)} = 0.5, \mu_{(x=A2)} = 0.2, \mu_{(y=B1)} = 0.1 \text{ และ } \mu_{(y=B2)} = 0.7$$

กฎข้อที่ 1

$$\mu_{C1}(z) = \max[\mu_{A3}(x), \mu_{B1}(y)] = \max[0.0, 0.1] = 0.1$$

หรือ

$$\mu_{C1}(z) = \text{probor}[\mu_{A3}(x), \mu_{B1}(y)] = 0.0 + 0.1 - 0.0 * 0.1 = 0.1$$

กฎข้อที่ 2

$$\mu_{C2}(z) = \min[\mu_{A2}(x), \mu_{B2}(y)] = \min[0.2, 0.7] = 0.2$$


หรือ

$$\mu_{C2}(z) = \text{prod}[\mu_{A2}(x), \mu_{B2}(y)] = 0.2 * 0.7 = 0.14$$

ขั้นตอนที่ 3 สรุปผลกฎต่างๆ ออกเป็นเอาท์พุต (Aggregation of the rule outputs)

ในการคำนวณผลเอาท์พุตแบ่งเป็น 2 ส่วนคือ แบบสเกล (Scale) และแบบเมมเบอร์ชิฟ ฟังก์ชัน

(membership function)



รูปที่ 4-3 แสดงการหาค่าเอาท์พุต ด้วยวิธีแบบสเกล และเมมเบอร์ชิฟ ฟังก์ชัน

ขั้นตอนที่ 4 ประมวลผลออกเป็นค่า (Defuzzification)


การทำฟัซซี่ทำให้สามารถคำนวณค่ามาจากกฎได้ อย่างไรก็ตามท้ายที่สุดแล้วผลที่ได้ก็ออกมาเป็นตัวเลขที่แน่นอนเพียงตัวเดียว เราเรียกรูปแบบนี้ว่า คีฟซซี่

โดยมีการหาค่า centre of gravity (COG) ดังนี้

$$COG = \frac{\int_a^b \mu_A(x) x \, dx}{\int_a^b \mu_A(x) \, dx}$$

ดังนั้นสามารถคำนวณค่าได้ดังนี้

$$COG = \frac{(0+10+20)*0.1+(30+40+50+60)*0.2+(70+80+90+100)*0.5}{0.1+0.1+0.1+0.2+0.2+0.2+0.2+0.5+0.5+0.5+0.5} = 67.4$$



รูปที่ 4-4 แสดงลำดับขั้นตอนการทำงานของ Mandani-style


2) สัจโน สไตล์ (Sugeno-style) มีขั้นตอนการทำงานเหมือนกับ Mandani-style จะแตกต่างกันในส่วนของการสรุปผลต่างๆออกเป็นเอาต์พุต โดยในการคำนวณเราจะหาค่าออกมาเป็นค่าน้ำหนักเฉลี่ย (weight average) มีหลักการคำนวณดังนี้

$$WA = \frac{\mu(k1)*k1 + \mu(k2)*k2 + \mu(k3)*k3}{\mu(k1) + \mu(k2) + \mu(k3)} = \frac{0.1*20 + 0.2*50 + 0.5*80}{0.1 + 0.2 + 0.5} = 65$$

4.1.3 เหตุผลในการเลือกวิธีใช้งานระหว่าง Mandani-style และ Sugeno-style

Mandani-style จะเป็นวิธีการที่นำมาใช้งานคาดเดาส่งที่ยังไม่ปรากฏ เช่น ฝนตก น้ำท่วม เป็นต้น รวมถึงความรู้ของมนุษย์

Sugeno-style จะเป็นการคำนวณค่าผลกระทบ และ ค่าการทำงาน ด้วยค่าที่ดีที่สุด หรือการพัฒนาเทคนิค ของการควบคุมปัญหา และแบ่งเป็นส่วนสำหรับการทำค่าที่เคลื่อนไหวโดยไม่เป็นเส้นตรง




รูปที่ 4-5 แสดงลำดับขั้นตอนการทำงานของ Sugeno-style

4.2 การเรียนรู้

อุปกรณ์ต่างๆ ที่นำคอมพิวเตอร์เข้าไปใช้งานเพื่อการเรียนรู้ นั้น จะเรียนรู้ได้โดยอาศัยประสบการณ์ ตัวอย่าง และ อนาล็อก (analog) การเรียนรู้ทำให้อุปกรณ์เพิ่มระดับความสามารถให้มากขึ้น โดยวิธีการที่นิยมในการนำมาใช้ในการเรียนรู้ คือ นิวรอนเน็ตเวิร์ค (Neural Network) และ เจนเนติก (Genetic algorithms) ในวิทยานิพนธ์ฉบับนี้จะขอล่าเฉพาะในส่วนของนิวรอนเน็ตเวิร์ค


4.2.1 นิวรอนเน็ตเวิร์ค (Neural Network)

นิวรอนเน็ตเวิร์ค เป็นการจำลองการทำงานของสมองมนุษย์มาเป็นรูปแบบการประมวลผลข้อมูล ปกติแล้วในสมองของมนุษย์จะประกอบด้วยเซลล์ประสาทจำนวนมาก ซึ่งทำงานอย่างอิสระ แต่ละเซลล์จะมีการเชื่อมต่อระหว่างกันเรียกว่า ซาแนฟ (Synapse) มีส่วนที่เป็นอินพุตของเซลล์ เรียกว่า ดิไรด์ (Dendrite) และส่วนที่เป็นเอาต์พุตเรียกว่า เอซอน (Axon) ซึ่งการติดต่อทำได้โดยการสร้างความต่างศักย์ (Voltage) ซึ่งถือว่าเซลล์ประสาทเหล่านี้เป็นหน่วยย่อยที่สุดในการทำงานของสมองซึ่งการทำงานจะเป็นไปในลักษณะที่สัญญาณประสาทถูกส่งต่อกันไปเป็นทอดๆ จากเซลล์หนึ่งไปยังอีกเซลล์หนึ่ง โดยแต่ละเซลล์จะทำหน้าที่ในการคำนวณในส่วนย่อย และมีการเชื่อมต่อถึงกันที่ซับซ้อนเพื่อให้ได้ผลการคำนวณที่ต้องการ



รูปที่ 4-6 แสดงรูปทางชีววิทยาของสมอง


ข้อดี ของการทำงานแบบนี้ คือ เราไม่จำเป็นต้องทราบถึงรูปแบบการคำนวณที่แน่นอน แต่ปล่อยให้มันเป็นหน้าที่ของกระบวนการเรียนรู้ ที่จะทำหน้าที่สร้างรูปแบบการคำนวณที่ใกล้เคียงกับการคำนวณค่าที่ถูกต้องขึ้นมา โดยอาศัยการปรับค่าที่อยู่ภายในหน่วยย่อย หรือ ค่าที่บริเวณจุดเชื่อมต่อระหว่างหน่วยย่อยเหล่านี้ว่าจะให้อินพุต ใดมีความสำคัญเท่าไร เมื่อนำมาใช้ในทางคอมพิวเตอร์ เราจึงสร้างหน่วยประมวลผลซึ่งมีลักษณะคล้ายเซลล์ประสาท โดยให้แต่ละหน่วยประกอบด้วยส่วนอินพุต ที่มีค่าน้ำหนัก (Weight) อยู่เพื่อระบุค่าความสำคัญของอินพุตนั้นๆ ภายในจะมีการประมวลผลโดยส่วนแรกจะนำค่าอินพุตทั้งหมดมารวมกัน จากนั้นจึงนำไปแทนค่าในแอคทีเวชัน ฟังก์ชัน (Activation Function) แล้วได้ออกมาเป็นเอาต์พุต



รูปที่ 4-7 แสดงไดอะแกรมของนิวรอนเน็ตเวิร์ค

แอ็คติเวชัน ฟังก์ชัน (Activation Function) นำมาใช้ในการแยกประเภทการจดจำของงานนั้น โดยมีรูปแบบดังนี้

- สะเท็ป (Step function) และ ซายฟังก์ชัน (Sign function) ถูกเรียกว่า ฮาร์ดลิมิตฟังก์ชัน (Hard-limit function) คือ มักจะถูกใช้ในการตัดสินใจของนิวรอนเน็ตเวิร์ค ในการแยกประเภท และการจดจำรูปแบบ
- ซิกมอย ฟังก์ชัน (Sigmoid function) ใช้กับอินพุตที่มีค่าระหว่างค่าบวก ถึงอินฟินิตี้ (α) และมีค่าเอาต์พุตอยู่ระหว่าง 0-1 ฟังก์ชันนี้จะถูกใช้ใน แบ็กโพรพาเกชัน นิวรอนเน็ตเวิร์ค (Back Propagation Network)
- ลีเนียร์แอ็คติเวชัน (linear activation function) ใช้กลับค่าที่มีเอาต์พุตเท่ากับค่าน้ำหนัก (Weight) ของนิวรอนในส่วนอินพุต มักจะใช้ในการจัดการค่าประมาณ




รูปที่ 4-8 แสดงแอ็คติเวชัน ฟังก์ชัน (Activation Function)

4.2.2 รูปแบบการใช้งานนิวรอนแบบต่างๆ

มัลติ เลเยอร์ เพอร์เซปตรอน เน็ตเวิร์ค (Multi-layered perceptron Network) เน็ตเวิร์คแบบนี้ จะมีลักษณะแบ่งออกเป็นชั้น (Layer) ซึ่งประกอบไปด้วย อินพุต ยูนิคต์ (Input units) เอาท์พุต ยูนิคต์ (Output units) ยูนิคต์ และ ไฮเดน ยูนิคต์ (Hidden units) ซึ่งจำนวนชั้นของ ไฮเดน (Hidden units) จะแตกต่างกันไปตามความซับซ้อนของการคำนวณที่ใช้กล่าวคือ ยิ่งการคำนวณซับซ้อนมาก ก็ต้องมีชั้นของ ไฮเดน ยูนิคต์ (Hidden units) มากขึ้น ข้อมูลที่รับเข้ามาทาง อินพุตยูนิคต์ นั้นจะถูกผ่านไปให้แต่ละหน่วยประมวลผลที่อยู่ในชั้นเดียวกันเพื่อทำการประมวลผล และสัญญาณเหล่านี้จะถูกส่งผ่านไปเรื่อยๆ สู่ชั้นถัดไป ซึ่งจะมีการให้ค่าความสำคัญ (Weight) ของอินพุตที่รับเข้ามาจากหน่วยต่างๆ แตกต่างกันไป และสัญญาณจะถูกส่งต่อระหว่างชั้นไปเรื่อยๆ จนกระทั่งไปถึงเอาท์พุตยูนิคต์ซึ่งจะส่งผลลัพธ์ที่ได้ออกมาโดยค่าน้ำหนักของอินพุตต่างๆ นั้น จะถูกปรับโดยวิธีการเรียนรู้ (Learning) โดยวิธีการเรียนรู้ ก็คือ การนำข้อมูลที่ทราบผลลัพธ์ แล้วมาใช้เป็นอินพุต และเปรียบเทียบค่าเอาท์พุตที่ได้กับผลลัพธ์หาค่าความผิดพลาด


จากนั้นจึงนำค่าความผิดพลาดที่ได้มาทำการปรับน้ำหนัก (Weight) ภายใน Neural Network ซึ่งวิธีการปรับค่านี้นั้นขึ้นอยู่กับวิธีการเรียนรู้ที่เลือกใช้ ซึ่งวิธีการเรียนรู้นั้นมีหลายรูปแบบขึ้นกับการออกแบบโครงสร้างภายในของ นิวรอน เน็ตเวิร์คและประเภทของงานที่นำไปใช้



รูปที่ 4-9 แสดงการทำงานหลายเลเยอร์

แบ็กโพรพาคชัน (Back-propagation neural network) เป็นวิธีการเรียนรู้รูปแบบหนึ่ง ซึ่งเป็นที่นิยมใช้ โดยอาศัยหลักการกระจายความรับผิดชอบต่อความผิดพลาดออกไปยังหน่วยย่อยทุกหน่วยใน เน็ตเวิร์ค เท่าๆ กัน โดยจะกระจายความผิดพลาดลงไปในแต่ละระดับชั้น ซึ่งจะสังเกตได้ว่าใน มัลติเลเยอร์ เพอร์เซปตรอน (Multi-layered perceptron Network) นั้น ค่าที่ได้จากแต่ละระดับชั้นจะส่งผลกระทบถึง

ระดับชั้นถัดไป ในลักษณะของการยกกำลัง ดังนั้นการกระจายความผิดพลาดจากระดับชั้นหลังไปสู่ระดับชั้นต้นๆ นั้นจำเป็นต้องใช้หลักการอินทิเกรต เพื่อให้ได้อัตราความผิดพลาดที่เกิดขึ้นในระดับชั้นนั้น



รูปที่ 4-10 แสดงการทำงานของแบ็กโพรพาคชัน (Back-propagation neural network)

วิธีการเรียนรู้ของแบ็กโพรพาคชัน นิวรอนเน็ตเวิร์ค (Back-propagation neural network)

1. สร้างค่าน้ำหนัก (Weight) และค่ากำหนดขอบเขต (Threshold) โดยค่าทั้งสองจะเป็นค่าที่สุ่มขึ้นมาระหว่าง

$$\left(-\frac{2.4}{F_i}, +\frac{2.4}{F_i} \right)$$

โดยค่า F คือจำนวนอินพุตของนิวรอน I ในเน็ตเวิร์ค

2. ประมวลผล

คำนวณค่าเอาต์พุตจริงของนิวรอนในไฮเดนเลเยอร์

$$y_j(p) = \text{sigmoid} \left[\sum_{i=1}^n x_i(p) \cdot w_{ij}(p) - \theta_j \right]$$

โดยที่ n คือ จำนวนอินพุต j ในไฮเดนเลเยอร์ และ sigmoid

คำนวณค่าเอาต์พุตจริงของนิวรอนในเอาต์พุตเลเยอร์

$$y_k(p) = \text{sigmoid} \left[\sum_{j=1}^m x_{jk}(p) \cdot w_{jk}(p) - \theta_k \right]$$

โดยที่ m คือ จำนวนอินพุตของนิวรอน k ใน เอาท์พุทเลเยอร์

3. เรียนรู้ซ้ำ

ปรับค่าน้ำหนักใน แบ็กโพรพเกชัน เน็ตเวิร์ค ค่าผิดพลาดจะเกี่ยวข้องกับเอาท์พุตนิวรอน

คำนวณค่าผิดพลาดเกเดียน (error gradient) จากนิวรอนในเอาท์พุทเลเยอร์

$$\delta_k(p) = y_k(p) \cdot [1 - y_k(p)] \cdot e_k(p)$$

โดย

$$e_k(p) = y_{d,k}(p) - y_k(p)$$

คำนวณค่าผิดพลาดเกเดียน (error gradient) จากนิวรอนในไฮเดนเลเยอร์

$$\delta_j(p) = y_j(p) \cdot [1 - y_j(p)] \cdot \sum_{k=1}^l \delta_k(p) w_{jk}(p)$$

คำนวณหาค่าน้ำหนักจริง


$$\Delta w_{ij}(p) = \alpha \cdot x_i(p) \cdot \delta_j(p)$$

ปรับค่าน้ำหนักที่ไฮเดน นิวรอน

$$w_{ij}(p+1) = w_{ij}(p) + \Delta w_{ij}(p)$$

4. ทำซ้ำ

เพิ่มค่า p ขึ้นอีกหนึ่ง และกลับไปเริ่มทำลำดับที่ 2 ใหม่ ทำจนกระทั่งค่าผิดพลาด พอใจ



รูปที่ 4-11 ตัวอย่างการทำงานโดยใช้ 3 เลเยอร์

อัตราความเร็วของการเรียนรู้ขึ้นอยู่กับตัวแปร α ซึ่งหากมีค่ามากจะทำให้ค่าภายในนิวรอนเน็ตเวิร์ก เปลี่ยนแปลงไปอย่างรวดเร็วระหว่างการเรียนรู้ แต่ก็มีข้อเสียคือจะทำให้ค่าที่ได้ไม่ละเอียดซึ่งทำให้ผลการทำงานของนิวรอนเน็ตเวิร์กผิดพลาด ไม่เที่ยงตรงได้ ในกรณีที่เรำใช้ค่า α ไม่มากนัก อาจทำให้ในการทำแบ็กโพรพาเกชันที เพียงรอบเดียวไม่สามารถปรับค่าให้ถูกต้องได้ ดังนั้นส่วนใหญ่ในการเรียนรู้แต่ละครั้งนั้น จะเป็นการทำ Back Propagation หลายๆ รอบกับข้อมูลกลุ่มเดิม โดยยังค่า α ค่าจำนวนรอบในการทำงานก็ยิ่งต้องเพิ่มมากขึ้น นอกจากนี้ปริมาณและการกระจายตัวของข้อมูลตัวอย่างที่ใช้ในการเรียนรู้ (Training Set) นั้นก็เป็นสิ่งสำคัญที่มีผลต่อการเรียนรู้มาก ข้อมูลที่นำมาใช้เป็นตัวอย่างในการเรียนรู้จำเป็นต้องเป็นข้อมูลที่เป็นมาตรฐานตามปกติ ไม่ใช่ข้อมูลที่มีรูปแบบโครงสร้างที่ผิดไปจากข้อมูลปกติ นอกจากนี้ต้องมีจำนวนมากพอที่ จะทำให้มีรูปแบบที่หลากหลายพอที่จะครอบคลุมถึงลักษณะปกติของข้อมูลที่จะทำการวิเคราะห์ได้หมด