

บทที่ 3

กระบวนการค้นหารูปภาพโดยใช้เสิร์จเอนจิน

3.1 โครงสร้างฐานข้อมูล

แบ่งเป็น 2 ตาราง (table) คือ table_image และ table_link ดังนี้

3.1.1 table_image

id	urlimage	histogram	date	chis
1	http://www.postgang.com/prekapook/thumb/55.jpg	[1, 0, 0, 0, 0, 0, 0, 0, ...]	2006-02-15	1
2	http://www.kapook.com/images/wantjob2.jpg	[10, 0, 0, 0, 0, 0, 0, 0, ...]	2006-02-15	1
3	http://www.kapook.com/images2/chomsoan.jpg	[43, 0, 0, 0, 0, 0, 0, 0, ...]	2006-02-15	1
4	http://guide.kapook.com/images2/kb.jpg	[0, 0, 0, 0, 0, 0, 0, 0, ...]	2006-02-15	1
5	http://www.kapook.com/images2/banmanda.jpg	[2, 0, 0, 0, 0, 0, 2, 0, ...]	2006-02-15	1
6	http://www.kapook.com/images2/chang.jpg	[11, 4, 0, 0, 0, 1, 0, 0, ...]	2006-02-15	1
7	http://www.kapook.com/images2/sonywalkman00001.jpg	[18, 0, 0, 0, 0, 0, 0, 0, ...]	2006-02-15	1
8	http://www.kapook.com/google/images/photo001.jpg	[0, 0, 0, 0, 0, 0, 0, 0, ...]	2006-02-15	1
9	http://www.kapook.com/images/mo.jpg	[0, 0, 0, 0, 0, 0, 0, 0, ...]	2006-02-15	1
10	http://www.kapook.com/images/alive2bthumb.jpg	[9, 0, 0, 0, 0, 0, 4, 0, ...]	2006-02-15	1
...				

ตารางที่ 3.1 ตัวอย่างตาราง table_image ที่เก็บ id, url, ค่าฮิสโตแกรม, วันที่ และ flag ของแต่ละภาพ โดย

- id - เป็นฟิลด์ตัวเลขที่เป็น auto increment เพื่อกำหนดหมายเลขของภาพ เช่น 1, 2, 3, ... จะมีขนาดเท่ากับจำนวนภาพที่มีอยู่ทั้งหมดในฐานข้อมูล
- urlimage - เป็นฟิลด์ชื่อของลิงค์ที่เป็นที่อยู่ของภาพในเครือข่ายอินเทอร์เน็ต
- histogram - เป็นฟิลด์ตัวเลขที่ใช้เก็บค่าฮิสโตแกรมของแต่ละภาพ
- date - เป็นฟิลด์ที่แสดงวันที่ทำการเก็บภาพมา
- chis - เป็นฟิลด์ที่ใช้เพื่อทำการเช็คค่าฮิสโตแกรมแล้วหรือไม่

* ใช้ id และ urlimage เป็น Primary Key ร่วมกัน

3.1.2 table_link



id	urllink	date
1	http://my.kapook.com	2006-02-15
2	http://mobile.kapook.com	2006-02-15
3	http://bangkok.kapook.com	2006-02-15
4	http://guide.kapook.com	2006-02-15
5	http://gamecenter.kapook.com	2006-02-15
6	http://radio.prettygang.com	2006-02-15
7	http://picpost.kapook.com	2006-02-15
8	http://music.kapook.com	2006-02-15
9	http://download.kapook.com	2006-02-15
10	http://event.kapook.com	2006-02-15
...		

ตารางที่ 3.2 ตัวอย่างตาราง table_link ที่เก็บ id, urllink และวันที่เก็บของแต่ละลิงค์

โดย

- id - เป็นฟิลด์ตัวเลขที่เป็น auto increment เพื่อกำหนดหมายเลขของลิงค์ย่อยที่อยู่ภายในลิงค์หลัก
- urllink - เป็นฟิลด์ของชื่อลิงค์ย่อยที่อยู่ภายในลิงค์หลัก
- date - เป็นฟิลด์ที่แสดงวันที่เข้าสู่ลิงค์นั้นมา

* ใช้ id และ urllink เป็น Primary Key ร่วมกัน

3.1.3 table_id_proces



id	start	stop
1	0	0
2	1	100
3	101	200
4	201	300
5	301	400
6	401	500
7	501	600
8	601	700
9	701	800
10	801	900
...		


ตารางที่ 3.3 ตัวอย่างตาราง table_id_process ที่เก็บค่าโปรเซสที่ทำงานกับ urlimage เพื่อประสานการทำงานระหว่างกัน

โดย

- id - เป็นฟิลด์ตัวเลขที่เป็น auto increment เพื่อกำหนดหมายเลขของโปรเซสที่ทำงานจัดการกับภาพ
- start - เป็นฟิลด์ตัวเลขที่เก็บ id ของภาพเริ่มต้น ที่แต่ละโปรเซสทำงาน
- stop - เป็นฟิลด์ตัวเลขที่เก็บ id ของภาพสุดท้าย ที่แต่ละโปรเซสทำงาน

3.2 การออกแบบและพัฒนาระบบค้นหารูปภาพโดยใช้เว็บเสิร์จเอนจิน

จะทำงานในด้านของเครื่องเซิร์ฟเวอร์โดยใช้โปรแกรม Web crawler ที่พัฒนาขึ้นมาด้วย ภาษา Python ทำการกำหนดเว็บไซต์ที่ต้องการเข้าไปค้นหา และเก็บรูปภาพลงไปด้วยโปรแกรมจะทำงานโดยอัตโนมัติซึ่งจะตรวจสอบข้อผิดพลาดของเว็บไซต์นั้น โดยเริ่มจากโปรแกรมแรกจะทำหน้าที่หา URL ซึ่งเป็นลิงค์ไปยังหน้าอื่นๆ นั่นคือเมื่อพบ tag ที่เป็นโค้ดของลิงค์ก็จะทำการตัดเอาส่วนของ URL ของลิงค์นั้นไปเก็บไว้ในฐานข้อมูล ซึ่งจะเก็บไปเรื่อยๆจนกระทั่งหมดหน้านั้น จากนั้นก็จะทำการเข้าไปยังหน้าถัดไปโดยเลือกจากค่า URL ที่เก็บไว้ในฐานข้อมูล ซึ่งจะทำให้การเก็บข้อมูลไปเรื่อยๆตามข้อมูลในฐานข้อมูล จากนั้นโปรแกรมที่สองจะเริ่มทำงานโดยทำการเลือก URL จากฐานข้อมูลเพื่อเข้าไปยังหน้านั้นๆแล้วทำการค้นหารูปภาพ นั่นคือเมื่อพบ tag ที่เป็นโค้ดของไฟล์รูปภาพก็จะทำการตัดเอาเฉพาะส่วนที่เป็น URL ของรูปภาพนั้น ด้วยการใช้ Regular Expression จากนั้นจะทำการเก็บข้อมูลรูปภาพไว้ในฐานข้อมูล จากนั้นโปรแกรมที่สามจะเริ่มทำงานโดยการเลือกรูปภาพจากฐานข้อมูล เพื่อนำมาเข้าฟังก์ชันการหาค่าฮิสโตแกรมของภาพ ทั้งนี้จะบันทึกวันที่เก็บข้อมูลต่างๆลงในฐานข้อมูลด้วยเพื่อใช้ในการอัปเดตข้อมูลในภายหลัง ส่วนโปรแกรมที่สี่เพื่อให้ผู้เข้ามาทำการค้นหารูปภาพผ่านทางเว็บ ซึ่งพัฒนาด้วย PHP ร่วมกับ Python โดยใช้รูปภาพเป็นอินพุตเพื่อไปหาค่าฮิสโตแกรมจากนั้นจะไปค้นหาภาพในฐานข้อมูลที่มีค่าฮิสโตแกรมคล้ายกัน แล้วแสดงผลออกมาเป็นลิงค์ของภาพและภาพจากฐานข้อมูล ซึ่งแสดงขั้นตอนต่างๆไว้ดังนี้



รูปที่ 3.1 ขั้นตอนการทำงานของโปรแกรมอิมเมจเสิร์จเอนจิน

3.2.1 การทำงานของโปรแกรม Web crawler ที่ใช้ในการเก็บลิงค์

ขั้นตอนที่ 1 โปรแกรมทำการอ่านค่า URL ที่อยู่ใน textfile

ขั้นตอนที่ 2 ทำการเช็ค URL ที่อ่านมาสามารถเปิดได้หรือไม่ เว็บเพ็จนั้นปิดไปแล้วหรือไม่ ถ้าไม่สามารถเปิดได้ก็จะจบฟังก์ชันการทำงาน จากนั้นโปรแกรมก็จะกลับไปอ่านค่า URL ใน textfile อีกครั้งหนึ่ง

ขั้นตอนที่ 3 เปิดหน้าเว็บเพ็จนั้นขึ้นมาและทำการเช็คการ match regular expression ในตอนแรก ต้อง import re ซึ่งเป็น library ของภาษา Python ที่ใช้เรียกใช้งาน Regular Expression และเพื่อที่จะได้ส่วน URL ที่เราต้องการโดยการที่เราต้องใช้ฟังก์ชัน match ค่าของ Regular Expression คือ `re.compile("""href="(\\S+)[\\/[a-zA-Z0-9-\\_]+](\\.php|.com|.shtml|.html|.htm|.cgi|.th)*(\\/*)" """, re.IGNORECASE)` โดยที่ `""\"href="(\\S+)[\\/[a-zA-Z0-9-\\_]+](\\.php|.com|.shtml|.html|.htm|.cgi|.th)*(\\/*)" ""\"` เป็น pattern ที่เราต้องการจะ match ลิงค์ย่อยในหน้าเว็บเพ็จนั้น คือ href ในภาษา HTML โดยเราต้องสร้าง pattern นี้ขึ้นมาเอง ต่อมาจึงต้องค้นหา pattern ที่ต้องการในหน้าเว็บเพ็จนั้น โดยการใช้ฟังก์ชัน search ค้นหา `re.search(<pattern>, line)` โดยที่ `<pattern>` เป็น pattern ที่ต้องการค้นหา และ `line` เป็นส่วนที่จะทำการค้นหาในแต่ละบรรทัดในซอสโค้ดของหน้าเว็บเพ็จนั้น เพื่อหาลิงค์ย่อยๆที่อยู่ในหน้าเว็บเพ็จนั้นที่ต้องการ

ขั้นตอนที่ 4 ได้ผลลัพธ์เป็น URL ลิงค์ที่ต้องการแล้วนำไปเก็บในฐานข้อมูล

ขั้นตอนที่ 5 ทำการเช็คในฐานข้อมูลว่า URL ลิงค์นั้นเคยมีในฐานข้อมูลแล้วหรือไม่ ถ้าเคยมีแล้วก็จะกลับไปทำขั้นตอนที่ 3 อีกครั้งเพื่อหา URL ลิงค์ในบรรทัดต่อไปของซอสโค้ดในหน้าเว็บเพ็จนั้น ถ้ายังไม่เคยมีก็จะทำการเก็บลงในฐานข้อมูล

ขั้นตอนที่ 6 ทำการดูในซอสโค้ดในหน้าเว็บเพ็จนั้นว่าจบหน้าแล้วหรือไม่ ถ้าจบแล้วก็จะจบฟังก์ชันการทำงาน ถ้ายังไม่จบก็จะกลับไปขั้นตอนที่ 3 อีกครั้ง

3.2.2 การทำงานของโปรแกรม Web crawler ที่ใช้ในการเก็บลิงค์ในระดับถัดไป

ขั้นตอนที่ 1 โปรแกรมจะทำการอ่านค่า URL จากฐานข้อมูลในตาราง table_link

ขั้นตอนที่ 2 ทำการเช็คค่า URL ที่อ่านมาสามารถเปิดได้หรือไม่เว็บเพจนั้นปิด

ไปแล้วหรือไม่ ถ้าไม่สามารถเปิดได้ก็จะจบฟังก์ชันการทำงาน แล้วโปรแกรมก็จะกลับไปอ่านค่า URL จาก table_link อีกครั้ง


ขั้นตอนที่ 3 เปิดหน้าเว็บเพจนั้นขึ้นมาและทำการเช็คการ match regular

expression ในตอนแรก ต้อง import re ซึ่งเป็น library ของภาษา Python ที่ไว้เรียกใช้งาน Regular Expression และเพื่อที่จะได้ส่วน URL ที่ต้องการต้องใช้ฟังก์ชัน match คำของ Regular Expression คือ `re.compile("""href=(|")([S+]*[^\a-zA-Z0-9-_]+)*(.php|.com|.shtml|.html|.htm|.cgi|.th)*( |)*("|)""", re.IGNORECASE)` โดยที่ `""href=(|")` `[S+]*[^\a-zA-Z0-9-_]+)` `(.php|.com|.shtml|.html|.htm|.cgi|.th)*( |)*(|)""` เป็น pattern ที่ต้องการจะ match ลิงค์ย่อยในหน้าเว็บเพจนั้น คือ href ในภาษา HTML โดยต้องสร้าง pattern นี้ขึ้นมาเอง ต่อมาต้องค้นหา pattern ที่ต้องการในหน้าเว็บเพจนั้นโดยการใช้ฟังก์ชัน search ค้นหา `re.search(<pattern>, line)` โดยที่ `<pattern>` เป็น pattern ที่ต้องการค้นหา และ `line` เป็นส่วนที่จะทำการค้นหาในแต่ละบรรทัดในซอสโค้ดของหน้าเว็บเพจนั้น เพื่อหาลิงค์ย่อยๆที่อยู่ในหน้าเว็บเพจนั้นที่ต้องการ

ขั้นตอนที่ 4 ได้ผลลัพธ์เป็น URL ลิงค์ ที่ต้องการจากนั้นจะนำไปเก็บในฐานข้อมูล

ขั้นตอนที่ 5 ทำการเช็คในฐานข้อมูล ว่า URL ลิงค์นั้นเคยมีในฐานข้อมูล แล้วหรือไม่ ถ้าเคยมีแล้วก็จะกลับไปทำขั้นตอนที่ 3 อีกครั้งเพื่อหา URL ลิงค์ในบรรทัดต่อไปของซอสโค้ดในหน้าเว็บเพจนั้น ถ้ายังไม่เคยมีก็จะทำการเก็บลงในฐานข้อมูล

ขั้นตอนที่ 6 ทำการดูในซอสโค้ดในหน้าเว็บเพจนั้นว่าจบหน้าแล้วหรือไม่ ถ้าจบแล้วก็จะจบฟังก์ชันการทำงาน ถ้ายังไม่จบก็จะกลับไปขั้นตอนที่ 3 อีกครั้ง



รูปที่ 3.3 ขั้นตอนการทำงานของโปรแกรม Web crawler ที่ใช้ในการเก็บลิงค์ในระดับถัดไป

3.2.3 การทำงานของโปรแกรม Web crawler ที่ใช้ในการเก็บ ลิงค์ ของรูปภาพ

ขั้นตอนที่ 1 โปรแกรมทำการอ่านค่า URL ลิงค์จากฐานข้อมูลในตาราง table_link

ขั้นตอนที่ 2 ทำการเช็คค่า URL ที่อ่านมาสามารถเปิดได้หรือไม่เว็บเพจนั้นปิด

ไปแล้วหรือยัง ถ้าไม่สามารถเปิดได้ก็จะจบฟังก์ชันการทำงาน แล้วโปรแกรมก็จะกลับไปอ่านค่า URL จาก table_link อีกครั้ง

ขั้นตอนที่ 3 เปิดหน้าเว็บเพจนั้นขึ้นมาและทำการเช็คการ match Regular

expression ในตอนแรก ต้อง import re ซึ่งเป็น library ของภาษา Python ที่ไว้เรียกใช้งาน Regular Expression และเพื่อที่จะได้ส่วน URL ที่ต้องการโดยการใช้ฟังก์ชัน match คำของ Regular Expression คือ `re.compile("src=(\"|\")*[\\S+]*[\\/[a-zA-Z0-9-_]+*(.jpg|.bmp)(/)*(\"|\")*\"", re.IGNORECASE)` โดยที่ pattern นี้ `"src=(\"|\")*[\\S+]*[\\/[a-zA-Z0-9-_]+*(.jpg|.bmp)(/)*(\"|\")*\""` เป็น pattern ที่ต้องการจะ match ลิงค์รูปภาพในหน้าเว็บเพจนั้น คือ src ในภาษา HTML โดยต้องสร้าง pattern นี้ขึ้นมาเอง ต่อมาทำการ search หา pattern ที่ต้องการในหน้าเว็บเพจนั้นโดยการใช้ฟังก์ชัน search ค้นหา `re.search(<pattern>, line)` โดยที่ `<pattern>` เป็น pattern ที่ต้องการค้นหา และ line เป็นส่วนที่จะทำการค้นหาในแต่ละบรรทัดในซอสโค้ดของหน้าเว็บเพจนั้นเพื่อหาลิงค์รูปภาพที่อยู่ในหน้าเว็บเพจที่ต้องการ


ขั้นตอนที่ 4 ได้ผลลัพธ์เป็น urlimage ที่ต้องการจากนั้นทำการเก็บในฐานข้อมูล

ขั้นตอนที่ 5 ทำการเช็คในฐานข้อมูล ว่า urlimage นั้นเคยมีในฐานข้อมูลแล้ว

หรือไม่ ถ้าเคยมีแล้วก็จะกลับไปทำขั้นตอนที่ 3 อีกครั้งเพื่อหา urlimage ในบรรทัดต่อไปของซอสโค้ดในหน้าเว็บเพจนั้น ถ้ายังไม่เคยมีก็จะทำการเก็บลงในฐานข้อมูล

ขั้นตอนที่ 6 ทำการเช็คในซอสโค้ดในหน้าเว็บเพจนั้นว่าจบหน้าแล้วหรือยัง

ถ้าจบแล้วก็จะจบฟังก์ชันการทำงาน ถ้ายังไม่จบก็จะกลับไปขั้นตอนที่ 3 อีกครั้ง



รูปที่ 3.4 ขั้นตอนการทำงานของโปรแกรม Web crawler ที่ใช้ในการเก็บลิงค์ของรูปภาพ


3.2.4 การคำนวณหาค่าฮีสโตแกรมของภาพ

ขั้นตอนที่ 1 โปรแกรมอ่านค่า url image จากฐานข้อมูลในตาราง table_image

ขั้นตอนที่ 2 ทำการเช็คค่า URL ที่อ่านมาสามารถเปิดได้หรือไม่เว็บเพจนั้นปิดไปแล้วหรือไม่ ถ้าไม่สามารถเปิดได้ก็จะจบฟังก์ชันการทำงาน จากนั้นโปรแกรมก็จะกลับไปอ่านค่า URL จาก table_image อีกครั้ง

ขั้นตอนที่ 3 อ่านค่าจาก urlimage และนำไปเข้าฟังก์ชันฮีสโตแกรม เมื่อได้ค่ามาก็จะจัดเก็บลงฐานข้อมูล

ขั้นตอนที่ 4 โปรแกรมทำการตรวจสอบฐานข้อมูล ใน table_image ว่ามีรูปภาพใดที่ยังไม่ได้เข้าฟังก์ชันฮีสโตแกรม




รูปที่ 3.5 ขั้นตอนการทำงานของโปรแกรมที่ใช้ในการหาคำนวณค่าฮีสโตแกรมของภาพ

3.3 การค้นหารูปภาพของผู้ใช้

จากเครื่องผู้ใช้งานจะทำการเลือกรูปภาพจากเครื่องของตนเป็นอินพุตผ่านทางหน้าเว็บเพื่อใช้ค้นหาว่ามีภาพที่เหมือนกันหรือคล้ายกันในเครือข่ายอินเทอร์เน็ตหรือไม่ จากนั้นจะทำการอัปโหลดไฟล์รูปภาพดังกล่าวขึ้นมาที่เครื่องเซิร์ฟเวอร์แล้วจึงนำไปเข้าฟังก์ชันการหาค่าฮิสโตแกรมของภาพและทำการค้นหาในฐานข้อมูล โดยที่กำหนดให้ค่า differential ในการหาภาพที่มีลักษณะสีในแต่ละแบบคล้ายกันได้ มีค่าต่างกันได้ ± 5 ค่า โดยจะเปรียบเทียบค่าฮิสโตแกรมทีละค่าถ้าหากว่ามีค่าต่างกันเกิน ± 5 ก็จะทำให้การข้ามไปเปรียบเทียบภาพอื่นต่อไป ถ้าพบจะแสดงลิงค์ของภาพดังกล่าวและภาพที่อยู่ตำแหน่งนั้นขึ้นมา แต่ถ้าหากไม่พบจะแจ้งให้ทราบ ซึ่งแสดงขั้นตอนต่างๆ ไว้ดังรูปที่

3.6



รูปที่ 3.6 ขั้นตอนการทำงานผู้ใช้งานในการค้นหารูปภาพ

3.4 ทดสอบหาค่าฮิสโตแกรมจากภาพต่างๆ


ในการทดสอบหาค่าฮิสโตแกรมจากภาพต่างๆนั้นได้ใช้โปรแกรมการหาค่าฮิสโตแกรมที่พัฒนาด้วยภาษา Python ร่วมกับ Python Image Library (PIL) ซึ่งเป็นไลบรารีที่เพิ่มความสามารถด้านอิมเมจโปรเซสซิ่ง จากนั้นเลือกรูปภาพตัวอย่างมา 5 ภาพ โดยในแต่ละภาพมีองค์ประกอบของภาพต่างกันพอสมควร โดยแต่ละภาพมีขนาดภาพ 600 x 400 และขนาดของไฟล์ภาพประมาณ 40-80 KB ซึ่งเป็นขนาดที่ใกล้เคียงกับภาพในเครือข่ายอินเทอร์เน็ต โดยจะนำภาพตัวอย่างมาย่อขนาดให้มีขนาดต่างๆ ดังนี้ 75%, 50%, 10% และภาพที่มีการหมุนไป 90° มาหาค่าฮิสโตแกรมโดยได้ค่า ซึ่งจากการทดสอบจะเห็นว่าค่าฮิสโตแกรมของภาพในชุดทดลองเดียวกันจะมีค่าที่ใกล้เคียงกัน นั่นคือ ลักษณะสีของแต่ละภาพจะมีความใกล้เคียงกันในทุกๆ ลักษณะสี ซึ่งจะต่างกันเพียงไม่กี่ค่าเปอร์เซ็นต์ ทำให้สามารถหาความคล้ายของภาพได้จากการหาค่าความต่างกัน (differential) ของค่าลักษณะสีที่เหมาะสม ซึ่งจากข้อมูลที่ได้นี้จะนำไปพัฒนาเป็นกระบวนการค้นหารูปภาพต่อไป โดยข้อมูลดังกล่าวจะแสดงดังตารางข้างล่าง

3.5 ส่วนหน้าจอของผู้ใช้

IMAGE SEARCH ENGINE

Select your image to search :

รูปที่ 3.7 หน้าแรกที่เป็นหน้าจอเพื่อให้ผู้ใช้งานทำการเลือกไฟล์รูปภาพที่จะทำการค้นหา



รูปที่ 3.8 ผู้ใช้ทำการเลือกไฟล์รูปภาพ

SEARCH RESULT:

Your Picture	
	
Source	Picture
http://img61.imageshack.us/img61/834/cvicm4zj.jpg	
http://img239.imageshack.us/img239/8683/cvic5wz.jpg	
http://img141.imageshack.us/img141/8350/cvics3qz.jpg	
	

รูปที่ 3.9 ถ้าค้นพบรูปภาพที่มีค่าลักษณะเฉพาะที่เหมือนกันจะแสดง URL ของภาพและภาพออกมา

Search Results:

no match found

รูปที่ 3.10 เมื่อรูปภาพที่ใช้ค้นหาไม่พบรูปภาพที่มีลักษณะเฉพาะเหมือนกันในฐานข้อมูล

Your file is too big, please reduce size DSCF0843.JPG

รูปที่ 3.11 ถ้าหากไฟล์รูปภาพที่เลือกมีขนาดเกิน 1Mb จะแจ้งว่าไฟล์มีขนาดใหญ่เกินไป

Cannot search, please check your file

รูปที่ 3.12 ถ้าหากกดปุ่ม Search โดยไม่ได้เลือกไฟล์จะแจ้งให้ทราบ