

บทที่ 3

รูปแบบการเก็บข้อมูล

โครงการระบบสืบค้นวิทยานิพนธ์ (THESIS ONLINE) นี้คณะผู้จัดทำโครงการนี้ได้ใช้ภาษา ASP.NET เป็นตัวพัฒนาระบบ และได้ใช้ SQL SERVER 2005 ของ Microsoft เป็นตัวจัดการฐานข้อมูล ซึ่งมีคุณสมบัติในการเก็บข้อมูลในรูปแบบที่เป็น XML โดยการเก็บข้อมูลได้นำเอาหลักการของ Dublin Core Metadata มาใช้ในการออกแบบ

3.1 Metadata

Metadata เกิดขึ้นมาเมื่อ 15 ปีที่แล้ว เมื่อประมาณกลางปี 1990 ซึ่งคำว่า Metadata นี้จะใช้คำนี้ใน 3 ลักษณะด้วยกัน คือ Content, Context และ Structure

การเรียกใช้ Metadata นั้นก็จะเรียกแตกต่างกันออกไป บางคนเรียกว่า Dublin Core-Metadata แต่บางคนเรียก Metadata Dublin Core ทั้งนี้คำว่า Dublin มาจากชื่อเมืองๆ หนึ่งในรัฐไอโอโฮที่ได้อัดให้มีการประชุม Metadata ขึ้นเป็นครั้งแรก ในปี 1995 ตั้งแต่นั้นเป็นต้นมาก็เรียกกันว่า Dublin Core Metadata (DCM) คำว่า core ในที่นี้คือ เป็นตัวชี้ เช่น บัตรรายการหนังสือ

Metadata เป็นศัพท์ทันสมัยสำหรับยุคอินเทอร์เน็ต หมายความว่าข้อมูลที่บอกรายละเอียดของข้อมูล ซึ่งอาจจะเป็นสิ่งของ กิจกรรม คน หรือหน่วยงานก็ได้ ถ้าเราแปรข้อมูลเหล่านี้ให้เป็นรูปดิจิทัลแล้ว ทุกสิ่งทุกอย่างจะมีสภาพเหมือนกัน แยกไม่ค่อยออกว่าอะไรเป็นอะไร Metadata คือป้ายหรือฉลากสำหรับอธิบายว่าข้อมูลแต่ละรายการคืออะไร โดยเราไม่ต้องเสียเวลาเปิดดูก่อน (ตัวอย่าง เช่น กระป๋องนม ที่มีฉลากภายนอกบอกให้เราทราบ ว่า สิ่งที่บรรจุอยู่ในกระป๋องเป็นนมผงหรือนมข้นหวาน หรือนมสด ผลิตโดยโรงงานใด ผลิตเมื่อไร หมดอายุเมื่อไร ราคาเท่าไร และผลิตเพื่อผู้บริโภคกลุ่มใด) เช่นเดียวกัน ข้อมูลที่อยู่ในรูปดิจิทัล จำเป็นต้องมีป้ายบอกเพื่อให้เราทราบว่า รายการนี้คือชื่อเรื่องของหนังสือ หรือชื่อภาพยนตร์ที่สร้างจากหนังสือ หรือชื่อเรื่องของหนังสือที่มีผู้แปลเป็นอีกภาษาหนึ่ง สำหรับกรณีที่เป็นชื่อเฉพาะ เช่น ชื่อคน ซึ่งเราพบบ่อยๆ ในการสืบค้นจาก www แต่แต่ละครั้งที่แสดงผลมักมีจำนวนมากกว่า 1 รายการ และเราต้องเลือกโดยการเดาว่า รายการนี้น่าจะเป็นเรื่องที่เราต้องการ ด้วยเหตุนี้การสืบค้นสารสนเทศจากอินเทอร์เน็ต โดยเฉพาะจาก www จึงจำเป็นต้องสร้าง Metadata เพื่อช่วยให้จัดข้อมูลได้ตามลักษณะเฉพาะที่แท้จริง ของข้อมูลแต่ละรายการ เพื่อนำไปสู่การสืบค้นที่มีประสิทธิภาพ

Metadata แท้ที่จริงคือการวิเคราะห์รายการหนังสือ และวารสารที่ห้องสมุดทั่วโลกปฏิบัติมาตั้งแต่อดีตมา เพราะส่วนใหญ่การพิมพ์หนังสือ และวารสารไม่ได้พิมพ์อย่างมีมาตรฐาน แม้ว่าเราจะมีมาตรฐานสากลของ ISO อยู่ก็ตาม บรรณารักษ์ถือว่าภารกิจสำคัญคือ การรวบรวม

รายการสิ่งพิมพ์ ที่ปรากฏอยู่หลากหลายรูปแบบ วิเคราะห์และจัดรูปแบบสำหรับสืบค้นง่ายๆ เสียใหม่ ให้มีรายการมาตรฐานที่ประกอบด้วย รายการผู้แต่ง ชื่อเรื่อง และคำสำคัญ ที่จะสื่อให้เราทราบว่า สารสนเทศรายการนั้นคือหนังสือ หรือวารสาร หรือฐานข้อมูล วิธีการของบรรณารักษ์เป็นมาตรฐานสากล ใช้ได้ผลก็จริง แต่เป็น Metadata ที่มีรายละเอียดมาก เช่น U.S. MARC ค่อนข้างยากสำหรับคนทั่วไปที่จะใช้ ปัจจุบันสารสนเทศที่เผยแพร่ในอินเทอร์เน็ตเพิ่มมากขึ้นทุกที จนกระทั่งหลายคนคิดว่า น่าจะมีวิธีแบบที่บรรณารักษ์ใช้ และสามารถสืบค้นสารสนเทศใน www ได้ถูกต้องรวดเร็ว โดยไม่ต้องเสียเวลาคัดเลือกว่า รายการที่แสดงผลมากมาย เรื่องใดเป็นบทความวิชาการ บทโฆษณา บทภาพยนตร์ หรือบทวิจารณ์

Dublin Core Metadata Elements ประกอบด้วยรายการ ที่แสดงลักษณะพื้นฐานของสารสนเทศ 15 ข้อ เพื่อให้พัฒนาข้อมูลดิจิทัล และทำดัชนีสำหรับสืบค้นได้อย่างมีประสิทธิภาพ

๑. ชื่อเรื่อง - Title

คำจำกัดความ ชื่อของทรัพยากรสารสนเทศ ได้แก่ ชื่อเว็บเพจ (Web page)
ชื่อหนังสือ ชื่อฐานข้อมูล CD-ROM ชื่อสื่อการสอน ฯลฯ

๒. เจ้าของงาน - Creator

คำจำกัดความ ผู้แต่ง ผู้สร้างสรรค์เนื้อหาผลงานของทรัพยากรสารสนเทศ

๓. หัวเรื่อง และ คำสำคัญ - Subject and Keywords

คำจำกัดความ ชื่อเฉพาะ คำ หรือ วลี ที่อธิบายเรื่องและเนื้อหาของทรัพยากรสารสนเทศ

๔. สาระสังเขป - Description

คำจำกัดความ สาระสำคัญของทรัพยากรสารสนเทศ

๕. หน่วยงานที่ผลิต - Publisher

คำจำกัดความ หน่วยงานที่ผลิตและเผยแพร่ทรัพยากรสารสนเทศ

6. ผู้ร่วมงาน – Contributor

คำจำกัดความ บุคคลหรือหน่วยงานที่มีส่วนร่วมสร้างสรรค์ทรัพยากรสารสนเทศ

๗. ปี - Date

คำจำกัดความ ปีที่ผลิตและเผยแพร่ทรัพยากรสารสนเทศ

๘. ประเภท - Type

คำจำกัดความ คุณลักษณะของทรัพยากรสารสนเทศ ได้แก่

- ข้อความ / Text เป็นทรัพยากรสารสนเทศที่เป็นข้อความ เช่น หนังสือ หนังสือพิมพ์ วิทยานิพนธ์

ตัวอย่าง

๑. แฟ้มเอกสาร ๒. เอกสารฉบับเต็ม

- รูปภาพ / Image เป็นทรัพยากรประเภทรูปภาพ เช่น ภาพถ่าย ภาพวาด ภาพเคลื่อนไหว ภาพสแกน

ตัวอย่าง ๑. รูปภาพ ๒. ภาพนิ่ง ๓. ภาพเคลื่อนไหว

- เสียง / Sound เป็นทรัพยากรสารสนเทศประเภทเสียง เช่น เสียงจากแถบบันทึกเสียง เสียงดนตรี เสียงบรรยาย

ตัวอย่าง ๑. เสียงบรรยายบทสวด ๒. เพลงประกอบ

- ฐานข้อมูล / Data เป็นทรัพยากรสารสนเทศประเภทฐานข้อมูล เช่น ตารางคำนวณ ตาราง ระเบียบข้อมูล

ตัวอย่าง ๑. ฐานข้อมูล ๒. ตารางคำนวณ

- ซอฟต์แวร์ / Software เป็นทรัพยากรสารสนเทศประเภทโปรแกรมคอมพิวเตอร์

ตัวอย่าง Acrobat Reader

- สื่อปฏิสัมพันธ์ / Multimedia เป็นทรัพยากรสารสนเทศสื่อผสม สื่อปฏิสัมพันธ์

ตัวอย่าง ๑. บทเรียนคอมพิวเตอร์ช่วยสอน ๒. วิดิทัศน์ ๓. มัลติมีเดีย

๘. รูปแบบ – Format

คำจำกัดความ ลักษณะ รูปร่าง และขนาดของทรัพยากรสารสนเทศเชิงกายภาพ และดิจิทัล เพื่อชี้ให้เห็นถึง ซอฟต์แวร์ และอุปกรณ์ที่ใช้อ่านหรือประมวลทรัพยากรสารสนเทศ

๑๐. รหัส - Identifier

คำจำกัดความ ที่อยู่ของเว็บเพจ

๑๑. ต้นฉบับ – Source

คำจำกัดความ การอ้างอิงถึงผลงานที่มาของทรัพยากรสารสนเทศ ที่อาจดัดแปลงบางส่วนหรือทั้งเรื่อง ไม่ว่าจะเป็นเอกสารหรืออยู่ในรูปอิเล็กทรอนิกส์

๑๒. ภาษา - Language

คำจำกัดความ ภาษาที่ใช้ในการเรียบเรียงสารสนเทศ กำหนดให้ใช้ตามมาตรฐาน
RFC 1766 (<http://ds.internic.net/rfc/rfc1776.txt>)

๑๓. เรื่องที่เกี่ยวข้อง – Relation

คำจำกัดความ การอ้างอิงถึงผลงานหรือทรัพยากรสารสนเทศที่เกี่ยวข้องสัมพันธ์กับทรัพยากรสารสนเทศที่ผลิต

๑๔. ขอบเขต - Coverage

คำจำกัดความ ระยะเวลาและหรือสถานที่ที่กล่าวถึงในเนื้อหาทรัพยากรสารสนเทศ

๑๕. สิทธิ - Rights Management

คำจำกัดความ ข้อมูลเกี่ยวกับเจ้าของสิทธิในทรัพยากรสารสนเทศรวมถึงสิทธิทางทรัพย์สินทางปัญญา ลิขสิทธิ์ และสิทธิในทรัพย์สินอื่น ๆ

3.2 การนำ XML มาใช้เก็บข้อมูล

ในขั้นตอนนี้เราจะต้องทำการออกแบบว่าจะเก็บข้อมูลวิทยานิพนธ์อะไรลงใน XML บ้าง และมีรูปแบบโครงสร้างเช่นไร ซึ่งในที่นี้เราได้ใช้รูปแบบการเก็บเอกสารตามหลัก Dublin Core ซึ่งมาหลักๆด้วยกัน 15 อย่าง แต่เราได้ทำการเพิ่มรูปแบบการเก็บข้อมูลเข้าไปอีกเพื่อให้ได้ข้อมูลที่ครบถ้วนตามต้อง โดยโครงสร้าง XML สามารถกำหนดได้โดยใช้ DTD ซึ่งใน Thesis เล่มนี้ได้ใช้ DTD ดังนี้

- การออกแบบโครงสร้างเอกสารในรูปแบบ DTD

```
<?xmlversion="1.0" encoding="UTF-8"?>
<!ELEMENT Book (DC, Kmitl)>
<!ELEMENT DC (DC_Title, DC_Creator, DC_Subject, DC_Desscription, DC_Contributor,
DC_Publisher, DC_Date, DC_Format, DC_Identifier, DC_Source, DC_Language,
DC_Relation?, DC_Coverage?, DC_Rights, DC_Thesis)>
<!ELEMENT DC_Title (Title_Title, Title_Alternative)>
<!ELEMENT Title_Title (#PCDATA)>
<!ELEMENT Title_Alternative (#PCDATA)>
<!ELEMENT DC_Creator (Creator_Name+, Creator_Org_Name, Creator_E-Mail*)>
<!ELEMENT Creator_Name (#PCDATA)>
<!ELEMENT Creator_Org_Name (#PCDATA)>
<!ELEMENT Creator_E-Mail (#PCDATA)>
<!ELEMENT DC_Subject (Subject_ThaSH)>
<!ELEMENT Subject_ThaSH (#PCDATA)>
<!ELEMENT DC_Desscription (Desscription_Abstract)>
<!ELEMENT Desscription_Abstract (#PCDATA)>
<!ELEMENT DC_Contributor (Contributor_Name+, Contributor_Roles, Contributor_E-
mail*)>
<!ELEMENT Contributor_Name (#PCDATA)>
<!ELEMENT Contributor_Roles (#PCDATA)>
<!ELEMENT Contributor_E-mail (#PCDATA)>
<!ELEMENT DC_Publisher (Publisher_Name, Publisher_Place, Publisher_E-mail*)>
<!ELEMENT Publisher_Name (#PCDATA)>
<!ELEMENT Publisher_Place (#PCDATA)>
```

```

<![ELEMENT Publisher_E-mail (#PCDATA)>
<![ELEMENT DC_Date (Date_Created, Date_Issued, Date_Modified)>
<![ELEMENT Date_Created (#PCDATA)>
<![ELEMENT Date_Issued (#PCDATA)>
<![ELEMENT Date_Modified (#PCDATA)>
<![ELEMENT DC_Format (#PCDATA)>
<![ELEMENT DC_Identifier (Identifier_Url, Identifier_Isbn?, Identifier_Issn?,
Identifier_BibliographyCitation?)>
<![ELEMENT Identifier_Url (#PCDATA)>
<![ELEMENT Identifier_Isbn (#PCDATA)>
<![ELEMENT Identifier_Issn (#PCDATA)>
<![ELEMENT Identifier_BibliographyCitation (#PCDATA)>
<![ELEMENT DC_Source (Source_Call_Number)>
<![ELEMENT Source_Call_Number (#PCDATA)>
<![ELEMENT DC_Language (#PCDATA)>
<![ELEMENT DC_Relation (#PCDATA)>
<![ELEMENT DC_Coverage (#PCDATA)>
<![ELEMENT DC_Rights (Rights_Rights, Rights_Rights_Access)>
<![ELEMENT Rights_Rights (#PCDATA)>
<![ELEMENT Rights_Rights_Access (#PCDATA)>
<![ELEMENT DC_Thesis (Thesis_Degree_Name, Thesis_Degree_Level,
Thesis_Degree_Descipline, Thesis_Degree_Grantor)>
<![ELEMENT Thesis_Degree_Name (#PCDATA)>
<![ELEMENT Thesis_Degree_Level (#PCDATA)>
<![ELEMENT Thesis_Degree_Descipline (#PCDATA)>
<![ELEMENT Thesis_Degree_Grantor (#PCDATA)>
<![ELEMENT Kmitl ( Creator_English+, Adviser_English+, Faculty, Department_English,
Year_English, Abstract_English, Contents?, Illustrative?, Chapter, Bibliography?, Appendix?,
Keyword?)>
<![ELEMENT Creator_English (#PCDATA)>
<![ELEMENT Adviser_English (#PCDATA)>
<![ELEMENT Faculty (Faculty_Thai, Faculty_English)>

```

```

<!ELEMENT Faculty_Thai (#PCDATA)>
<!ELEMENT Faculty_English (#PCDATA)>
<!ELEMENT Department_English (#PCDATA)>
<!ELEMENT Year_English (#PCDATA)>
<!ELEMENT Abstract_English (#PCDATA)>
<!ELEMENT Contents (#PCDATA)>
<!ELEMENT Illustrative (#PCDATA)>
<!ELEMENT Chapter
(Chapter1,Chapter2,Chapter3,Chapter4,Chapter5?,Chapter6?,Chapter7?,Chapter8?,Chapter9?,C
hapter10?,Chapter11?,Chapter12?,Chapter13?,Chapter14?,Chapter15?)>
<!ELEMENT Chapter1 (#PCDATA)>
<!ELEMENT Chapter2 (#PCDATA)>
<!ELEMENT Chapter3 (#PCDATA)>
<!ELEMENT Chapter4 (#PCDATA)>
<!ELEMENT Chapter5 (#PCDATA)>
<!ELEMENT Chapter6 (#PCDATA)>
<!ELEMENT Chapter7 (#PCDATA)>
<!ELEMENT Chapter8 (#PCDATA)>
<!ELEMENT Chapter9 (#PCDATA)>
<!ELEMENT Chapter10 (#PCDATA)>
<!ELEMENT Chapter11 (#PCDATA)>
<!ELEMENT Chapter12 (#PCDATA)>
<!ELEMENT Chapter13 (#PCDATA)>
<!ELEMENT Chapter14 (#PCDATA)>
<!ELEMENT Chapter15 (#PCDATA)>
<!ELEMENT Bibliography (#PCDATA)>
<!ELEMENT Appendix (#PCDATA)>
<!ELEMENT Keyword (#PCDATA)>

```

โดยการออกแบบโครงสร้างการเก็บข้อมูลเอกสาร XML นั้นเราจะแบ่งออกเป็น 2 อิลิเมนต์ใหญ่ๆ 2 ตัว คือ อิลิเมนต์ที่ชื่อ DC ซึ่งย่อมาจาก DublinCore ซึ่งเราใช้เป็นเกณฑ์มาตรฐานหลักในการจัดเก็บ และอิลิเมนต์ที่ชื่อ kmitl ที่ออกแบบมาเพื่อเก็บข้อมูลเพิ่มเติมจากที่ DC ไม่มี เพื่อให้ได้ข้อมูลที่เก็บครบถ้วน โดยแต่ละอิลิเมนต์ย่อยมีความหมายดังนี้

อิลิเมนต์	ความหมาย
Title_Title	ชื่อโครงการวิจัยภาษาไทย
Title_Alternative	ชื่อโครงการวิจัยภาษาอังกฤษ
Creator_Name	ชื่อผู้วิจัย และผู้ร่วมวิจัยภาษาไทย
Creator_Org_Name	ชื่อภาควิชาที่สังกัด
Creator_E-Mail	e-mail ของผู้ทำวิทยานิพนธ์
Subject_ThaSH	หัวเรื่อง
Desscription_Abstract	บทคัดย่อโครงการวิจัย ภาษาไทย
Contributor_Name	ชื่ออาจารย์ที่ปรึกษาภาษาไทย
Contributor_Roles	ใส่คำว่า "อาจารย์ผู้ควบคุมวิทยานิพนธ์"
Contributor_E-mail	e-mail อาจารย์ผู้ควบคุมวิทยานิพนธ์
Publisher_Name	ชื่อหน่วยงานที่จัดทำ
Publisher_Place	ชื่อจังหวัด
Publisher_E-mail	e-mail ของหน่วยงานที่ทำ
Date_Created	ปี พ.ศ. ของวิทยานิพนธ์
Date_Issued	ปี พ.ศ. /เดือน/วัน
Date_Modified	แก้ไขเมื่อ ปี พ.ศ./ เดือน /วัน
DC_Format	ชนิด เอกสาร
Identifier_Url	เว็บ ของ สำนักหอสมุด
Identifier_Isbn	เลข Isbn
Identifier_Issn	เลข Issn
Identifier_BibliographyCitation	ไม่ได้กรอกข้อมูล
Source_Call_Number	เลขหมู่หนังสือ
DC_Language	หนังสือ ภาษาไทย หรือ ภาษาอังกฤษ
DC_Relation	ไม่ได้กรอกข้อมูล
DC_Coverage	ไม่ได้กรอกข้อมูล
Rights_Rights	ชื่อสถาบัน
Rights_Rights_Access	สามารถเข้าใช้ได้เฉพาะสมาชิกในกลุ่ม
Thesis_Degree_Name	หลักสูตร
Thesis_Degree_Level	ระดับปริญญา

Thesis_Degree_Descipline	สาขาวิชา
Thesis_Degree_Grantor	ชื่อสถาบัน
Creator_English	ชื่อผู้วิจัย และผู้ร่วมวิจัยภาษาอังกฤษ
Adviser_English	ชื่ออาจารย์ที่ปรึกษาภาษาอังกฤษ
Faculty_Thai	คณะวิชา Thai
Faculty_English	คณะวิชาภาษาอังกฤษ
Discipline_English	สาขาวิชาภาษาอังกฤษ
Year_English	ปีภาษาอังกฤษ
Abstract_English	บทคัดย่อภาษาอังกฤษ
Contents	สารบัญ
Illustrative	สารบัญ รูป
Chapter	เนื้อหาแต่ละบท
Bibliography	อ้างอิง
Appendix	ภาคผนวก
Keyword	คำค้นหา

ตารางที่ 3.1 โครงสร้างการเก็บข้อมูลเอกสาร XML

3.3 การจัดเก็บข้อมูลลงในดาต้าเบสเซิร์ฟเวอร์

ในขั้นตอนการจัดเก็บข้อมูลลงดาต้าเบสเซิร์ฟเวอร์ นั้น จะต้องสร้าง Database Schema เพื่อมาทำการตรวจสอบความถูกต้องของ XML ที่ทำการเก็บลงในดาต้าเบสเซิร์ฟเวอร์ เมื่อแมปเป็น Database Schema แล้วทำการ Normalize แล้วจะได้ ตารางดังนี้

DC_BOOK

COLUMN NAME	TYPE	SIZE	KEY
BOOK_ID	nchar	10	P.K.
DESCRIPTION_ID	nchar	6	F.K.
TITLE_THAI	ntext	-	
TITLE_ENGLISH	ntext	-	
SUBJECT	nvarchar	MAX	
ABSTRACT_THAI	nvarchar	MAX	
ABSTRACT_ENGLISH	nvarchar	MAX	
YEAYCREATED_THAI	nchar	10	
YEAYCREATED_ENGLISH	nchar	10	
DATE_ISSUED	nvarchar	50	
DATE_MODIFIED	nvarchar	20	
FOMAT	ncha	10	
LANGUAGE	nchar	10	
INEDTIFIER_ISSN	nvarchar	15	
INEDTIFIER_ISBN	nvarchar	15	
CALL_NUMBER	nvarchar	50	
RELATION	nchar	10	
COVERAGE	nchar	10	
DEGREEGRANTOR	nvarchar	50	
KEYWORD	ntext	-	
FILEXML	xml	-	
POSITION	nchar	2	
POSITIONFILE	nchar	2	

ตารางที่ 3.2 ข้อมูลทั่วไปของวิทยานิพนธ์

DC_CHAPTER

COLUMN NAME	TYPE	SIZE	KEY
CHAPTER_ID	nchar	10	P.K.
BOOK_ID	nchar	10	F.K.
CONTENTS	ntext	-	
ILLUSTRATIVE	ntext	-	
CHAPTER1	ntext	-	
CHAPTER2	ntext	-	
CHAPTER3	ntext	-	
CHAPTER4	ntext	-	
CHAPTER5	ntext	-	
CHAPTER6	ntext	-	
CHAPTER7	ntext	-	
CHAPTER8	ntext	-	
CHAPTER9	ntext	-	
CHAPTER10	ntext	-	
CHAPTER11	ntext	-	
CHAPTER12	ntext	-	
CHAPTER13	ntext	-	
CHAPTER14	ntext	-	
CHAPTER15	ntext	-	
APPENDIX	ntext	-	
BIBLIOGRAPHY	ntext	-	

ตารางที่ 3.3 ข้อมูลแค็ตตาล็อกของวิทยานิพนธ์

DC_KEYWORD

COLUMN NAME	TYPE	SIZE	KEY
TEXTKEYWORD	nvarchar	50	P.K.
BOOKCOUNT	ntext	-	

ตารางที่ 3.4 ข้อมูลการทำ Index ของวิทยานิพนธ์

DC_CONTRIBUTOR

COLUMN NAME	TYPE	SIZE	KEY
CONTRIBUTOR_ID	nvarchar	10	P.K.
CONTRIBUTOR_NAME	nvarchar	50	
CONTRIBUTOR_ENGLISH	nvarchar	50	
CONTRIBUTOR_E_MAIL	nvarchar	50	
CONTRIBUTOR_ROLES	nvarchar	50	

ตารางที่ 3.5 ข้อมูลอาจารย์ผู้ควบคุมวิทยานิพนธ์

DC_CREATOR

COLUMN NAME	TYPE	SIZE	KEY
CREATOR_ID	nchar	10	P.K.
BOOK_ID	nchar	10	F.K.
CREATOR_NAME	ntext	-	
CREATOR_ENGLIST	ntext	-	
CREATOR_E_MAIL	ntext	-	
CREATOR_ORG_NAME	ntext	-	

ตารางที่ 3.6 ข้อมูลผู้จัดทำวิทยานิพนธ์

DC_DEGREE

COLUMN NAME	TYPE	SIZE	KEY
DEGREE_ID	nchar	6	P.K.
DEGREE_LAVEL	nvarchar	50	
DEGREE_NAME	nvarchar	50	

ตารางที่ 3.7 ข้อมูลระดับการศึกษาของวิทยานิพนธ์

DC_DEPARTMEN

COLUMN NAME	TYPE	SIZE	KEY
DEPARTMENTID	nchar	6	P.K.
FACULTYID	nchar	6	F.K.
DEPARTMENT_THAI	nvarchar	50	
DEPARTMENTID_ENG	nvarchar	50	

ตารางที่ 3.8 ข้อมูลภาควิชาของวิทยานิพนธ์

DC_DESCRIPTION

COLUMN NAME	TYPE	SIZE	KEY
DESCRIPTION_ID	nchar	6	P.K.
DEPARTMENTID	nchar	6	F.K.
DESCRIPTION_THAI	nvarchar	50	
DESCRIPTION_ENGLISH	nvarchar	50	

ตารางที่ 3.9 ข้อมูลสาขาวิชาของวิทยานิพนธ์

DC_FACULTY

COLUMN NAME	TYPE	SIZE	KEY
FACULTYID	nchar	6	P.K.
DEGREE_ID	nchar	6	F.K.
FACULTY_THAI	nvarchar	50	
FACULTY_ENGLISH	nvarchar	50	

ตารางที่ 3.10 ข้อมูลคณะวิชาของวิทยานิพนธ์

LOGIN

COLUMN NAME	TYPE	SIZE	KEY
USERNAME	nvarchar	50	P.K.
PASSWORD	nvarchar	MAX	
PRIVILEGE	nchar	2	

ตารางที่ 3.11 ข้อมูลสมาชิกที่ทำการกรอกข้อมูลของเจ้าหน้าที่

DC_FILE

COLUMN NAME	TYPE	SIZE	KEY
FILE_ID	nchar	10	P.K.
BOOK_ID	nchar	10	F.K.
LINK_FILE	nvarchar	MAX	
FILE_BOOK_FULL	nvarchar	50	
FILE_CHAPTER1	nvarchar	50	
FILE_CHAPTER2	nvarchar	50	
FILE_CHAPTER3	nvarchar	50	
FILE_CHAPTER4	nvarchar	50	
FILE_CHAPTER5	nvarchar	50	
FILE_CHAPTER6	nvarchar	50	
FILE_CHAPTER7	nvarchar	50	
FILE_CHAPTER8	nvarchar	50	
FILE_CHAPTER9	nvarchar	50	
FILE_CHAPTER10	nvarchar	50	
FILE_CHAPTER11	nvarchar	50	
FILE_CHAPTER12	nvarchar	50	
FILE_CHAPTER13	nvarchar	50	
FILE_CHAPTER14	nvarchar	50	
FILE_CHAPTER15	nvarchar	50	
FILE_DOCUMENT	nvarchar	50	

ตารางที่ 3.12 ข้อมูลการเก็บ Link File PDF ของวิทยานิพนธ์

SUB_BOOK

COLUMN NAME	TYPE	SIZE	KEY
CONTRIBUTOR_ID	nvarchar	10	P.K.
BOOK_ID	nchar	10	P.K. , F.K.

ตารางที่ 3.13 ข้อมูลความสัมพันธ์ระหว่างวิทยานิพนธ์และอาจารย์ผู้ควบคุมวิทยานิพนธ์

DC_PUBLISHER

COLUMN NAME	TYPE	SIZE	KEY
PUBLISHER_ID	nchar	6	P.K.
BOOK_ID	nchar	10	P.K. , F.K.
PUBLISHER_NAME	nvarchar	MAX	
PUBLISHER_PLACE	nvarchar	MAX	
PUBLISHER_E_MAIL	nvarchar	MAX	
IDENTIFIER_URL	nvarchar	MAX	
RIGHTS_RIGHTS	nvarchar	MAX	
RIGHTS_ACCRESS	nvarchar	MAX	

ตารางที่ 3.14 ข้อมูลสำนักพิมพ์หรือสถาบันการศึกษาที่เป็นเจ้าของวิทยานิพนธ์

3.4 การทำดัชนีในการค้นหาข้อมูล

โครงสร้างเอกสาร XML เพื่อจัดเก็บข้อมูลวิทยานิพนธ์ โดยออกแบบเพื่อให้เก็บข้อมูลทั้งหมดของวิทยานิพนธ์ที่เป็นตัวอักษร แล้วทำการแยกคำที่เป็นภาษาไทย และ ภาษาอังกฤษ ออกเพื่อให้ง่ายต่อการทำดัชนี

3.4.1 การประมวลผลคำในเอกสาร XML

การประมวลผลคำในเอกสาร XML มีขั้นตอนดังต่อไปนี้

1. การคัดเลือกแท็ก คือ คัดเลือกแท็กที่มีความเกี่ยวข้องกับการทำดัชนี
2. การวิเคราะห์ระดับคำ(Lexical analysis) โดยทำการแยกข้อความออกมาว่าเป็นข้อมูลชนิดใด เช่น ตัวเลข, เครื่องหมายหรือว่าเป็นตัวอักษร
3. ตัดคำที่ไม่มีอำนาจจำแนกคำ เช่น ก็,กัน,การ,ของ, คน,ความ,จะ ฯลฯ

การคัดเลือกแท็ก

การคัดเลือกแท็ก คือการคัดเลือกแท็กในเอกสารที่จะนำเอาข้อมูลภายในแท็กนั้นมาคิดหาคำดัชนี โดยคัดเลือกแท็กที่มีความสำคัญของเอกสาร และตัดข้อมูลในแท็กที่ไม่มีความสำคัญสำหรับเอกสารออกเพื่อลดจำนวนข้อมูลที่น่ามาประมวลผล

การวิเคราะห์ระดับของคำ

การวิเคราะห์ระดับของคำ คือการเปลี่ยนข้อมูลจากตัวอักษรมาสู่ข้อมูลที่อยู่ในรูปของคำ ดังนั้นส่วนที่สำคัญคือการระบุให้ได้ว่ากลุ่มตัวอักษรนั้นคือคำว่าอะไร นอกจากนี้ยังต้องสามารถจำแนกตัวเลข และเครื่องหมายวรรคตอนต่างๆ ออกจากตัวอักษรให้ได้

เครื่องหมายวรรคตอน สามารถที่จะเอาออกได้เนื่องจากมีผลต่อระบบสืบค้นน้อยมากเมื่อผ่านขั้นตอนนี้แล้วจะได้คำและกลุ่มคำ ซึ่งได้ทำการเขียนโปรแกรมเพื่อทำการวิเคราะห์ระดับคำที่เป็นภาษาไทย ส่วนภาษาอังกฤษใช้ช่องว่างแบ่งคำ และใช้การวิเคราะห์ระดับแท็กในการแบ่งคำหรือกลุ่มคำเฉพาะในแท็กที่ใช้เครื่องหมายวรรคตอนเฉพาะเช่น คำในแท็กคำสำคัญจะใช้เครื่องหมาย (,) ในการแบ่งคำหรือกลุ่มคำ

การตัดคำที่มีอำนาจจำแนกคำ

คำที่พบบ่อยในเอกสารเกิน 80 % ของจำนวนเอกสารทั้งหมดในระบบถือว่าเป็นคำที่มีอำนาจจำแนกคำ (Stop word) ซึ่งจะถูกลบทิ้งไม่นำมาคำนวณในการคิดเป็นดัชนี

วิธีการคำนวณน้ำหนักคำดัชนี

กำหนดให้สำหรับแต่ละแท็กร่วมคิดคำนวณจากความถี่ของดัชนีคำที่ปรากฏในเอกสารเป็นหลักซึ่งเป็นการมองเอกสารแบบไม่มีโครงสร้างและไม่มีให้ความสำคัญกับส่วนของข้อมูลที่มีความแตกต่างกัน โดยจะนำเอาดัชนีคำที่ทำการหาได้นั้น ทำการหาความถี่ ที่ปรากฏในเอกสารสมมติให้มีคำว่า “com” ซึ่งปรากฏซ้ำๆ ในเอกสารจากนั้นได้แสดงให้เห็นถึงความแตกต่างในการคำนวณค่าน้ำหนักคำดัชนี ได้ผลการคำนวณในตารางที่ 3.15

เอกสาร	คำทั้งหมดที่พบในเอกสาร (“com”)
Book 1	20
Book 2	10
Book 3	50
Book 4	30
Book 5	10

ตารางที่ 3.15 การแสดงผลการหาความถี่ของคำในเอกสาร XML

เมื่อได้ค่าน้ำหนักคำดัชนี แล้วก็จะนำเอาค่าน้ำหนักคำดัชนีที่มีค่ามากที่สุดนำขึ้นมาแสดงเป็นอันดับแรกเมื่อมีการสืบค้นข้อมูล แต่ถ้าค่าน้ำหนักของคำดัชนีมีค่าเท่ากันก็ จะเอาเล่มใดเล่มหนึ่งขึ้นมาทำการแสดงก่อนก็ได้ อย่างเช่นในตารางที่ 3.16

เอกสาร	ค้นหาคำว่า (“com”)
Book 3	50
Book 4	30
Book 1	20
Book 2	10
Book 5	10

ตารางที่ 3.16 แสดงการจัดเรียงลำดับค่าน้ำหนักคำดัชนีในการสืบค้นข้อมูล