

ระบบตรวจหาข้อมูลอันตรายในเวิร์ลไวด์เว็บ
WORLD WIDE WEB MALEFIC CODE INSPECTION SYSTEM

นางสาว พิษานี ทัดสนเสถียร
นาย ภัคดีทูล ใจทอง

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต
สาขาวิชาวิศวกรรมคอมพิวเตอร์
คณะวิศวกรรมศาสตร์
สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง
พ.ศ. 2549

ระบบตรวจหาข้อมูลอันตรายในเวิร์ลไวด์เว็บ
WORLD WIDE WEB MALEFIC CODE INSPECTION SYSTEM

โดย
นางสาว พิชานี ทศนเสถียร
นาย ภักดิ์ภูธ ใจทอง

อาจารย์ที่ปรึกษา
อาจารย์ ธนัญชัย ศรีภาค
อาจารย์ อัครเดช วัชรภูพงษ์

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต
สาขาวิชาวิศวกรรมคอมพิวเตอร์
คณะวิศวกรรมศาสตร์
สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง
พ.ศ.2549

ปริญญานิพนธ์ปีการศึกษา 2549

ภาควิชาวิศวกรรมคอมพิวเตอร์

คณะวิศวกรรมศาสตร์ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

เรื่อง ระบบตรวจหาข้อมูลอันตรายในเวิร์ลไวด์เว็บ

WORLD WIDE WEB MALEFIC CODE INSPECTION SYSTEM

ผู้จัดทำ

1. นางสาว พิชานี ทศนเสถียร รหัสประจำตัว 46010522
2. นาย ภักดีทูล ใจทอง รหัสประจำตัว 46010555

อาจารย์ที่ปรึกษา
(อาจารย์ ชาญชัย ศรีภาค)

อาจารย์ที่ปรึกษา
(อาจารย์ อัครเดช วัชรภูพงษ์)

ระบบตรวจหาข้อมูลอันตรายในเวิร์ลไวด์เว็บ

นางสาว พิชานี พิศนเสถียร	46010522
นาย ภักดิ์ทูล ใจทอง	46010555
อาจารย์ ธนัญชัย ศรีภาค	อาจารย์ที่ปรึกษา
อาจารย์ อัครเดช วัชรภพพงษ์	อาจารย์ที่ปรึกษาร่วม
ปีการศึกษา 2549	

บทคัดย่อ

เนื่องด้วยในปัจจุบันภาครัฐบาลมีนโยบายในการป้องกันและปราบปรามเว็บไซต์ที่มีเนื้อหาไม่เหมาะสม โดยกระบวนการตรวจสอบเว็บไซต์ดังกล่าวดำเนินการด้วยวิธีการตรวจสอบด้วยทีมงานของหน่วยงานราชการที่รับผิดชอบ ซึ่งล่าช้าและไม่ทันต่อการเพิ่มจำนวนของเว็บไซต์

โครงการนี้จึงได้จัดทำขึ้นเพื่อให้สามารถค้นหาเว็บไซต์ที่มีเนื้อหาไม่เหมาะสมให้มีประสิทธิภาพมากยิ่งขึ้น โดยสร้างระบบอัตโนมัติที่สามารถค้นหารายการเว็บที่มีเนื้อหาไม่เหมาะสมในอินเทอร์เน็ตอยู่ตลอดเวลา ในการตรวจสอบใช้การวิเคราะห์รูปภาพโดยใช้หลักของการประมวลผลรูปภาพ และเทคนิคการวิเคราะห์เนื้อหาในเว็บไซต์ เมื่อผ่านกระบวนการทั้งหมด จะทำการวิเคราะห์หาค่าน้ำหนักของความไม่เหมาะสมของเว็บไซต์นั้นๆว่ามีค่าความไม่เหมาะสมมากน้อยเพียงใด ถ้าเว็บไซต์ใดถูกวิเคราะห์ว่าเป็นเว็บไซต์ที่มีเนื้อหาไม่เหมาะสมจะถูกเก็บไว้ในรายการเว็บไซต์ต้องห้ามเพื่อให้ภาครัฐบาลดำเนินการกับเว็บไซต์นั้นๆ ในขั้นตอนต่อไป

World Wide Web Malefic Code Inspection System

Ms. Pichanee Tassanasatien	46010522
Mr. Paktoon Jaithong	46010555
Mr. Thananchai Treepak	Advisor
Mr. Akkradach Watcharapupong	Co-Advisor
Academic Year 2006	

ABSTRACT

Nowadays, Ministry of information and communication technology (ICT) proposes strict policy to prevent and suppress Thai people access any pornographic and inappropriate website. Group of authorized government officers named “Cyber Inspector” was established to investigate and block any website which contains pornographic content from all internet users. By using labor-intensive detection method, Cyber Inspector group unsuccessful in battle with porn websites because growth rate of porn websites is much more than human can identify manually.

For this reason, our project proposes an automatic pornographic website discovery system that recursive crawling websites in the internet and verifies that they are pornographic websites. In verifying process, our system uses not only image processing technique but also text analysis method to extract information from websites and then employ principal of component analysis to make a decision that each website is porn website or not. For all of pornographic website we get from our system, we collect them into database for future ICT work out.

กิตติกรรมประกาศ

ปริญญานิพนธ์ฉบับนี้สำเร็จลุล่วงได้อย่างดีด้วยคำแนะนำและคำปรึกษาเกี่ยวกับการดำเนินการศึกษาและวิจัยจากอาจารย์ธัญชัย ศรีภาค ซึ่งเป็นอาจารย์ผู้ควบคุมปริญญานิพนธ์และอาจารย์อัครเดช วัชรภูพงษ์ ผู้ควบคุมปริญญานิพนธ์ร่วม ผู้วิจัยรู้สึกซาบซึ้งในความอนุเคราะห์จากท่านอาจารย์ทั้งสองและขอกราบขอบพระคุณเป็นอย่างสูง

ขอขอบคุณห้องวิจัย ISAG ภาควิชาวิศวกรรมคอมพิวเตอร์ ที่ได้สนับสนุนเครื่องมือตลอดจนข้อมูล และหนังสือต่างๆที่ใช้ในการทำวิจัย

ขอกราบขอบพระคุณคณาจารย์ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง ทุกๆท่านที่ได้ประสิทธิ์ประสาทวิชาให้กับข้าพเจ้า

ขอขอบคุณเพื่อน ๆ พี่ ๆ น้องๆ ในภาควิชาวิศวกรรมคอมพิวเตอร์ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง ทุกคนที่ให้คำแนะนำต่างๆ และคอยให้กำลังใจเสมอมา

สุดท้ายนี้ข้าพเจ้าขอกราบขอบพระคุณ บิดา มารดา และครอบครัวของข้าพเจ้าที่เป็นกำลังใจ และให้การสนับสนุนในทุกๆเรื่อง ทำให้ข้าพเจ้าสามารถทำปริญญานิพนธ์ฉบับนี้สำเร็จลุล่วงด้วยดี

คุณค่าและประโยชน์อันพึงมาจากปริญญานิพนธ์ฉบับนี้ ข้าพเจ้าขอบแต่ผู้มีพระคุณทุกท่าน

นางสาว พิชานี ทศนเสถียร

นาย ภัคดิษฐ์ ใจทอง

สารบัญ

หน้า

บทคัดย่อภาษาไทย.....	I
บทคัดย่อภาษาอังกฤษ.....	II
กิตติกรรมประกาศ.....	III
สารบัญ.....	IV
สารบัญตาราง.....	VII
สารบัญรูป.....	VIII
บทที่ 1 บทนำ.....	1
1.1 ความสำคัญและที่มา.....	1
1.2 วัตถุประสงค์ของปริญญานิพนธ์.....	1
1.3 ขอบเขตของปริญญานิพนธ์.....	1
1.4 วิธีการดำเนินการ.....	2
1.5 ประโยชน์ที่คาดว่าจะได้รับ.....	2
1.6 ส่วนประกอบของปริญญานิพนธ์.....	3
บทที่ 2 ทฤษฎีที่เกี่ยวข้อง.....	4
2.1 กลไกการทำงานของระบบเสิร์จเอนจิน.....	4
2.1.1 โปรแกรมรวบรวมเอกสารเว็บ.....	4
2.1.2 รายการดัชนีข้อมูล.....	5
2.1.3 โปรแกรมการสืบค้น.....	5
2.2 หลักการทำงานของโปรแกรมรวบรวมเอกสารเว็บ.....	5
2.3 Google SOAP Search API.....	7
2.3.1 การทำงานของ Google SOAP Search API.....	7
2.4 พื้นฐานและระบบโครงสร้างสี่.....	8
2.4.1 ระบบโครงสร้างสี่อาร์จีบี.....	8
2.4.2 ระบบโครงสร้างสี่วายซีบีซีอาร์.....	9
2.4.3 การแปลงรูปแบบสี.....	10
2.5 กระบวนการค้นหาพื้นที่สีผิว.....	10
2.6 กระบวนการปรับความคมชัดของภาพ.....	14
2.6.1 First derivative.....	14
2.6.2 Second derivative.....	14

สารบัญ(ต่อ)

	หน้า
2.6.3 การใช้ First derivative ในการเพิ่มคุณภาพของภาพ.....	15
2.6.4 การใช้ Second derivative ในการเพิ่มคุณภาพของภาพ.....	16
2.6.5 การตรวจหาเส้นขอบด้วย กระบวนการโซเบล.....	16
2.7 การตรวจสอบเนื้อหาในเว็บไซต์	17
2.7.1 รูปแบบโครงสร้าง.....	18
2.8 Regular Expression.....	20
2.8.1 ความหมายและการใช้งาน.....	20
2.8.2 Meta-character.....	20
2.9 การจัดกลุ่มข้อมูล.....	21
2.9.1 สถิติ.....	22
2.9.2 Matrix Algebra.....	24
2.9.3 หลักการวิเคราะห์ส่วนประกอบ.....	25
2.9.4 K-Means.....	29
2.9.5 K-Nearest Neighbor.....	30
บทที่ 3 การออกแบบและพัฒนา.....	31
3.1 โครงสร้างของโครงการ.....	31
3.2 โปรแกรมรวบรวมเอกสารเว็บ.....	32
3.2.1 รายการเว็บไซต์ที่ยังไม่ได้เข้าถึง.....	34
3.2.2 การร้องขอบริการจาก Google SOAP Search API.....	34
3.2.3 การร้องขอเอกสารเว็บจากเครื่องที่ให้บริการ.....	37
3.2.4 การค้นหาลิงค์ของเว็บเพจและภาพภายในเอกสารเว็บ.....	38
3.2.5 โปรแกรมรวบรวมเอกสารเว็บแบบ Multi-threaded.....	39
3.3 โปรแกรมตรวจสอบภาพอนาจาร.....	40
3.3.1 Size and palette analysis.....	41
3.3.2 Skin detection module.....	41
3.3.3 Feature extraction module	41
3.3.4 Decision classifier module	43

สารบัญ(ต่อ)

	หน้า
3.4 โปรแกรมการวิเคราะห์เนื้อหาในเว็บไซต์.....	44
3.4.1 การจัดประเภทของเนื้อหาเว็บไซต์.....	47
3.5 โปรแกรมการคำนวณค่าน้ำหนักความไม่เหมาะสม.....	47
3.6 การออกแบบฐานข้อมูล.....	49
 บทที่ 4 การทดลองและผลการทดลอง.....	52
4.1 การทดสอบโปรแกรมรวบรวมเอกสารเว็บ.....	52
4.2 การทดสอบโปรแกรมตรวจสอบภาพอนาจาร.....	53
4.2.1 การตรวจหาสีผิวมนุษย์.....	53
4.2.2 การตรวจสอบคุณสมบัติของภาพ.....	54
4.2.3 การจัดประเภทของภาพด้วยคุณสมบัติ.....	55
4.3 การทดสอบโปรแกรมการวิเคราะห์เนื้อหาในเว็บไซต์.....	61
4.3.1 การตรวจสอบคุณสมบัติของเนื้อหาเว็บเพจ.....	61
4.3.2 การจัดประเภทของเว็บเพจด้วยคุณสมบัติ.....	62
4.4 การทดสอบประสิทธิภาพระบบ.....	64
 บทที่ 5 บทวิจารณ์และสรุป.....	66
5.1 บทสรุป.....	66
5.2 วิจารณ์สิ่งที่ได้จากโครงงาน	67
5.3 ปัญหาอุปสรรคและแนวทางในการแก้ไข	67
5.4 แนวทางการพัฒนาต่อ	67
 บรรณานุกรม	69
 ภาคผนวก.....	70
ภาคผนวก ก. ตัวอย่างข้อมูลที่ถูเก็บในฐานข้อมูล.....	71
ภาคผนวก ข. ตัวอย่างข้อมูลที่ได้จากการทดลอง	76

สารบัญตาราง

ตารางที่	หน้า
2.1 โครงสร้างที่แตกต่างกันระหว่างเว็บไซต์ธนาคารและเว็บไซต์ไม่ธนาคาร.....	18
2.2 คำที่ปรากฏทั้งในเว็บไซต์ธนาคารและเว็บที่ไม่ใช่เว็บธนาคาร.....	20
2.3 (a) ตัวอย่างข้อมูล 2 มิติ (x,y) ของข้อมูล 10 ตัวอย่าง.....	26
2.3 (b) ตัวอย่างข้อมูล 2 มิติ ที่มีการปรับค่าแล้วของข้อมูล 10 ตัวอย่าง.....	26
2.4 ตัวอย่างข้อมูลชุดใหม่ที่ผ่านมากระบวนการวิเคราะห์ส่วนประกอบ.....	28
3.1 คุณสมบัติ 6 ประการที่ได้จากภาพ.....	41
4.1 ผลการทดลองการตรวจสอบคุณสมบัติของภาพ.....	55
4.2 ประสิทธิภาพของการจัดกลุ่มข้อมูลของตัวอย่างภาพ.....	58
4.3 ประสิทธิภาพของการจัดกลุ่มข้อมูลของภาพนอกกลุ่มตัวอย่าง.....	60
4.4 ผลทดลองการตรวจสอบคุณสมบัติของเนื้อหาในเว็บไซต์.....	62
4.5 ประสิทธิภาพของการจัดกลุ่มข้อมูลของเว็บกลุ่มตัวอย่าง.....	64
4.6 ประสิทธิภาพของการจัดกลุ่มข้อมูลของเว็บนอกกลุ่มตัวอย่าง.....	64
ก.1 ตัวอย่างข้อมูลในตาราง ALLURL.....	72
ก.2 ตัวอย่างข้อมูลในตาราง IMAGE.....	73
ก.3 ตัวอย่างข้อมูลในตาราง PORN_WEB.....	74
ก.4 ตัวอย่างข้อมูลในตาราง ISP.....	75
ข.1 คุณสมบัติของเนื้อหาภายในเว็บเพจของข้อมูลตัวอย่างทั้ง 10 คุณสมบัติ.....	77
ข.2 คุณสมบัติของภาพของข้อมูลตัวอย่างทั้ง 6 คุณสมบัติ.....	78

สารบัญรูป

รูปที่	หน้า
2.1 การทำงานพื้นฐานของโปรแกรมรวบรวมเอกสารเว็บ.....	6
2.2 การค้นหาแบบ breadth-first และแสดง node ที่จะถูกค้นหาตามลำดับ.....	7
2.3 โครงสร้างสีอาร์จีบี เป็นลูกบาศก์.....	9
2.4 ความสัมพันธ์ระหว่างโครงสร้างสี YCbCr กับ RGB	9
2.5 กลุ่มตัวอย่างสีผิวในแกนของโครงสร้างสี YCbCr	11
2.6 กลุ่มตัวอย่างสีผิวในแกนของโครงสร้างสี HSV	11
2.7 กรอบพื้นที่สีผิวโครงสร้างสี YCbCr ที่ระนาบ $Y = 160$	12
2.8 กรอบพื้นที่สีผิวโครงสร้างสี HSV ที่ระนาบ $V = 70$	13
2.9 (a) จุดของภาพที่มีขอบเขต 3x3 pixel(ค่า z เป็นค่าระดับสีเทา)	16
2.9 (b)(c) Roberts cross-gradient operators.....	16
2.9 (d)(e) Sobel operators.....	16
2.10 (a) ตัวอย่างภาพต้นฉบับที่ต้องการหาเส้นขอบ.....	17
2.10 (b) ภาพที่ถูกตรวจหาเส้นขอบ (Sobel gradient).....	17
2.11 flow chart ของการหา K-Means	30
3.1 การทำงานของระบบ.....	32
3.2 ขั้นตอนการทำงานของโปรแกรมรวบรวมเอกสารเว็บ.....	33
3.3 ตัวอย่างการเรียกใช้ Library มาตรฐาน urllib2 และ httpplib ของภาษา Python	37
3.4 การทำงานของ Multi-threaded Crawler	39
3.5 การทำงานของการตรวจสอบภาพอนาจาร.....	40
3.6 การทำงานของโปรแกรมการตรวจสอบภาพอนาจาร.....	42
3.7 การทำงานของการคำนวณหาไอแกนเวกเตอร์และไอแกนเวกเตอร์ของชุดข้อมูลตัวอย่างและ การหาจุดเซ็นทรอยด์ 3 จุด.....	43
3.8 การจำแนกภาพ.....	44
3.9 ความสัมพันธ์ของเว็บไซต์และเอกสารเว็บในรูปของ Tree.....	47
3.10 ER diagram ของฐานข้อมูลระบบ.....	49
4.1 (a) ภาพต้นฉบับ	54
4.1 (b) ภาพเมื่อผ่านการทำกระบวนการตัดสีผิว.....	54
4.1 (c) ภาพเมื่อผ่านการทำ Sobel Edge Oprator กับภาพต้นฉบับ.....	54
4.1 (d) ภาพ เมื่อผ่านกระบวนการตัดสีผิวและผ่านการกรองด้วย Sobel Edge Oprator.....	54

สารบัญรูป (ต่อ)

รูปที่	หน้า
4.1 (e) ภาพเมื่อผ่านกระบวนการตัดเอาพื้นที่สีผิวที่มีขนาดเล็กออก.....	54
4.2 กราฟของความสัมพันธ์ของคุณสมบัติของภาพ.....	57
4.3 ผลการทดลองการจัดกลุ่มข้อมูลของตัวอย่างภาพ.....	58
4.4 ผลการแบ่งกลุ่มของภาพอนาจารนอกกลุ่มตัวอย่าง.....	59
4.5 ผลการแบ่งกลุ่มของภาพที่ไม่ใช่ภาพอนาจารนอกกลุ่มตัวอย่าง.....	60
4.6 กราฟของความสัมพันธ์ของคุณสมบัติของเว็บเพจ.....	63
4.7 สมการเส้นตรงที่ใช้แบ่งเว็บอนาจารจากเว็บไม่อนาจาร.....	63